



UNIVERSIDADE FEDERAL DO RIO GRANDE - FURG
CENTRO DE CIÊNCIAS COMPUTACIONAIS
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO
CURSO DE MESTRADO EM ENGENHARIA DE COMPUTAÇÃO

Dissertação de Mestrado

Reconstrução neural de cenas domésticas estruturadas para simulação robótica

João Francisco de Souza Santos Lemos

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Computação da Universidade Federal do Rio Grande - FURG, como requisito parcial para a obtenção do grau de Mestre em Engenharia de Computação

Orientador: Nelson Lopes Duarte Filho
Co-orientador: Rodrigo da Silva Guerra

Rio Grande, 2026

RESUMO

A reconstrução de ambientes a partir de imagens pode reduzir o trabalho de modelagem de cenas usadas em simulação robótica, mas uma representação neural não produz, por si só, objetos independentes, geometrias de colisão e superfícies de apoio adequadas ao simulador. Esta dissertação avalia uma cadeia baseada no DM-NeRF para converter uma reconstrução neural com decomposição de instâncias em uma cena explícita e estruturada. O estudo utiliza a cena *study* do conjunto DM-SR e separa a avaliação em síntese de vistas e decomposição de instâncias, geometria tridimensional e pós-processamento voltado à simulação. O treinamento final foi concluído em 200.000 iterações. Em 100 vistas de teste, o avaliador oficial obteve PSNR de 41,1100 dB, SSIM de 0,9875 e LPIPS de 0,0260. Para a decomposição, foram obtidos AP50 de 0,9956 e AP95 de 0,7192. A malha A0 contém 356.272 vértices e 710.928 faces. Na comparação com a referência do DM-SR, o F-score foi 0,0480 a 1 cm, 0,1960 a 2 cm e 0,7750 a 5 cm. Como baseline geométrico externo, o COLMAP foi executado com as poses oficiais e avaliado no mesmo suporte; seus F-scores foram 0,0285, 0,1288 e 0,3721 nos mesmos limiares. A separação A1 gerou 13 instâncias, preservando 95,844% das faces como faces homogêneas e registrando 29.545 faces de fronteira. Como o conjunto não fornece rótulo semântico rastreável para o piso, foi aplicada uma heurística geométrica definida antes da observação do resultado final; ela selecionou a instância 10 como candidata. A regularização A2 reduziu o P95 da distância ao plano de 6,80 cm para erro numérico, efeito esperado da projeção e que não é interpretado como aumento de fidelidade global. G0 e G1 passaram para A0, A1 e A2 no Gazebo Classic 11.10.2. Em G2, uma instância de A1 foi deslocada de forma independente. Em G3, uma caixa dinâmica caiu sobre a superfície regularizada e permaneceu apoiada na altura prevista pelo plano. Os resultados indicam que, para a cena estudada, a reconstrução decomposta pode ser transformada em modelos independentes e utilizáveis no simulador, embora a precisão geométrica dependa da escala de tolerância e as malhas continuem sem propriedades físicas ou articulações inferidas.

Palavras-chave: Reconstrução neural, simulação robótica, geometria tridimensional, DM-NeRF.

RESUMO

LEMOS, João Francisco de Souza Santos. **Neural reconstruction of structured domestic scenes for robotic simulation**. 2026. 41 f. Dissertação (Mestrado) – Programa de Pós-Graduação em Computação. Universidade Federal do Rio Grande - FURG, Rio Grande.

Image-based reconstruction can reduce the manual effort required to model environments for robotic simulation, but a neural scene representation does not directly provide independent objects, collision geometry, or suitable support surfaces. This dissertation evaluates a pipeline based on DM-NeRF to convert an instance-decomposed neural reconstruction into an explicit and structured scene. The study uses the *study* scene from DM-SR and separates the evaluation into view synthesis and instance decomposition, three-dimensional geometry, and post-processing for simulation. The final training reached 200,000 iterations. On 100 test views, the official evaluator reported 41.1100 dB PSNR, 0.9875 SSIM, and 0.0260 LPIPS. Instance decomposition obtained AP50 of 0.9956 and AP95 of 0.7192. The extracted A0 mesh contains 356,272 vertices and 710,928 faces. Against the DM-SR reference mesh, the F-score was 0.0480 at 1 cm, 0.1960 at 2 cm, and 0.7750 at 5 cm. As an external geometric baseline, COLMAP was run with the official poses and evaluated within the same support; its F-scores were 0.0285, 0.1288, and 0.3721 at the same thresholds. The A1 separation produced 13 instances and retained 95.844% of the faces as homogeneous faces, while 29,545 boundary faces were explicitly recorded. Because the inspected DM-SR artifacts do not provide a traceable semantic floor label, a predefined geometric heuristic selected instance 10 as the floor candidate. A2 regularization reduced the 95th percentile distance to the fitted plane from 6.80 cm to numerical error; this is an expected consequence of projection and is not interpreted as improved global reconstruction fidelity. G0 and G1 passed for A0, A1, and A2 in Gazebo Classic 11.10.2. In G2, one A1 instance was displaced independently. In G3, a dynamic box fell onto the regularized surface and remained supported at the height predicted by the fitted plane. The results show that, for the evaluated scene, the decomposed reconstruction can be converted into independent models that load and interact with the simulator, while geometric accuracy remains dependent on the distance tolerance and no physical properties or articulations are inferred.

Palavras-chave: neural reconstruction, robotic simulation, three-dimensional geometry, DM-NeRF.

LISTA DE FIGURAS

Figura 1 Comparação entre imagens de referência e renderizações finais. Linha superior: referência; linha inferior: DM-NeRF. Da esquerda para a direita, vistas 0, 33, 66 e 99. 25

Figura 2 Mapas de instância. Linha superior: referência; linha inferior: predição. Da esquerda para a direita, vistas 0, 33, 66 e 99. As cores identificam IDs do protocolo e não classes semânticas. 25

Figura 3 Comparação qualitativa da geometria no mesmo sistema de coordenadas, suporte e enquadramento. A nuvem COLMAP apresenta maior dispersão e superfícies mais espessas. 27

Figura 4 F-score geométrico de A0 e COLMAP nos limiares de 1, 2 e 5 cm. . . 28

Figura 5 Visualização da reconstrução colorida por instância em dois pontos de vista. As cores são usadas somente para distinguir IDs. 29

Figura 6 Resíduo assinado ao plano da instância 10 antes e depois da regularização. À esquerda, A1; à direita, A2. O eixo vertical é limitado a ± 20 cm para leitura da distribuição principal; o residual máximo de A1, 1,64 m, permanece reportado no texto e nas métricas. 30

Figura 7 Cena A2 no Gazebo Classic com materiais visuais distintos por instância. As cores foram adicionadas somente para interpretação da figura; a geometria e as colisões são as mesmas usadas nos testes funcionais. 32

LISTA DE TABELAS

Tabela 1 — PQ_{scene} publicado em benchmarks panópticos. Valores compilados por Bhalgat et al. [1]; não são diretamente comparáveis ao DM-SR desta dissertação. 14
Tabela 2 — Comparação qualitativa entre trabalhos relacionados e a cadeia desta dissertação. 15
Tabela 3 — Etapas da cadeia e evidências utilizadas. 16
Tabela 4 — Resumo da execução final. 23
Tabela 5 — Métricas do avaliador oficial na cena *study*. 24
Tabela 6 — Comparação entre a reprodução desta dissertação e os resultados publicados para a cena *study* do DM-SR. 24
Tabela 7 — Distâncias entre A0 e a referência DM-SR. 26
Tabela 8 — Precision, Completeness e F-score da geometria A0. 26
Tabela 9 — Comparação geométrica entre A0 e o baseline COLMAP no mesmo suporte e com 200.000 pontos por conjunto. 27
Tabela 10 — Resumo da separação A1. 28
Tabela 11 — Métricas da instância 10 antes e depois da regularização. 30
Tabela 12 — Resultado das verificações de integração com o Gazebo Classic. . . . 31

LISTA DE ABREVIATURAS E SIGLAS

AMP	Automatic Mixed Precision
AP	Average Precision
DM-NeRF	3D Scene Geometry Decomposition and Manipulation from 2D Images
DM-SR	conjunto de dados utilizado pelo protocolo do DM-NeRF
GT	Ground Truth
IoU	Intersection over Union
LPIPS	Learned Perceptual Image Patch Similarity
MVS	Multi-View Stereo
NeRF	Neural Radiance Field
PQ	Panoptic Quality
PSNR	Peak Signal-to-Noise Ratio
RANSAC	Random Sample Consensus
RMSE	Root Mean Squared Error
SDFormat	Simulation Description Format
SSIM	Structural Similarity Index Measure
URDF	Unified Robot Description Format

SUMÁRIO

1 Introdução **9**
1.1 Problema de pesquisa . . . 10
1.2 Objetivos . . . 10
1.3 Delimitação e contribuição . . . 11
1.4 Organização do texto . . . 11

2 Fundamentação e trabalhos relacionados **12**
2.1 Representações neurais de cenas e superfícies . . . 12
2.2 Estrutura de objetos e reconstrução panóptica . . . 12
2.3 Geração de ambientes para simulação . . . 13
2.4 Contexto quantitativo publicado . . . 13
2.5 Comparação por características . . . 14

3 Metodologia **16**
3.1 Visão geral . . . 16
3.2 Conjunto de dados DM-SR . . . 16
3.3 Treinamento e avaliação do DM-NeRF . . . 17
3.4 Extração da malha e contrato de rótulos . . . 17
3.5 Separação estrutural A1 . . . 18
3.6 Seleção geométrica do piso . . . 18
3.7 Regularização A2 . . . 18
3.8 Exportação para Gazebo Classic . . . 19

4 Protocolo experimental **20**
4.1 Unidade experimental e proveniência . . . 20
4.2 Condições A0, A1 e A2 . . . 20
4.3 Síntese de vistas e decomposição . . . 20
4.4 Avaliação geométrica . . . 21
4.5 Baseline geométrico externo . . . 21
4.6 Avaliação da separação e do piso . . . 22
4.7 Validação funcional . . . 22
4.8 Custo computacional . . . 22

5 Resultados **23**
5.1 Treinamento e custo computacional . . . 23
5.2 Síntese de vistas . . . 23
5.2.1 Comparação com os resultados publicados do DM-NeRF . . . 24

5.3 Decomposição de instâncias 25
5.4 Geometria A0 26
5.5 Baseline geométrico externo: COLMAP 26
5.6 Separação estrutural A1 28
5.7 Seleção e regularização do piso 29
5.8 Integração no Gazebo Classic 30

6 Discussão **33**

7 Limitações metodológicas **36**

8 Conclusão **38**

Referências **40**

1 INTRODUÇÃO

A construção de ambientes virtuais para robótica envolve requisitos diferentes dos encontrados em aplicações voltadas somente à visualização. Uma cena pode produzir imagens próximas das observações originais e, ainda assim, apresentar superfícies descontínuas, objetos fundidos ou uma organização que impeça a manipulação independente de seus componentes. Da mesma forma, o fato de uma malha poder ser carregada por um simulador não demonstra que sua geometria seja fiel ao ambiente reconstruído. Qualidade de imagem, qualidade geométrica e uso funcional em simulação são propriedades relacionadas, mas não equivalentes.

Os campos de radiância neurais, introduzidos por Mildenhall et al. [5], representam uma cena por uma função contínua aprendida a partir de imagens e poses de câmera. A formulação possibilita síntese de novas vistas e originou linhas de trabalho voltadas à reconstrução de superfícies, mapeamento e inclusão de informação semântica ou orientada a objetos. Entretanto, a saída de uma representação neural implícita não é diretamente uma cena de simulação. Para esse uso, é necessário obter geometria explícita, preservar a individualidade dos elementos e construir uma descrição compatível com mecanismos de visualização e colisão.

O DM-NeRF [9] combina uma representação neural da cena com decomposição em instâncias. No protocolo DM-SR utilizado nesta dissertação, o treinamento recebe imagens RGB, poses de câmera e mapas bidimensionais de instância. Assim, a decomposição não é obtida exclusivamente a partir das imagens RGB sem supervisão. A saída do método, por outro lado, fornece uma base para investigar a etapa posterior: como transformar uma reconstrução neuralmente decomposta em uma representação explícita que possa ser organizada e testada em um simulador.

Este trabalho examina essa transição. A cadeia estudada compreende a reprodução do DM-NeRF na cena *study* do DM-SR, a extração de uma malha, a associação explícita dos identificadores de instância aos vértices, a separação dos objetos, a identificação geométrica de um candidato a piso, a regularização condicionada dessa superfície e a exportação para Gazebo Classic. O SDFormat é empregado como mecanismo de descrição da cena, sem ser tratado como contribuição científica.

1.1 Problema de pesquisa

Simuladores como o Gazebo operam sobre entidades explícitas. Modelos, links, geometrias visuais e geometrias de colisão precisam estar definidos e referenciados. Uma cena reconstruída como uma única malha não permite remover ou reposicionar um móvel sem tratamento adicional. Superfícies de apoio com ruído podem gerar contatos e colisões diferentes daqueles esperados. Além disso, massa, inércia, atrito, articulações e outros parâmetros físicos não podem ser deduzidos de forma geral somente das imagens utilizadas na reconstrução.

A questão que orienta a dissertação é:

> **Em que medida uma reconstrução neural com decomposição de instâncias, combinada a pós-processamento geométrico, permite gerar ambientes domésticos estruturados para simulação robótica?**

A expressão "em que medida" é adotada porque a resposta não é binária. A cadeia é examinada separadamente nos domínios de síntese de vistas, decomposição de instâncias, geometria, estrutura dos objetos, planaridade do piso, integração com o simulador e custo computacional.

1.2 Objetivos

O objetivo geral é avaliar a capacidade de uma cadeia baseada em DM-NeRF e pós-processamento geométrico de transformar reconstruções neuralmente decompostas em ambientes domésticos estruturados para simulação robótica.

Os objetivos específicos são:

1) reproduzir e caracterizar a reconstrução e a decomposição da cena *study* do DM-SR com o DM-NeRF;

2) avaliar síntese de vistas e decomposição de instâncias pelo protocolo oficial do método;

3) avaliar a geometria explícita extraída, sem usar métricas de imagem como substituto de avaliação tridimensional;

4) transformar identificadores explícitos de instância em objetos tridimensionais independentes;

5) selecionar de forma rastreável um candidato geométrico a piso e medir o efeito de sua regularização;

6) avaliar a integração da cena estruturada no Gazebo Classic por critérios funcionais definidos previamente; e

7) registrar custo computacional e proveniência dos artefatos necessários à reprodução.

1.3 Delimitação e contribuição

O escopo experimental é restrito ao DM-NeRF como método neural principal, ao DM-SR como conjunto de dados e à cena *study* como estudo de caso. Não são propostas uma nova arquitetura neural, uma nova função de perda, um novo segmentador, recuperação de modelos CAD ou migração para outro simulador. O COLMAP integra a avaliação como baseline geométrico externo no mesmo suporte espacial, sem constituir uma comparação de decomposição de instâncias ou de integração com o simulador.

A contribuição consiste em caracterizar, de forma rastreável, a passagem de uma reconstrução DM-NeRF para geometria explícita, objetos independentes e uma cena executável no Gazebo Classic. Essa caracterização compreende: (i) um contrato explícito entre a topologia da malha e os identificadores de instância, incluindo o tratamento conservador das faces de fronteira; (ii) uma regra geométrica auditável para selecionar a superfície de apoio, seguida de regularização condicionada à validade da seleção; e (iii) uma avaliação que separa aparência, geometria, estrutura e funcionamento no simulador, incluindo a comparação geométrica externa com COLMAP. O trabalho não apresenta como contribuição o DM-NeRF, o SDFormat ou uma nova arquitetura neural.

1.4 Organização do texto

O Capítulo 2 apresenta trabalhos relacionados em representação neural, reconstrução panóptica e geração de cenas para simulação. O Capítulo 3 descreve a cadeia adotada. O Capítulo 4 define as condições experimentais e as métricas. O Capítulo 5 apresenta os resultados obtidos. Os Capítulos 6 e 7 discutem esses resultados e delimitam seu alcance. O Capítulo 8 responde à questão de pesquisa no contexto da cena e do protocolo avaliados.

2 FUNDAMENTAÇÃO E TRABALHOS RELACIONADOS

2.1 Representações neurais de cenas e superfícies

O NeRF representa uma cena por uma função neural contínua que associa posição espacial e direção de observação a densidade volumétrica e cor [5]. A renderização volumétrica permite sintetizar imagens em pontos de vista que não foram apresentados durante o treinamento. O método, entretanto, foi formulado para síntese de vistas, e não como uma descrição explícita de objetos e colisões.

NeuS [10] e VolSDF [13] aproximam a representação implícita da reconstrução de superfícies. Esses trabalhos são relevantes para esta dissertação porque evidenciam que qualidade de imagem e qualidade geométrica precisam ser tratadas como dimensões distintas. Uma representação capaz de sintetizar novas vistas pode conter geometria insuficiente para uso em simulação, e uma superfície extraída pode depender de decisões de amostragem, domínio e limiar.

No campo da robótica, iMAP [8] e NICE-SLAM [14] exploram representações implícitas em problemas de mapeamento e localização. Esses sistemas têm objetivos diferentes do presente trabalho, mas mostram a aproximação entre representações neurais e tarefas robóticas. Para simulação, contudo, a existência de uma representação contínua não elimina a necessidade de entidades explícitas e organizadas.

2.2 Estrutura de objetos e reconstrução panóptica

Panoptic Neural Fields [3] incorpora estrutura de objetos e fundo a campos neurais e utiliza predições auxiliares para obter informação panóptica. A individualização permanece no domínio da representação neural. O trabalho não tem como saída principal um conjunto de malhas de colisão ou um mundo de simulador.

Panoptic Lifting [7] parte de imagens, poses e segmentações panópticas 2D e trata inconsistências de identificadores entre vistas para formar uma representação tridimensional coerente. Seu objetivo principal é compreensão panóptica e síntese de vistas. PanoRecon [11], por sua vez, combina reconstrução monocular em tempo real com geometria, semântica e instâncias persistentes. O regime de entrada e o protocolo de treinamento diferem

do DM-NeRF, o que impede uma comparação quantitativa direta dos valores publicados.

Como referência geométrica externa, o COLMAP fornece uma cadeia clássica de reconstrução multivista densa. O componente *Multi-View Stereo* (MVS) estima a superfície a partir da correspondência de pontos observados em várias imagens; no COLMAP, ele combina estimativa de profundidade e normais, seleção de vistas e consistência geométrica antes da fusão dos mapas de profundidade [6]. Nesta dissertação, ele é usado somente como baseline de geometria: as poses do DM-SR são fornecidas diretamente e não há estimação de pose, segmentação de instâncias ou geração de entidades de simulador.

O DM-NeRF [9] é o componente neural adotado nesta dissertação. No DM-SR, o método é treinado por cena com RGB, poses e mapas 2D de instância. A representação permite decomposição e manipulação no campo neural. O presente trabalho não modifica esse estágio; investiga a materialização posterior da geometria e das instâncias para uso em simulação.

2.3 Geração de ambientes para simulação

URDFormer [2] parte de uma imagem e produz uma descrição articulada em *Unified Robot Description Format* (URDF), formato usado para representar elos e juntas de sistemas robóticos, inferindo partes, relações e juntas e recorrendo a ativos previamente disponíveis. Essa abordagem favorece estrutura cinemática, mas não equivale à reconstrução multivista da superfície observada.

DRAWER [12] produz ambientes interativos a partir de vídeo e combina representação geométrica implícita, aparência e articulações. O método aproxima a reconstrução de uma cadeia *real-to-sim*, mas utiliza componentes, entradas e objetivos diferentes dos adotados aqui. GRS [15] constrói tarefas de simulação a partir de observações reais e recuperação de ativos. Sua saída é um análogo funcional composto por ativos, e não a superfície diretamente reconstruída da cena.

A publicação anterior do autor [4] também tratou a descrição e reconstrução de ambientes com segmentação panóptica. Os resultados desse trabalho são utilizados apenas como contexto histórico; não são incorporados como resultado da reprodução atual.

2.4 Contexto quantitativo publicado

As métricas publicadas por métodos panópticos posteriores ajudam a situar a evolução da área, mas não devem ser comparadas diretamente aos resultados DM-SR desta dissertação. A Tabela 1 reúne valores de PQ_{scene} reportados por Bhalgat et al. [1] em ScanNet, Replica e HyperSim, utilizando o protocolo de Panoptic Lifting. Nesse protocolo, PQ_{scene} sintetiza a qualidade panóptica da cena, e valores maiores indicam melhor resultado. Os

números mostram que a posição relativa dos métodos depende do dataset. Como a cena *study* usa outro conjunto de dados e outra métrica principal de decomposição, os valores da tabela servem apenas como contexto quantitativo e não são diretamente comparáveis aos resultados do DM-SR.

Tabela 1: PQ_{scene} publicado em benchmarks panópticos. Valores compilados por Bhalgat et al. [1]; não são diretamente comparáveis ao DM-SR desta dissertação.

Método	**ScanNet**	**Replica**	**HyperSim**
DM-NeRF	41,7	44,1	51,6
Panoptic Neural Fields	48,3	41,1	44,8
Panoptic Lifting	58,9	57,9	60,1
Contrastive Lift	62,3	59,1	62,3

2.5 Comparação por características

A Tabela 2 resume diferenças relevantes entre os métodos. Ela não é uma tabela de desempenho: datasets, entradas, supervisão e protocolos não são equivalentes.

Tabela 2: Comparação qualitativa entre trabalhos relacionados e a cadeia desta dissertação.

Método	**Entrada principal**	**Saída e estrutura**	**Simulação**
Panoptic Neural Fields	imagens e predições 2D	campos neurais orientados a objetos; edição no campo	não é a saída principal
Panoptic Lifting	RGB, poses e máscaras panópticas	campo neural panóptico 3D	não
PanoRecon	vídeo monocular	reconstrução online com instâncias	não como objetivo principal
DM-NeRF	RGB, poses e mapas 2D de instância	campo neural com decomposição; malha por extração	não diretamente
COLMAP	RGB e poses fixas	nuvem densa por MVS; sem instâncias	não
URDFormer	imagem RGB	hierarquia URDF e ativos predefinidos	sim
DRAWER	vídeo	ambiente interativo com geometria e articulações	sim
GRS	RGB-D	segmentação, recuperação de ativos e tarefas	sim
Este trabalho	RGB, poses e mapas 2D de instância	DM-NeRF, malha, IDs, objetos separados e SDFormat	Gazebo Classic

A comparação mostra que os trabalhos cobrem pontos diferentes entre aparência, reconstrução, compreensão de cena e geração de conteúdo para simulação. A cadeia desta dissertação é mais restrita que métodos que inferem articulações ou recuperam ativos: mantém a geometria do DM-NeRF como ponto de partida e avalia como essa geometria pode ser estruturada e integrada ao simulador. Essa restrição também delimita as conclusões: não se pretende recuperar propriedades físicas, articulações ou semântica completa dos objetos.

3 METODOLOGIA

3.1 Visão geral

O estudo é organizado como uma cadeia de reconstrução e estruturação. O estágio neural é executado com DM-NeRF sobre DM-SR. A partir do modelo treinado, são produzidas métricas de teste e uma malha triangular com identificadores de instância por vértice. O pós-processamento transforma essa saída em objetos independentes, seleciona um candidato geométrico a piso, regulariza essa superfície quando a seleção é válida e exporta uma cena em SDFormat.

As etapas e suas evidências são apresentadas na Tabela 3. A organização evita atribuir a uma etapa uma métrica que ela não pode alterar. A separação estrutural A1, por exemplo, não modifica intencionalmente as coordenadas das faces preservadas e, portanto, não é avaliada por PSNR ou por ganho de distância de superfície.

Tabela 3: Etapas da cadeia e evidências utilizadas.

Etapa	**Transformação**	**Evidência principal**
Neural	treinamento e avaliação do DM-NeRF	PSNR, SSIM, LPIPS e AP em vistas de teste
A0	extração da malha	distâncias de superfície, Precision, Completeness e F-score
A1	separação por IDs explícitos	número de instâncias, cobertura de faces e fronteiras
A2	regularização do candidato a piso	resíduos ao plano antes/depois
Gazebo	exportação e execução	validações G0–G3

3.2 Conjunto de dados DM-SR

O conjunto DM-SR fornece imagens RGB, poses de câmera, mapas bidimensionais de instância e uma malha tridimensional de referência. Para a cena *study*, o pacote utilizado no experimento contém 300 imagens de treinamento e 100 vistas de teste no protocolo original. Um pacote de referência separado foi gerado diretamente do arquivo oficial e

validado por SHA-256. Esse pacote inclui a malha de referência, os metadados de câmera e quatro vistas RGB de teste utilizadas apenas para figuras qualitativas.

Quatro vistas reais da cena, extraídas do conjunto de teste, são apresentadas posteriormente junto às renderizações correspondentes do DM-NeRF (Figura 1). Essa comparação introduz visualmente a configuração doméstica/escritório e evita repetir as mesmas imagens em figuras distintas.

A malha de referência tem 437.008 vértices e 844.701 faces. O procedimento oficial de extração de malha do DM-NeRF utiliza o *oriented bounding box* dessa referência para definir o volume e a orientação da consulta ao campo neural. Dessa forma, a referência participa da definição do domínio de extração. Esse ponto é mantido como limitação ao interpretar as métricas geométricas posteriores.

Os mapas de instância do DM-SR utilizam identificadores inteiros, mas os artefatos inspecionados não fornecem um catálogo semântico completo que associe cada ID a uma classe do ambiente. Em particular, não foi encontrada uma associação oficial e rastreável para a classe piso.

3.3 Treinamento e avaliação do DM-NeRF

A reprodução utiliza a implementação oficial do DM-NeRF fixada no commit registrado pelo experimento e um executor que preserva a identidade da execução, os arquivos de configuração e os estados necessários à retomada. A configuração final usa 64 amostras no passe inicial, 128 amostras adicionais, 3.072 raios no treinamento e 1.024 raios no avaliador. O treinamento foi realizado com precisão mista automática; a avaliação final e o meshing foram mantidos em FP32.

O avaliador oficial calcula PSNR, SSIM e LPIPS para síntese de vistas. Para decomposição, a interseção sobre união (IoU) mede a sobreposição entre uma máscara predita e sua referência, e a precisão média (AP) resume a qualidade das detecções em um limiar de IoU; valores maiores indicam melhor correspondência. São usados os limiares de IoU 0,50, 0,75, 0,80, 0,85, 0,90 e 0,95. A função de perda e as métricas emitidas durante o treinamento não são utilizadas como resultados de teste.

3.4 Extração da malha e contrato de rótulos

Após o treinamento, o campo neural é consultado no volume definido pelo procedimento oficial e convertido em malha triangular. A saída utilizada em A0 é o arquivo `mesh_geometry.ply`. A visualização `mesh_instances.ply` contém cores por instância, mas essas cores são usadas somente para apresentação. A identidade estrutural é obtida do arquivo `instance_labels.npz`, que armazena os vértices, triângulos e o vetor `vertex_instance_id`.

Antes de separar objetos, o contrato verifica a quantidade e a ordem dos vértices, os índices dos triângulos, a topologia e a finitude das coordenadas. Essa verificação impede a associação de IDs a uma malha com ordem de vértices diferente. A malha final auditada contém 356.272 vértices e 710.928 faces.

3.5 Separação estrutural A1

A condição A1 é formada a partir de A0. Para cada triângulo, são consultados os IDs de seus três vértices. Uma face é atribuída a uma instância somente quando os três IDs coincidem. Faces com IDs diferentes são classificadas como faces de fronteira e permanecem fora das malhas individuais. A decisão evita escolher arbitrariamente um dos rótulos presentes na face.

Para cada instância com faces homogêneas, os vértices utilizados são remapeados e uma malha independente é exportada. O manifesto registra ID, número de vértices, número de faces, área, limites espaciais e centroide. A cobertura de faces homogêneas e a quantidade de fronteiras são calculadas sobre a topologia original.

3.6 Seleção geométrica do piso

Como não há rótulo semântico oficial para o piso, a etapa de seleção é declarada como heurística geométrica. A regra foi definida antes da observação da malha final. Cada instância é analisada somente pelas faces homogêneas. O plano principal é obtido por covariância dos vértices dessas faces com ponderação pela área dos triângulos. São calculados área, fração de área aproximadamente horizontal, normal, altura e RMSE do ajuste.

Uma instância é elegível quando satisfaz simultaneamente: área de pelo menos 0,5 m^2; pelo menos 85% da área com orientação de até 15 graus da vertical; normal do plano dentro do mesmo limite angular; RMSE de no máximo 0,03 m; e posição na faixa inferior da cena, definida pelo percentil 1 das alturas acrescido de 20% da amplitude vertical. O eixo vertical da malha é +Y.

Entre candidatas elegíveis, a maior área é escolhida se a segunda candidata tiver área inferior a 80% da primeira. Caso contrário, a saída é ambígua. Se nenhuma instância for elegível, a saída é “não identificada”. Em ambos os casos de abstenção, A2 é bloqueada. A regra não utiliza cor, número de ID ou associação histórica como critério semântico.

3.7 Regularização A2

Quando existe candidato válido, os vértices associados ao ID selecionado são usados no algoritmo *Random Sample Consensus* (RANSAC), que ajusta um modelo robusto mesmo na presença de pontos discrepantes, com limiar de 2 cm e semente fixa. O plano

final é ajustado aos inliers. A regularização projeta apenas os vértices da instância selecionada sobre esse plano. A topologia e os IDs não são alterados.

O efeito é medido sobre o mesmo subconjunto antes e depois da projeção. São reportados erro absoluto médio, RMSE, P95 e fração de inliers. Uma redução desses resíduos indica apenas maior aderência ao plano estimado. Como a operação é uma projeção, a redução é esperada por construção e não demonstra aumento de fidelidade global em relação ao ambiente real.

3.8 Exportação para Gazebo Classic

A exportação gera mundos SDFormat com referências relativas. A0 é representada por uma malha única. A1 e A2 são representadas por modelos independentes derivados das instâncias. Cada modelo possui um link, um elemento visual e um elemento de colisão apontando para a mesma malha triangular. O referencial +Y da reconstrução é rotacionado para +Z do Gazebo por uma transformação rígida comum.

A validação G0 verifica XML, nomes únicos, existência das malhas, caminhos relativos, escalas positivas e correspondência entre visual e colisão. Essa etapa não executa a física e não substitui o parser nativo do Gazebo. G1, G2 e G3 verificam, respectivamente, carregamento real, manipulação independente e suporte/colisão do piso.

4 PROTOCOLO EXPERIMENTAL

4.1 Unidade experimental e proveniência

A cena *study* é a unidade experimental principal. O experimento final parte de uma única sequência de treinamento, retomada em três sessões, e mantém a mesma identidade nos artefatos derivados. Ensaios preliminares de desempenho e infraestrutura não são misturados aos resultados finais.

O treinamento oficial utilizado foi concluído em 200.000 iterações. A identidade do upstream DM-NeRF e do executor, a configuração, o ambiente e os arquivos produzidos são preservados em arquivos de estado e manifestos. O bundle final foi auditado antes do uso dos resultados nesta versão. A auditoria confirmou a presença e a consistência de `training_state.json`, `identity.json`, `stages.jsonl`, `metrics.csv`, `test_results.txt`, das 100 renderizações de teste e dos artefatos de meshing.

4.2 Condições A0, A1 e A2

As três condições são derivadas da mesma reconstrução:

- **A0**: malha extraída do campo neural, antes do pós-processamento geométrico;
- **A1**: A0 separada em objetos por IDs explícitos de instância; e
- **A2**: A1 com projeção dos vértices do candidato a piso sobre o plano estimado.

A0 é avaliada por métricas de superfície. A1 é avaliada por cobertura da separação e quantidade de objetos; as coordenadas das faces preservadas não são modificadas. A2 é avaliada por métricas pareadas do piso e por suporte e colisão no simulador.

4.3 Síntese de vistas e decomposição

As métricas de síntese são PSNR, SSIM e LPIPS. Para PSNR e SSIM, valores maiores indicam maior semelhança com a imagem de referência; para LPIPS, valores menores indicam maior semelhança perceptual. A decomposição utiliza AP50, AP75, AP80, AP85,

AP90 e AP95. O sufixo indica o limiar de IoU exigido: quanto maior o limiar, mais precisa deve ser a sobreposição das máscaras; em todos os casos, AP maior é melhor. A linha média do arquivo oficial de resultados é utilizada diretamente. O arquivo derivado `metrics.csv` foi comparado com `test_results.txt` e os valores coincidem até a precisão registrada.

4.4 Avaliação geométrica

A0 e a malha de referência são amostradas com 200.000 pontos de superfície, semente 42. Para cada conjunto, calcula-se a distância ao vizinho mais próximo do conjunto oposto. As métricas incluem distância média em cada direção, soma das duas médias como distância simétrica L1, RMSE em cada direção e Precision, Completeness e F-score nos limiares de 1, 2 e 5 cm.

Para um limiar t, Precision é a fração dos pontos previstos a no máximo t da referência. Completeness é a fração dos pontos da referência a no máximo t da previsão. O F-score é a média harmônica dessas duas frações.

A interpretação considera a dependência do bounding frame da referência no meshing oficial. Portanto, as métricas descrevem a saída dentro do protocolo reproduzido; não são apresentadas como uma avaliação cujo volume de extração foi obtido independentemente do *ground truth*.

4.5 Baseline geométrico externo

Como referência externa foi executado o MVS denso do COLMAP [6] com as 300 imagens de treinamento da cena *study*. As poses e os intrínsecos oficiais do DM-SR foram fornecidos diretamente ao COLMAP; portanto, o baseline avalia a reconstrução densa e não a estimação de pose. Para cada imagem de referência foram selecionadas as dez câmeras mais próximas em posição. O PatchMatch utilizou consistência geométrica, intervalo de profundidade de 4 a 15 m e a fusão foi executada com `min_num_pixels=1`. Não foi realizada busca de hiperparâmetros.

A saída do COLMAP permanece no sistema de coordenadas das poses do DM-SR, enquanto o gerador de malha do DM-NeRF consulta a rede após a permutação de eixos $[x, y, z]_{rede} = [x, -z, y]_{cena}$. Antes da comparação, a nuvem COLMAP é portanto convertida de volta para o sistema da malha por $[x, y, z]_{cena} = [x, z, -y]_{COLMAP}$.

Há ainda uma diferença de suporte: o meshing oficial do DM-NeRF restringe a consulta a uma caixa orientada definida a partir da referência, com extensões fixas de $1,9 \times 7,0 \times 7,0$ m. Para não penalizar apenas o COLMAP por reconstruir pontos fora desse volume, a avaliação principal do baseline é limitada ao mesmo suporte orientado. Dos 5.800.316 pontos fundidos, 3.416.962 (58,91%) permanecem dentro desse volume.

Em seguida, 200.000 pontos são amostrados com semente 42, igualando a cardinalidade usada na avaliação de A0. As métricas são então calculadas pelas mesmas definições de distância, Precision, Completeness e F-score.

Os números produzidos diretamente pelo notebook antes dessa conversão de coordenadas e da equalização de suporte não são usados na análise comparativa, pois misturam convenções de referência distintas.

4.6 Avaliação da separação e do piso

Em A1 são registrados o número de instâncias, faces homogêneas, faces de fronteira e cobertura. As faces de fronteira permanecem contabilizadas mesmo quando são omitidas das malhas individuais.

Para o piso, o relatório de seleção registra todos os candidatos e motivos de rejeição. A regularização usa limiar RANSAC de 2 cm, 2.000 iterações e semente 42. O P95 é mantido como medida principal, acompanhado de média absoluta, RMSE e fração de inliers.

4.7 Validação funcional

A validação funcional é dividida em etapas de validação:

G0 validação estática do arquivo SDFormat e de suas referências;

G1 carregamento do mundo no Gazebo Classic sem erro fatal associado aos modelos;

G2 transformação independente de pelo menos uma instância em A1/A2;

G3 verificação pontual de apoio e colisão da superfície regularizada em A2.

G0 não é interpretado como evidência de comportamento físico. G1–G3 acrescentam, de forma progressiva, evidência de carregamento, independência estrutural e contato no ponto ensaiado.

4.8 Custo computacional

São reportados tempo de treinamento, atualizações efetivas, atualizações puladas pelo AMP, pico de memória alocada pelo PyTorch, pico observado pela telemetria, tempo de avaliação e tempo de extração da malha. O uso de GPU gratuita é uma condição de reprodução, não uma métrica de qualidade.

5 RESULTADOS

5.1 Treinamento e custo computacional

O treinamento foi concluído em três sessões, totalizando aproximadamente 30 h 58 min. O estado final registra 200.000 iterações, 199.916 atualizações efetivamente aplicadas pelo otimizador e 85 atualizações puladas pelo escalonador de AMP. Isso corresponde a aproximadamente 0,0425% das tentativas de atualização.

O pico de memória alocada pelo PyTorch foi de aproximadamente 5,58 GiB e o pico observado pela telemetria do dispositivo foi 7.417 MiB. A avaliação oficial levou 2.568,48 s (42,8 min) e a extração da malha levou 109,13 s (1,82 min). A Tabela 4 reúne esses valores.

Tabela 4: Resumo da execução final.

Medida	**Valor**
Iteração final	200.000
Atualizações efetivas	199.916
Atualizações puladas por AMP	85
Tempo de treinamento	30 h 58 min
Pico PyTorch	5,58 GiB
Pico da telemetria	7.417 MiB
Tempo de avaliação	2.568,48 s
Tempo de meshing	109,13 s

5.2 Síntese de vistas

A Tabela 5 apresenta as médias do avaliador oficial sobre 100 vistas de teste. PSNR e SSIM aumentam com a semelhança à referência, enquanto LPIPS diminui quando a distância perceptual é menor. Esses valores foram conferidos no bundle final; a linha média de `test_results.txt` coincide com o `metrics.csv` derivado. Eles caracterizam aparência nas vistas de teste, mas não medem precisão da superfície tridimensional.

Tabela 5: Métricas do avaliador oficial na cena *study*.

PSNR	SSIM	LPIPS	AP50	AP75	AP80	AP85	AP90	AP95
41,1100	0,9875	0,0260	0,9956	0,9911	0,9849	0,9769	0,9311	0,7192

5.2.1 Comparação com os resultados publicados do DM-NeRF

A reprodução pode ser comparada diretamente aos valores publicados por Wang et al. [9] para a mesma cena *study* do DM-SR. Essa comparação é distinta de um novo baseline: seu objetivo é verificar se o estágio neural reproduz o comportamento reportado pelo método de origem antes de analisar as transformações propostas nesta dissertação. A Tabela 6 apresenta os valores.

Tabela 6: Comparação entre a reprodução desta dissertação e os resultados publicados para a cena *study* do DM-SR.

Fonte	**PSNR (dB)**	**SSIM**	**LPIPS**	**AP$_{0,75}$ (%)**
Wang et al. (2023)	41,08	0,987	0,026	98,86
Esta reprodução	41,110	0,9875	0,0260	99,11

As diferenças são de 0,03 dB em PSNR, 0,0005 em SSIM, aproximadamente zero em LPIPS na precisão reportada e 0,25 ponto percentual em AP$_{0,75}$. Com uma única cena, esses desvios não sustentam uma análise de significância estatística; eles mostram apenas que a execução reproduz de forma próxima os valores publicados para *study*.

O mesmo artigo reporta, para a cena *study*, AP$_{0,75}$ de 96,86% para Mask R-CNN e 97,88% para Swin Transformer, ambos ajustados por cena, contra 98,86% do DM-NeRF publicado. A reprodução desta dissertação obteve 99,11%. Em relação aos valores publicados dos dois baselines 2D, a diferença é de 2,25 e 1,23 pontos percentuais, respectivamente. Esses números são usados como referência de literatura e não como reexecução independente dos baselines.

A Figura 1 mostra quatro pares de referência e renderização. A composição usa exatamente as vistas 0, 33, 66 e 99 presentes no pacote de referência e os arquivos correspondentes do avaliador. Nas quatro vistas, a disposição dos objetos e as principais regiões de aparência são mantidas. Diferenças locais são mais perceptíveis em contornos finos e detalhes pequenos do mobiliário.

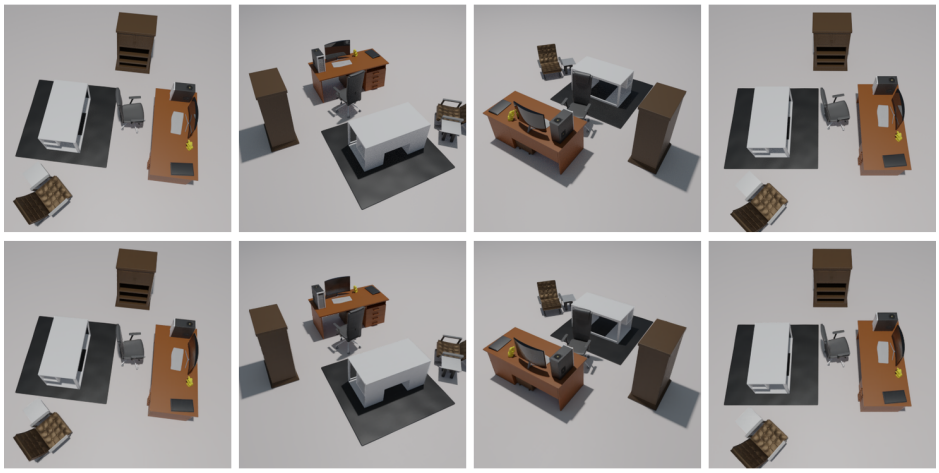


Figura 1: Comparação entre imagens de referência e renderizações finais. Linha superior: referência; linha inferior: DM-NeRF. Da esquerda para a direita, vistas 0, 33, 66 e 99.

5.3 Decomposição de instâncias

Os APs, para os quais valores maiores indicam melhor detecção e correspondência das máscaras, permanecem próximos de 1,0 nos limiares de IoU menos restritivos e diminuem quando a coincidência exigida se aproxima de 0,95. O AP50 é 0,9956, enquanto o AP95 é 0,7192. Esse comportamento indica que a correspondência geral das instâncias é mantida na maior parte das vistas, mas diferenças de contorno e pequenas regiões passam a afetar a métrica no limiar mais estrito. Como o protocolo fornece máscaras 2D durante o treinamento, os valores não demonstram descoberta de instâncias sem supervisão.

A Figura 2 compara mapas de instância de referência e predição em quatro vistas. A figura não substitui os APs, mas permite observar que a diferença entre as máscaras se concentra em regiões pequenas e fronteiras de objetos.

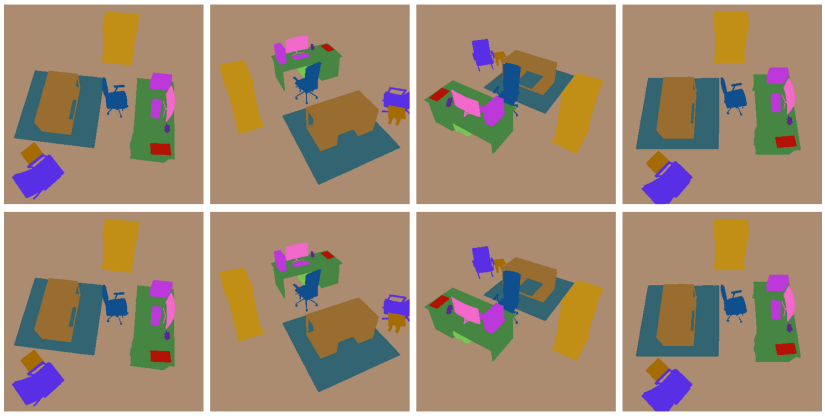


Figura 2: Mapas de instância. Linha superior: referência; linha inferior: predição. Da esquerda para a direita, vistas 0, 33, 66 e 99. As cores identificam IDs do protocolo e não classes semânticas.

5.4 Geometria A0

A malha A0 final contém 356.272 vértices e 710.928 faces. Sua evidência qualitativa é apresentada junto à referência DM-SR e ao COLMAP na Figura 3, evitando repetir o mesmo enquadramento em uma figura isolada. A estrutura global da sala e dos objetos principais é reconhecível, mas a visualização também mostra regiões ruidosas e superfícies que não formam volumes fechados.

A Tabela 7 apresenta as distâncias médias e RMSE. As duas direções têm valores próximos: 4,34 cm da predição para a referência e 4,14 cm da referência para a predição.

Tabela 7: Distâncias entre A0 e a referência DM-SR.

Medida	**Valor**
Média predição → referência	4,335 cm
Média referência → predição	4,139 cm
Distância simétrica L1	8,474 cm
RMSE predição → referência	5,757 cm
RMSE referência → predição	4,940 cm

Os resultados por limiar são apresentados na Tabela 8. Precision mede a fração da reconstrução situada perto da referência; Completeness mede a fração da referência coberta pela reconstrução; e o F-score combina as duas medidas. Valores maiores são melhores. A 1 cm, somente cerca de 5% dos pontos em cada direção encontram correspondência dentro do limiar. A 5 cm, Precision e Completeness passam de 0,75 e o F-score chega a 0,7750. Assim, a reconstrução representa melhor a estrutura quando se admite tolerância de 5 cm, sem sustentar coincidência fina em 1 cm.

Tabela 8: Precision, Completeness e F-score da geometria A0.

Limiar	**Precision**	**Completeness**	**F-score**
1 cm	0,04887	0,04724	0,04804
2 cm	0,20977	0,18398	0,19603
5 cm	0,79630	0,75478	0,77498

5.5 Baseline geométrico externo: COLMAP

O baseline COLMAP concluiu o PatchMatch e a fusão densa para as 300 vistas de treinamento, produzindo 5.800.316 pontos. Após a conversão para o sistema de coordenadas da malha e a restrição ao mesmo volume orientado empregado pelo meshing do DM-NeRF, 3.416.962 pontos permaneceram no suporte comum. A comparação usa

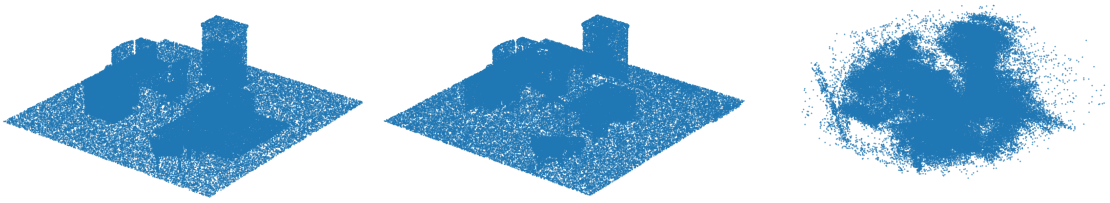
uma amostra determinística de 200.000 pontos dessa nuvem, de modo a manter a mesma cardinalidade de A0 e da referência.

A Tabela 9 compara as duas reconstruções. A0 apresenta menor erro nas duas direções. A distância média da predição para a referência é 4,34 cm em A0 e 20,42 cm no COLMAP; no sentido referência para predição, os valores são 4,14 cm e 8,13 cm. A diferença entre as direções no COLMAP indica que parte relevante da superfície de referência possui pontos próximos, mas a nuvem contém espessamento e pontos afastados da superfície correta.

Tabela 9: Comparação geométrica entre A0 e o baseline COLMAP no mesmo suporte e com 200.000 pontos por conjunto.

Medida	**DM-NeRF A0**	**COLMAP**
Média predição → referência	4,335 cm	20,418 cm
Média referência → predição	4,139 cm	8,129 cm
Distância simétrica L1	8,474 cm	28,547 cm
RMSE predição → referência	5,757 cm	30,079 cm
RMSE referência → predição	4,940 cm	13,942 cm
F-score a 1 cm	0,0480	0,0285
F-score a 2 cm	0,1960	0,1288
F-score a 5 cm	0,7750	0,3721

A decomposição de Precision e Completeness ajuda a interpretar a diferença a 5 cm: A0 obtém 0,7963 e 0,7548, respectivamente, enquanto o COLMAP obtém 0,2710 e 0,5936. Assim, o baseline recupera regiões próximas de grande parte da referência, mas com proporção maior de pontos fora da tolerância. A Figura 3 mostra a referência, A0 e COLMAP no mesmo enquadramento, e a Figura 4 resume os F-scores.



(a) Referência DM-SR (b) DM-NeRF A0 (c) COLMAP

Figura 3: Comparação qualitativa da geometria no mesmo sistema de coordenadas, suporte e enquadramento. A nuvem COLMAP apresenta maior dispersão e superfícies mais espessas.

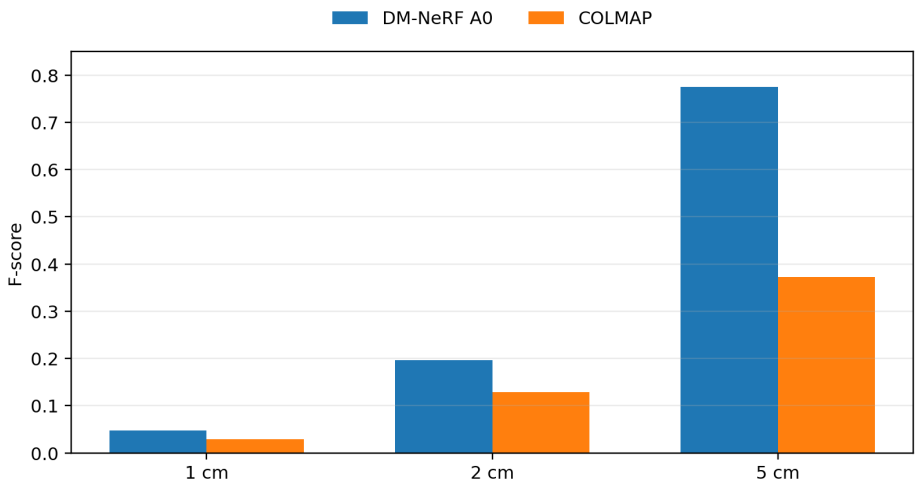


Figura 4: F-score geométrico de A0 e COLMAP nos limiares de 1, 2 e 5 cm.

5.6 Separação estrutural A1

A separação identificou 13 instâncias com faces homogêneas. Das 710.928 faces da malha original, 681.383 foram atribuídas a uma instância, enquanto 29.545 foram registradas como faces de fronteira. A cobertura resultante é 95,844%; nesse indicador, valores maiores representam maior preservação da topologia nas malhas individuais. A cobertura não mede estanqueidade nem corrige erros geométricos da malha de origem.

Tabela 10: Resumo da separação A1.

Instâncias exportadas	13
Faces da malha A0	710.928
Faces homogêneas exportadas	681.383
Faces de fronteira	29.545
Cobertura de faces homogêneas	95,844%

A Figura 5 utiliza as cores armazenadas em `mesh_instances.ply` apenas para distinguir visualmente as instâncias. A identidade empregada no processamento vem do vetor de IDs, não da cor.



Figura 5: Visualização da reconstrução colorida por instância em dois pontos de vista. As cores são usadas somente para distinguir IDs.

A individualização também foi verificada nos arquivos exportados por instância. Fragmentos e fronteiras permanecem visíveis em alguns objetos, razão pela qual a evidência visual principal de A1 é apresentada na cena completa colorida por ID e, posteriormente, no Gazebo com cada entidade carregada separadamente.

5.7 Seleção e regularização do piso

A heurística geométrica selecionou a instância 10. Ela foi a única instância a satisfazer simultaneamente os critérios de área, orientação, planaridade e altura. A instância 9 também apresenta grande fração horizontal e baixa altura, mas seu RMSE de 3,23 cm excede o limite de 3 cm definido antes da execução final. A seleção identifica um candidato geométrico e não constitui rótulo semântico de piso fornecido pelo DM-SR.

No RANSAC aplicado à instância selecionada, 77,11% dos vértices ficaram a até 2 cm do plano estimado. Antes da projeção, a distância absoluta média era 2,051 cm, o RMSE era 5,722 cm e o P95 era 6,800 cm. O maior residual chegou a 1,64 m, indicando a presença de vértices associados ao mesmo ID afastados do plano principal. Esse valor não foi removido da análise.

A projeção de A2 leva os vértices selecionados ao plano, reduzindo média, RMSE e P95 a erro numérico. Esse resultado é consequência direta da operação e deve ser interpretado como alteração de planaridade, não como evidência de que a reconstrução inteira se tornou geometricamente mais fiel.

Tabela 11: Métricas da instância 10 antes e depois da regularização.

Medida	**A1**	**A2**
Média absoluta	2,051 cm	$< 10^{-12}$ cm
RMSE	5,722 cm	$< 10^{-12}$ cm
P95	6,800 cm	$< 10^{-12}$ cm
Fração de inliers (2 cm)	77,11%	100%

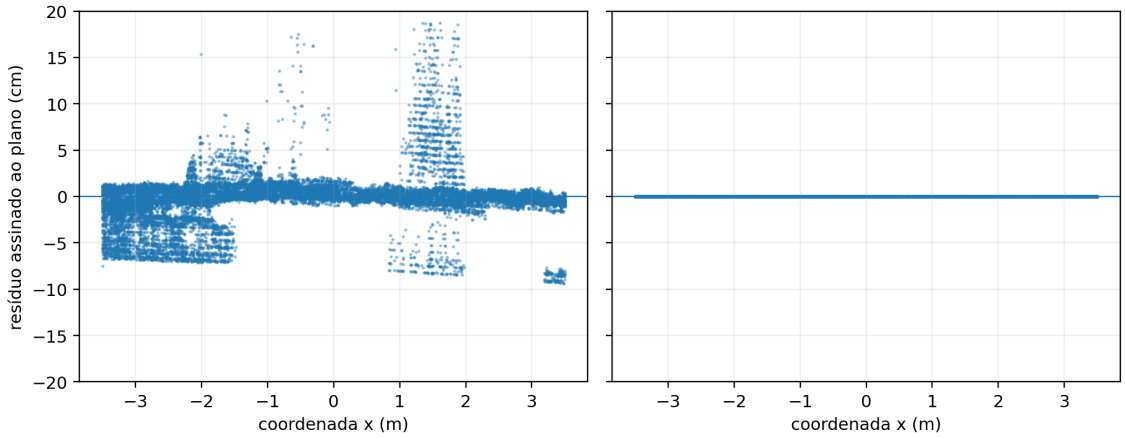


Figura 6: Resíduo assinado ao plano da instância 10 antes e depois da regularização. À esquerda, A1; à direita, A2. O eixo vertical é limitado a ± 20 cm para leitura da distribuição principal; o residual máximo de A1, 1,64 m, permanece reportado no texto e nas métricas.

5.8 Integração no Gazebo Classic

A validação G0 passou para as três condições. A0 gerou um modelo correspondente à malha completa; A1 e A2 geraram 13 modelos independentes, com caminhos relativos para os arquivos de malha e correspondência entre os elementos visuais e de colisão.

Os testes de execução foram realizados no Gazebo Classic 11.10.2. Em G1, os mundos A0, A1 e A2 foram carregados pelo `gzserver` e permaneceram ativos durante a janela de verificação. Os logs registraram avisos de ausência de material nos arquivos OBJ, mas não erros fatais de carregamento. Esses avisos afetam a aparência visual padrão e não a presença das geometrias usadas nos testes.

Em G2, a instância `instance_006` da condição A1 foi deslocada em 0,25 m no eixo x por meio da interface do Gazebo. A pose consultada antes da operação era $(0, 0, 0)$ m e, após o comando, a coordenada x passou para 0,25 m. A operação foi dirigida somente a esse modelo, demonstrando que a separação de A1 foi materializada em entidades endereçáveis de forma independente no simulador.

O teste G3 utilizou uma caixa dinâmica de 10 cm de lado e massa de 0,2 kg, posicionada no arquivo de mundo com centro em $z = 0,65$ m sobre uma região do candidato a piso regularizado. O script de coleta espera seis segundos após iniciar o servidor antes da primeira consulta; por isso, o campo denominado "inicial" no arquivo de poses já corresponde ao estado após a queda. Nessa primeira consulta, o centro da caixa estava em $z = 0,093811$ m. Após mais oito segundos, estava em $z = 0,093806$ m, variação de aproximadamente 5 μm.

Considerando metade da altura da caixa, sua face inferior permaneceu em $z = 0,043806$ m. A altura calculada do plano regularizado no ponto $(x, y) = (3,07411, -3,31338)$ m, após a rotação comum de +Y para +Z usada na exportação, é $z = 0,043810$ m. A diferença de aproximadamente 4 μm expressa apenas a concordância numérica entre a pose registrada da face inferior da caixa e a altura calculada do plano no mesmo ponto; não representa uma medida de precisão física micrométrica do Gazebo. A observação funcional permitida é que a caixa caiu aproximadamente 0,56 m, encontrou a superfície, não a atravessou no ponto ensaiado e permaneceu estável durante a segunda janela de observação. O G3 é, portanto, classificado como aprovado. A classificação automática original como "inconclusivo" decorreu do fato de o script comparar duas poses já posteriores ao assentamento.

Tabela 12: Resultado das verificações de integração com o Gazebo Classic.

Verificação	**A0**	**A1**	**A2**
G0 – validação estática	passou	passou	passou
G1 – carregamento no Gazebo	passou	passou	passou
G2 – manipulação independente	–	passou	–
G3 – apoio/colisão do piso	–	–	passou

Para tornar a individualização visualmente verificável, a mesma cena A2 foi aberta com materiais de visualização distintos por instância. Essa alteração não modifica poses, geometrias de colisão nem os resultados G1–G3. A Figura 7 mostra as entidades separadas no runtime; a caixa vermelha no canto superior esquerdo corresponde ao corpo dinâmico usado no ensaio G3.

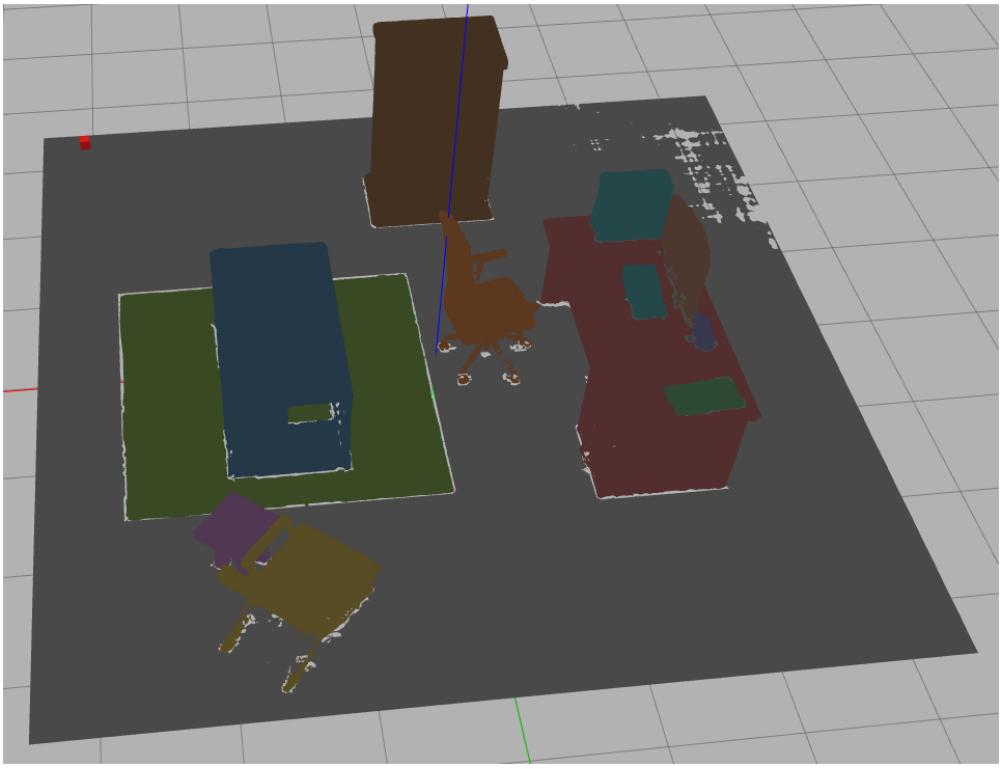


Figura 7: Cena A2 no Gazebo Classic com materiais visuais distintos por instância. As cores foram adicionadas somente para interpretação da figura; a geometria e as colisões são as mesmas usadas nos testes funcionais.

As malhas triangulares exportadas não são estanques e continuam inadequadas para inferências gerais sobre comportamento físico. O resultado de G3 demonstra contato no ponto ensaiado, não a ausência de falhas de colisão em toda a superfície.

6 DISCUSSÃO

Os resultados permitem separar com clareza o que foi demonstrado em cada estágio. No domínio de imagem, o DM-NeRF reproduz as vistas da cena *study* com PSNR de 41,11 dB, SSIM de 0,9875 e LPIPS de 0,0260. A comparação visual mostra preservação da disposição global e da aparência dos objetos nas vistas selecionadas. Essa constatação está restrita à cena e ao protocolo reproduzido; não é utilizada para ordenar o método em relação a trabalhos executados em outros datasets.

A comparação direta com a publicação original ajuda a separar reprodução de contribuição. Para a mesma cena *study*, Wang et al. [9] reportam PSNR de 41,08 dB, SSIM de 0,987, LPIPS de 0,026 e $AP_{0,75}$ de 98,86%. A reprodução desta dissertação obteve 41,110 dB, 0,9875, 0,0260 e 99,11%, respectivamente. No mesmo experimento publicado, Mask R-CNN e Swin Transformer atingiram $AP_{0,75}$ de 96,86% e 97,88%. Esses valores não são tratados como uma nova contribuição algorítmica do estágio neural; eles mostram que a reprodução ficou próxima do DM-NeRF publicado e fornecem um ponto de referência para as etapas geométricas que seguem.

A comparação externa com COLMAP acrescenta uma referência de geometria que não depende do mesmo campo neural. Depois de colocar as duas saídas no mesmo sistema de coordenadas, restringir a nuvem ao suporte empregado pelo meshing oficial e usar 200.000 pontos por conjunto, A0 apresentou F-score superior nos três limiares: 0,0480 contra 0,0285 a 1 cm, 0,1960 contra 0,1288 a 2 cm e 0,7750 contra 0,3721 a 5 cm. A diferença cresce no limiar de 5 cm principalmente pela baixa Precision do COLMAP (0,2710), enquanto sua Completeness chega a 0,5936. A visualização correspondente mostra que a nuvem clássica cobre parte importante da cena, mas contém dispersão e espessamento maiores.

Esse resultado não estabelece superioridade geral do DM-NeRF sobre COLMAP. O baseline foi executado em uma única cena, com poses fornecidas, dez vistas-fonte por referência, intervalo de profundidade fixo e sem busca de hiperparâmetros; além disso, a fusão com `min_num_pixels=1` prioriza recuperação e admite pontos fracamente suportados. A comparação é usada para caracterizar o comportamento geométrico sob um protocolo controlado, não para ranquear métodos de reconstrução de forma abrangente.

A decomposição de instâncias apresenta AP próximo de 1,0 em limiares menos restritivos e queda para 0,7192 em IoU 0,95. A observação dos mapas de instância é compatível com esse comportamento: as diferenças são pequenas em relação à área total dos objetos, mas aparecem em contornos e regiões estreitas. Como o DM-SR fornece mapas 2D de instância durante o treinamento, esses resultados avaliam a reprodução do protocolo supervisionado e não uma descoberta sem supervisão da estrutura da cena.

A avaliação geométrica apresenta um quadro diferente daquele sugerido apenas pelas métricas de imagem. A 1 cm, Precision e Completeness são inferiores a 0,05. A 2 cm, o F-score é 0,1960. A 5 cm, o F-score sobe para 0,7750. Isso mostra que a superfície captura uma parcela maior da estrutura quando se admite tolerância centimétrica mais ampla, mas não apresenta coincidência fina com a referência em grande parte da área. As distâncias médias em torno de 4 cm nas duas direções são coerentes com essa leitura.

Essa diferença entre imagem e geometria é uma das observações centrais do experimento. A síntese de vistas pode permanecer próxima das imagens de referência mesmo quando a superfície extraída apresenta deslocamentos superiores aos tolerados em uma aplicação que dependa de contato geométrico preciso. Para simulação, portanto, as métricas de renderização não substituem a avaliação da malha.

A condição A1 mostra que a informação de instância pode ser materializada em objetos independentes sem recorrer às cores da malha. A cobertura de 95,844% indica que a maior parte das faces tem rótulo homogêneo nos três vértices. Ao mesmo tempo, 29.545 faces de fronteira permanecem sem atribuição. Essa omissão é deliberada e evita resolver fronteiras por regra arbitrária, mas pode introduzir aberturas nas malhas individuais. O efeito dessas aberturas em colisão não pode ser concluído a partir de G0.

A seleção do piso ilustra outro limite entre estrutura de instâncias e semântica. A instância 10 passa pelos critérios geométricos, mas isso não a transforma em *ground truth* semântico. A escolha é sustentada por área, orientação, planaridade e altura. A presença de outra instância baixa e horizontal que falha por pequena margem no RMSE mostra por que o relatório de candidatos é necessário: o procedimento deve permanecer auditável e deve poder se abster em outras cenas.

A regularização A2 reduz os resíduos ao plano porque os vértices são projetados sobre o próprio plano estimado. Esse resultado não deve ser apresentado como ganho de reconstrução. A utilidade proposta é funcional: produzir uma superfície de apoio mais regular para a condição de simulação. A existência de outliers de até 1,64 m antes da projeção também recomenda cautela. O ID selecionado contém vértices que não pertencem à região dominante do plano, o que pode estar relacionado a erros de decomposição ou à própria forma como a instância foi reconstruída.

A validação funcional complementa essa análise. G1 mostrou que A0, A1 e A2 podem ser carregadas no Gazebo Classic 11.10.2 sem erro fatal associado aos modelos. Os avisos de material ausente nos arquivos OBJ alteram a aparência padrão, mas não impediram

o carregamento das geometrias. Em G2, uma instância de A1 foi endereçada e deslocada independentemente, confirmando que a separação não ficou restrita à organização de arquivos.

G3 forneceu uma verificação pontual de apoio e colisão em A2. A caixa de 10 cm definida no mundo caiu de $z = 0,65$ m e, após o assentamento, permaneceu com o centro em aproximadamente $z = 0,09381$ m. A pose registrada de sua face inferior e a altura calculada do plano no mesmo ponto diferem em aproximadamente 4 μm; essa diferença é apenas uma concordância numérica entre duas grandezas calculadas, não uma medida de precisão física do Gazebo. O teste mostra que a caixa caiu, encontrou a superfície, não a atravessou naquele ponto e permaneceu estável na segunda janela de observação. Não demonstra que toda a malha tenha colisão adequada: as geometrias individuais não são estanques e uma única posição não cobre a superfície completa.

Com G1–G3, a cadeia foi observada até o runtime do simulador no caso estudado. A resposta à questão de pesquisa deixa, portanto, de depender apenas de validade estrutural do SDFormat. Para a cena *study*, a reconstrução decomposta pôde ser convertida em modelos independentes, carregados no Gazebo e usados em uma verificação de contato. Essa conclusão permanece condicionada às limitações geométricas já medidas, ao uso de uma única cena e à ausência de propriedades físicas inferidas.

Em relação aos trabalhos relacionados, a cadeia estudada ocupa uma posição específica. Panoptic Neural Fields, Panoptic Lifting e PanoRecon buscam representações com estrutura semântica ou de instâncias; URDFormer, DRAWER e GRS avançam diretamente para representações articuladas, interativas ou baseadas em ativos. Esta dissertação não tenta reproduzir todas essas capacidades. O objetivo é caracterizar o caminho de uma reconstrução DM-NeRF já decomposta até uma cena explícita. A vantagem dessa delimitação é permitir rastrear onde surgem perdas e hipóteses; a desvantagem é que propriedades físicas e articulações permanecem fora do escopo.

O custo de aproximadamente 31 horas de treinamento também é relevante para a reprodutibilidade. A execução foi realizada em sessões de GPU gratuita e exigiu retomada de estado. O desenho experimental adotou uma única cena e, por isso, não mede variabilidade entre ambientes; o número de vértices, pontos ou vistas da cena atual não substitui essa unidade experimental ausente. A interpretação permanece, portanto, restrita à cena *study* e ao protocolo descrito.

7 LIMITAÇÕES METODOLÓGICAS

A primeira limitação é a supervisão de instâncias do protocolo DM-SR. O DM-NeRF recebe mapas 2D de instância durante o treinamento; portanto, os APs não avaliam uma segmentação obtida sem rótulos. A disponibilidade dessa supervisão pode não se repetir em uma aplicação real de captura de ambientes.

A segunda limitação está na extração e na avaliação geométrica. O meshing oficial utiliza a malha de referência para determinar o bounding frame da grade consultada. Embora os valores de densidade sejam produzidos pela rede, o domínio de extração recebe informação do ground truth. As métricas de A0 devem ser lidas dentro desse protocolo e não como avaliação completamente independente da referência.

A terceira limitação é a utilização de uma única cena principal. Os 200.000 pontos amostrados e os centenas de milhares de vértices pertencem ao mesmo ambiente; eles não representam centenas de milhares de unidades experimentais independentes. O trabalho não estima variabilidade entre cenas.

A quarta limitação é a ausência de semântica oficial para o piso nos artefatos inspecionados. A heurística geométrica pode selecionar uma plataforma baixa ou falhar quando o piso estiver fragmentado ou fundido com outras superfícies. A seleção da instância 10 é um resultado do procedimento aplicado à cena *study*, não um mapeamento semântico fornecido pelo dataset.

A quinta limitação é inerente à regularização. A projeção sobre o plano reduz os resíduos ao plano por construção. Ela pode melhorar uma propriedade desejável para suporte, mas também pode deslocar geometria válida quando a superfície real não for plana ou quando a instância selecionada contiver regiões que não pertencem ao piso.

A sexta limitação está na conversão para simulação. Visual e colisão usam a mesma malha triangular e não são inferidos parâmetros de massa, inércia, atrito, materiais ou articulações. Além disso, as malhas exportadas não são estanques. A cena resultante deve ser entendida como uma representação geométrica estruturada para os ensaios definidos, e não como um gêmeo digital fisicamente completo.

Por fim, a validação funcional possui alcance limitado. G1 foi executado para A0, A1 e A2, G2 foi demonstrado com uma instância de A1 e G3 foi realizado em um único

ponto da superfície regularizada. Esses testes mostram carregamento, endereçamento independente e contato no caso ensaiado, mas não cobrem todas as instâncias, toda a extensão do piso nem situações dinâmicas mais complexas.

O baseline COLMAP também possui limitações de desenho experimental. As poses foram fornecidas pelo DM-SR, de modo que o ensaio não inclui erro de Structure-from-Motion. Foi usada uma única configuração de MVS, sem ajuste por cena, com dez vistas-fonte, profundidades entre 4 e 15 m e `StereoFusion.min_num_pixels=1`. Esse último valor favorece completude, mas pode aumentar pontos espúrios. A comparação foi ainda restrita ao mesmo volume orientado usado pelo meshing do DM-NeRF; isso evita penalizar apenas o baseline externo por suporte, porém mantém a dependência do bounding frame da referência já presente no protocolo original. Portanto, os números caracterizam esta execução controlada e não constituem um benchmark geral entre DM-NeRF e COLMAP.

8 CONCLUSÃO

Esta dissertação avaliou uma cadeia que parte de uma reconstrução neural com decomposição de instâncias e produz uma representação explícita e estruturada para simulação robótica. O trabalho manteve o DM-NeRF como método neural e concentrou a análise na extração da geometria, individualização dos elementos, regularização de uma superfície de apoio e integração com o Gazebo Classic.

O estágio neural foi reproduzido até 200.000 iterações e auditado a partir do bundle final. Na cena *study*, a avaliação oficial obteve PSNR de 41,1100 dB, SSIM de 0,9875 e LPIPS de 0,0260. A decomposição apresentou AP50 de 0,9956 e AP95 de 0,7192. A inspeção qualitativa das vistas é compatível com as métricas de imagem e mostra que as maiores diferenças de instância aparecem em contornos e regiões estreitas.

A avaliação da malha A0 mostrou que a qualidade geométrica depende do limiar adotado. O F-score foi 0,0480 a 1 cm, 0,1960 a 2 cm e 0,7750 a 5 cm, com distâncias médias próximas de 4 cm em ambas as direções. Assim, a síntese de vistas e a precisão de superfície não podem ser tratadas como medidas equivalentes.

A separação A1 gerou 13 objetos e preservou 95,844% das faces como faces homogêneas, mantendo 29.545 faces de fronteira explicitamente fora da atribuição. No Gazebo, uma dessas instâncias foi endereçada e deslocada de forma independente, mostrando que a decomposição pôde ser materializada como modelos separados e manipuláveis no simulador.

A ausência de um rótulo semântico oficial para o piso foi tratada por uma heurística geométrica com possibilidade de abstenção. Na cena avaliada, a instância 10 foi a única candidata que satisfez os critérios definidos. A regularização A2 reduziu o P95 do residual ao plano de 6,80 cm para erro numérico. Essa redução decorre da projeção e foi interpretada como mudança de planaridade, não como aumento de fidelidade global.

A integração foi verificada no Gazebo Classic 11.10.2. G0 passou para A0, A1 e A2, e G1 confirmou o carregamento das três condições sem erro fatal associado aos modelos. G2 confirmou a transformação independente de uma instância de A1. Em G3, uma caixa dinâmica de 10 cm caiu sobre a superfície A2, encontrou a superfície, não a atravessou no ponto ensaiado e permaneceu estável na segunda janela de observação. A concordância

numérica entre a pose registrada da face inferior e a altura calculada do plano não é interpretada como precisão física do simulador. O teste confirma o comportamento de contato apenas no ponto ensaiado e não elimina as limitações decorrentes de malhas não estanques.

Para a cena *study*, os resultados respondem à questão de pesquisa indicando que uma reconstrução DM-NeRF com decomposição de instâncias pode ser convertida, por meio do pós-processamento adotado, em uma cena explícita com modelos independentes, carregável no Gazebo e utilizável em um ensaio de apoio e colisão. Essa possibilidade não implica reconstrução geométrica precisa em escalas centimétricas estritas, nem recuperação de propriedades físicas, articulações ou semântica completa dos objetos.

As conclusões permanecem limitadas à cena *study* e ao protocolo reproduzido. O baseline externo COLMAP, executado com poses fixas e no mesmo suporte geométrico, apresentou F-score de 0,0285, 0,1288 e 0,3721 em 1, 2 e 5 cm, abaixo de A0 nos três limiares; esse resultado caracteriza somente a configuração adotada, que não foi otimizada por cena, e não estabelece superioridade geral sobre MVS clássico. Dentro dessa delimitação, a questão de pesquisa é respondida afirmativamente: a reconstrução neural decomposta pôde ser transformada em geometria explícita, objetos independentes e uma cena funcional no simulador, enquanto a avaliação separada mostrou os limites de precisão geométrica, estrutura e validade física dessa transformação.

REFERÊNCIAS

[1] Bhalgat, Y., Laina, I., Henriques, J. F., Vedaldi, A., and Zisserman, A. (2023). Contrastive lift: 3d object instance segmentation by slow-fast contrastive fusion. In *Advances in Neural Information Processing Systems*.

[2] Chen, Z. Q., Walsman, A., Memmel, M., Mo, K., Fang, A., Fox, D., and Gupta, A. (2024). URDFormer: A pipeline for constructing articulated simulation environments from real-world images. In *Robotics: Science and Systems*.

[3] Kundu, A., Genova, K., Yin, X., Fathi, A., Pantofaru, C., Guibas, L., Tagliasacchi, A., Dellaert, F., and Funkhouser, T. (2022). Panoptic neural fields: A semantic object-aware neural scene representation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.

[4] Lemos, J. F. d. S. S., Dorneles, G. A., Maurell, I. P., Brião, S. L., Guerra, R. d. S., and Drews Junior, P. L. J. (2025). Digital environment description and reconstruction using panoptic segmentation. In *RoboCup 2024: Robot World Cup XXVII*, volume 15570 of *Lecture Notes in Computer Science*, pages 236–246. Springer.

[5] Mildenhall, B., Srinivasan, P. P., Tancik, M., Barron, J. T., Ramamoorthi, R., and Ng, R. (2020). NeRF: Representing scenes as neural radiance fields for view synthesis. In *European Conference on Computer Vision*.

[6] Schönberger, J. L., Zheng, E., Frahm, J.-M., and Pollefeys, M. (2016). Pixelwise view selection for unstructured multi-view stereo. In *European Conference on Computer Vision*, pages 501–518.

[7] Siddiqui, Y., Porzi, L., Rota Bulò, S., Müller, N., Niessner, M., Dai, A., and Kontschieder, P. (2023). Panoptic lifting for 3d scene understanding with neural fields. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9043–9052.

[8] Sucar, E., Liu, S., Ortiz, J., and Davison, A. J. (2021). imap: Implicit mapping and positioning in real-time. In *IEEE/CVF International Conference on Computer Vision*.

[9] Wang, B., Chen, L., and Yang, B. (2023). DM-NeRF: 3d scene geometry decomposition and manipulation from 2d images. In *International Conference on Learning Representations*.

[10] Wang, P., Liu, L., Liu, Y., Theobalt, C., Komura, T., and Wang, W. (2021). NeuS: Learning neural implicit surfaces by volume rendering for multi-view reconstruction. In *Advances in Neural Information Processing Systems*.

[11] Wu, D., Yan, Z., and Zha, H. (2024). PanoRecon: Real-time panoptic 3d reconstruction from monocular video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21507–21518.

[12] Xia, H., Su, E., Memmel, M., Jain, A., Yu, R., Mbiziwo-Tiapo, N., Farhadi, A., Gupta, A., Wang, S., and Ma, W.-C. (2025). DRAWER: Digital reconstruction and articulation with environment realism. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21771–21782.

[13] Yariv, L., Gu, J., Kasten, Y., and Lipman, Y. (2021). Volume rendering of neural implicit surfaces. In *Advances in Neural Information Processing Systems*.

[14] Zhu, Z., Peng, S., Larsson, V., Xu, W., Bao, H., Cui, Z., Oswald, M. R., and Pollefeys, M. (2022). NICE-SLAM: Neural implicit scalable encoding for slam. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.

[15] Zook, A., Sun, F.-Y., Spjut, J., Blukis, V., Birchfield, S., and Tremblay, J. (2025). GRS: Generating robotic simulation tasks from real-world images. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 594–603.