



UNIVERSIDADE FEDERAL DO RIO GRANDE - FURG
CENTRO DE CIÊNCIAS COMPUTACIONAIS
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO
CURSO DE MESTRADO EM ENGENHARIA DE COMPUTAÇÃO

Dissertação de Mestrado

Reconstrução Semântica Automatizada de Ambientes Domésticos para Simulação de Robôs

João Francisco de Souza Santos Lemos

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Computação da Universidade Federal do Rio Grande - FURG, como requisito parcial para a obtenção do grau de Mestre em Engenharia de Computação

Orientador: Nelson Lopes Duarte Filho
Co-orientador: Rodrigo da Silva Guerra

Rio Grande, 2026

RESUMO

A reconstrução neural de ambientes pode reduzir o esforço de modelagem, mas não fornece diretamente a estrutura exigida por simuladores robóticos. Esta dissertação avalia a transformação de uma reconstrução DM-NeRF com decomposição de instâncias em uma cena explícita para o Gazebo Classic. O estudo utiliza a cena *study* do conjunto DM-SR e analisa separadamente aparência, geometria, organização dos objetos e funcionamento no simulador. Em 100 vistas de teste, foram obtidos PSNR de 41,1100 dB, SSIM de 0,9875 e LPIPS de 0,0260. Na avaliação geométrica, o F-score da malha variou de 0,0480, a 1 cm, a 0,7750, a 5 cm; no mesmo suporte, o COLMAP obteve 0,0285 e 0,3721. Na cena avaliada, a cadeia produziu 13 modelos independentes, tratou geometricamente a superfície de apoio e gerou uma cena executável no Gazebo, enquanto a avaliação geométrica mostrou forte dependência do limiar de distância.

Palavras-chave: Reconstrução neural, simulação robótica, geometria tridimensional, DM-NeRF.

ABSTRACT

LEMOS, João Francisco de Souza Santos. **Automated Semantic Reconstruction of Domestic Environments for Robot Simulation**. 2026. 40 f. Dissertação (Mestrado) – Programa de Pós-Graduação em Computação. Universidade Federal do Rio Grande - FURG, Rio Grande.

Neural scene reconstruction can reduce modeling effort but does not directly provide the structure required by robotic simulators. This dissertation evaluates the transformation of an instance-decomposed DM-NeRF reconstruction into an explicit scene for Gazebo Classic. The study uses the DM-SR *study* scene and analyzes appearance, geometry, object organization, and simulator operation separately. On 100 test views, the reconstruction achieved 41.1100 dB PSNR, 0.9875 SSIM, and 0.0260 LPIPS. In the geometric evaluation, the mesh F-score ranged from 0.0480 at 1 cm to 0.7750 at 5 cm; on the same spatial support, COLMAP achieved 0.0285 and 0.3721. In the evaluated scene, the pipeline produced 13 independent models, treated the support surface geometrically, and generated an executable Gazebo scene, while the geometric evaluation showed a strong dependence on the distance threshold.

Keywords: neural reconstruction, robot simulation, 3D geometry, DM-NeRF.

LISTA DE FIGURAS

Figura 1 Cadeia metodológica entre as observações do DM-SR e a cena no Gazebo Classic, com as medidas empregadas em cada etapa. 16

Figura 2 Síntese de vistas nas posições 0, 33, 66 e 99. A ampliação da diferença em (c) torna visíveis discrepâncias locais sem alterar as imagens comparadas. 26

Figura 3 Decomposição de instâncias nas vistas 0, 33, 66 e 99. Em (a) e (b), as cores identificam IDs, não classes semânticas; em (c), magenta indica divergência entre referência e predição. 27

Figura 4 Comparação qualitativa da geometria no mesmo sistema de coordenadas, suporte e enquadramento. A nuvem COLMAP apresenta maior dispersão e superfícies mais espessas. 29

Figura 5 F-score geométrico de A0 e COLMAP nos limiares de 1, 2 e 5 cm. . . 30

Figura 6 Visualização da reconstrução colorida por instância em dois pontos de vista. As cores são usadas somente para distinguir IDs. 31

Figura 7 Resíduo assinado ao plano da instância 10 antes e depois da regularização. À esquerda, A1; à direita, A2. O eixo vertical é limitado a ± 20 cm para leitura da distribuição principal; o residual máximo de A1, 1,64 m, permanece reportado no texto e nas métricas. 32

Figura 8 Cena A2 no Gazebo Classic com materiais visuais distintos por instância. As cores foram adicionadas somente para interpretação da figura; a geometria e as colisões são as mesmas usadas nos testes funcionais. 34

LISTA DE TABELAS

Tabela 1 Comparação qualitativa entre trabalhos relacionados e a cadeia desta dissertação. 14

Tabela 2 Etapas da cadeia e medidas utilizadas. 17

Tabela 3 Resumo da execução final. 24
Tabela 4 Métricas do avaliador oficial na cena *study*. 25
Tabela 5 Comparação entre a reprodução desta dissertação e os resultados publicados para a cena *study* do DM-SR. 25
Tabela 6 Distâncias entre A0 e a referência DM-SR. 28
Tabela 7 Precision, Completeness e F-score da geometria A0. 28
Tabela 8 Comparação geométrica entre A0 e o baseline COLMAP no mesmo suporte e com 200.000 pontos por conjunto. 29
Tabela 9 Resumo da separação A1. 30
Tabela 10 Métricas da instância 10 antes e depois da regularização. 32
Tabela 11 Resultado das verificações de integração com o Gazebo Classic. . . . 33

LISTA DE ABREVIATURAS E SIGLAS

AMP	Automatic Mixed Precision
AP	Average Precision
DM-NeRF	3D Scene Geometry Decomposition and Manipulation from 2D Images
DM-SR	conjunto de dados utilizado pelo protocolo do DM-NeRF
GT	Ground Truth
IoU	Intersection over Union
LPIPS	Learned Perceptual Image Patch Similarity
MVS	Multi-View Stereo
NeRF	Neural Radiance Field
PSNR	Peak Signal-to-Noise Ratio
RANSAC	Random Sample Consensus
RMSE	Root Mean Squared Error
SDFormat	Simulation Description Format
SSIM	Structural Similarity Index Measure
URDF	Unified Robot Description Format

SUMÁRIO

1 Introdução **9**
1.1 Problema de pesquisa 10
1.2 Objetivos 10
1.3 Delimitação e contribuição 11

2 Fundamentação e trabalhos relacionados **12**
2.1 Representações neurais de cenas e superfícies 12
2.2 Estrutura de objetos e reconstrução panóptica 12
2.3 Geração de ambientes para simulação 13
2.4 Comparação por características 13

3 Metodologia **15**
3.1 Visão geral 15
3.2 Conjunto de dados DM-SR 17
3.3 Treinamento e avaliação do DM-NeRF 17
3.4 Extração da malha e contrato de rótulos 18
3.5 Separação estrutural (A1) 18
3.6 Seleção geométrica do piso 18
3.7 Regularização do piso (A2) 19
3.8 Exportação para Gazebo Classic 19

4 Protocolo experimental **20**
4.1 Unidade experimental e proveniência 20
4.2 Condições de ablação A0, A1 e A2 20
4.3 Síntese de vistas e decomposição 21
4.4 Avaliação geométrica 21
4.5 Baseline geométrico externo 21
4.6 Avaliação da separação e do piso 22
4.7 Validação funcional 22
4.8 Custo computacional 22

5 Resultados **24**
5.1 Treinamento e custo computacional 24
5.2 Síntese de vistas 25
5.2.1 Comparação com os resultados publicados do DM-NeRF 25
5.3 Decomposição de instâncias 26
5.4 Geometria extraída (A0) 27

5.5 Baseline geométrico externo: COLMAP 28
5.6 Separação estrutural (A1) 30
5.7 Seleção e regularização do piso 31
5.8 Integração no Gazebo Classic 32

6 Discussão **35**
6.1 Validade e alcance 37

7 Conclusão **38**

Referências **39**

1 INTRODUÇÃO

A construção de ambientes virtuais para robótica envolve requisitos diferentes dos encontrados em aplicações voltadas somente à visualização. Uma cena pode produzir imagens próximas das observações originais e, ainda assim, apresentar superfícies descontínuas, objetos fundidos ou uma organização que impeça a manipulação independente de seus componentes. Da mesma forma, o fato de uma malha poder ser carregada por um simulador não demonstra que sua geometria seja fiel ao ambiente reconstruído. Qualidade de imagem, qualidade geométrica e uso funcional em simulação são propriedades relacionadas, mas não equivalentes.

Os campos de radiância neurais, introduzidos por Mildenhall et al. [6], representam uma cena por uma função contínua aprendida a partir de imagens e poses de câmera. A formulação possibilita síntese de novas vistas e originou linhas de trabalho voltadas à reconstrução de superfícies, mapeamento e inclusão de informação semântica ou orientada a objetos. Entretanto, a saída de uma representação neural implícita não é diretamente uma cena de simulação. Para esse uso, é necessário obter geometria explícita, preservar a individualidade dos elementos e construir uma descrição compatível com mecanismos de visualização e colisão.

O DM-NeRF [10] combina uma representação neural da cena com decomposição em instâncias. No protocolo DM-SR utilizado nesta dissertação, o treinamento recebe imagens RGB, poses de câmera e mapas bidimensionais de instância. Assim, a decomposição não é obtida exclusivamente a partir das imagens RGB sem supervisão. A saída do método, por outro lado, fornece uma base para investigar a etapa posterior: como transformar uma reconstrução neuralmente decomposta em uma representação explícita que possa ser organizada e testada em um simulador.

A dissertação examina essa transição. A cadeia estudada compreende a reprodução do DM-NeRF na cena *study* do DM-SR, a extração de uma malha, a associação explícita dos identificadores de instância aos vértices, a separação dos objetos, a identificação geométrica de um candidato a piso, a regularização condicionada dessa superfície e a exportação para Gazebo Classic. O SDFormat é empregado como mecanismo de descrição da cena, sem ser tratado como contribuição científica.

1.1 Problema de pesquisa

Simuladores como o Gazebo operam sobre entidades explícitas. Modelos, links, geometrias visuais e geometrias de colisão precisam estar definidos e referenciados. Uma cena reconstruída como uma única malha não permite remover ou reposicionar um móvel sem tratamento adicional. Superfícies de apoio com ruído podem gerar contatos e colisões diferentes daqueles esperados. Além disso, massa, inércia, atrito, articulações e outros parâmetros físicos não podem ser deduzidos de forma geral somente das imagens utilizadas na reconstrução.

A questão que orienta a dissertação é:

> **Em que medida uma reconstrução neural com decomposição de instâncias, combinada a pós-processamento geométrico, permite gerar ambientes domésticos estruturados para simulação robótica?**

A expressão "em que medida" é adotada porque a resposta não é binária. A cadeia é examinada separadamente nos domínios de síntese de vistas, decomposição de instâncias, geometria, estrutura dos objetos, planaridade do piso, integração com o simulador e custo computacional.

1.2 Objetivos

O objetivo geral é avaliar a capacidade de uma cadeia baseada em DM-NeRF e pós-processamento geométrico de transformar reconstruções neuralmente decompostas em ambientes domésticos estruturados para simulação robótica.

Os objetivos específicos são:

1) reproduzir e caracterizar a reconstrução e a decomposição da cena *study* do DM-SR com o DM-NeRF;

2) avaliar síntese de vistas e decomposição de instâncias pelo protocolo oficial do método;

3) avaliar a geometria explícita extraída, sem usar métricas de imagem como substituto de avaliação tridimensional;

4) transformar identificadores explícitos de instância em objetos tridimensionais independentes;

5) selecionar um candidato geométrico a piso por critérios explícitos e medir o efeito de sua regularização;

6) avaliar a integração da cena estruturada no Gazebo Classic por critérios funcionais definidos previamente; e

7) registrar custo computacional e proveniência dos artefatos necessários à reprodução.

1.3 Delimitação e contribuição

O escopo experimental é restrito ao DM-NeRF como método neural principal, ao DM-SR como conjunto de dados e à cena *study* como estudo de caso. Não são propostas uma nova arquitetura neural, uma nova função de perda, um novo segmentador, recuperação de modelos CAD ou migração para outro simulador. O COLMAP integra a avaliação como baseline geométrico externo no mesmo suporte espacial, sem constituir uma comparação de decomposição de instâncias ou de integração com o simulador.

A contribuição consiste em estudar a passagem de uma reconstrução DM-NeRF para geometria explícita, objetos independentes e uma cena executável no Gazebo Classic. O trabalho estabelece: (i) uma associação definida entre a topologia da malha e os identificadores de instância, incluindo o tratamento conservador das faces de fronteira; (ii) critérios geométricos para selecionar a superfície de apoio, seguidos de regularização somente quando esses critérios são satisfeitos; e (iii) uma avaliação separada de aparência, geometria, estrutura e funcionamento no simulador, com o COLMAP como referência geométrica externa. A contribuição não é o DM-NeRF, o SDFormat ou uma nova arquitetura neural, mas a formulação e a análise experimental desse percurso entre a saída neural e a cena de simulação.

Neste experimento, a informação semântica usada para estruturar a cena é a identidade de instância fornecida pelo DM-NeRF; não se avalia uma classificação categórica completa dos objetos. O caráter automatizado refere-se às etapas posteriores às entradas do protocolo: extração, separação, seleção e regularização do piso e exportação são executadas por rotinas sem edição manual individual das malhas.

2 FUNDAMENTAÇÃO E TRABALHOS RELACIONADOS

2.1 Representações neurais de cenas e superfícies

Mildenhall et al. [6] representam uma cena por uma função neural contínua que associa posição espacial e direção de observação a densidade volumétrica e cor. A renderização volumétrica permite sintetizar imagens em pontos de vista que não foram apresentados durante o treinamento. A formulação foi concebida para síntese de vistas, e não como uma descrição explícita de objetos e colisões.

Wang et al. [11] e Yariv et al. [15] aproximam a representação implícita da reconstrução de superfícies em NeuS e VolSDF, respectivamente. Esses trabalhos ajudam a distinguir qualidade de imagem de qualidade geométrica: uma representação capaz de sintetizar novas vistas pode conter geometria insuficiente para uso em simulação, e a superfície extraída depende de decisões de amostragem, domínio e limiar.

No campo da robótica, Sucar et al. [9] e Zhu et al. [17] exploram representações implícitas em problemas de mapeamento e localização com iMAP e NICE-SLAM. Esses sistemas mostram a aproximação entre representações neurais e tarefas robóticas, embora não eliminem, para a simulação, a necessidade de entidades explícitas e organizadas.

2.2 Estrutura de objetos e reconstrução panóptica

Kundu et al. [4] propõem Panoptic Neural Fields, que incorpora estrutura de objetos e fundo a campos neurais e utiliza predições auxiliares para obter informação panóptica. O método permite consultas e edição no domínio neural, mas não tem como saída principal um conjunto de malhas de colisão ou um mundo de simulador.

Siddiqui et al. [8] propõem Panoptic Lifting a partir de imagens, poses e segmentações panópticas 2D, tratando inconsistências de identificadores entre vistas para formar uma representação tridimensional coerente. Bhalgat et al. [1] abordam a segmentação tridimensional de instâncias em Contrastive Lift, combinando características em ritmos distintos para consolidar instâncias entre vistas. Wu et al. [13], por sua vez, combinam reconstrução monocular em tempo real com geometria, semântica e instâncias persistentes. Esses trabalhos avançam a compreensão panóptica e a reconstrução, mas não têm como

saída principal uma cena organizada em objetos e colisões para um simulador.

Como referência geométrica externa, o COLMAP fornece uma cadeia clássica de reconstrução multivista densa. O componente *Multi-View Stereo* (MVS) estima a superfície a partir da correspondência de pontos observados em várias imagens; no COLMAP, ele combina estimativa de profundidade e normais, seleção de vistas e consistência geométrica antes da fusão dos mapas de profundidade [7]. Nesta dissertação, ele é usado somente como baseline de geometria: as poses do DM-SR são fornecidas diretamente e não há estimação de pose, segmentação de instâncias ou geração de entidades de simulador.

Wang et al. [10] propõem o DM-NeRF, componente neural adotado nesta dissertação. No DM-SR, o método é treinado por cena com RGB, poses e mapas 2D de instância, e sua representação permite decomposição e manipulação no campo neural. O presente trabalho preserva esse estágio e investiga a materialização posterior da geometria e das instâncias para uso em simulação.

2.3 Geração de ambientes para simulação

Chen et al. [2] apresentam URDFormer, que parte de uma imagem e produz uma descrição articulada em *Unified Robot Description Format* (URDF), formato usado para representar elos e juntas de sistemas robóticos. O método infere partes, relações e juntas e recorre a ativos previamente disponíveis. Essa abordagem favorece estrutura cinemática, mas não equivale à reconstrução multivista da superfície observada.

Xia et al. [14] produzem ambientes interativos a partir de vídeo com DRAWER, combinando representação geométrica implícita, aparência e articulações. O trabalho aproxima a reconstrução de uma cadeia *real-to-sim*, mas utiliza componentes, entradas e objetivos diferentes dos adotados aqui. Zook et al. [18] constroem, com GRS, tarefas de simulação a partir de observações reais e recuperação de ativos. A saída é um análogo funcional composto por ativos, e não a superfície diretamente reconstruída da cena.

Em trabalho anterior, Lemos et al. [5] exploraram a descrição e reconstrução de ambientes com segmentação panóptica, incluindo separação de componentes, tratamento do piso e geração de uma cena editável no Gazebo. A presente dissertação amplia esse desenvolvimento ao fixar o DM-NeRF como método neural e submeter a cadeia a um protocolo quantitativo que distingue síntese, geometria, estrutura e funcionamento. Os resultados da publicação anterior não são combinados com as medições atuais.

2.4 Comparação por características

A Tabela 1 posiciona a cadeia avaliada em relação às entradas, às representações produzidas e ao destino de cada método. A comparação é qualitativa porque os trabalhos

respondem a problemas experimentais diferentes.

Tabela 1: Comparação qualitativa entre trabalhos relacionados e a cadeia desta dissertação.

Trabalho	**Entrada**	**Representação, estrutura e relação com simulação**
Panoptic Neural Fields	imagens e predições 2D	campo neural orientado a objetos e editável; simulador não é a saída principal
Panoptic Lifting	RGB, poses e máscaras panópticas	campo neural panóptico 3D; não gera cena de simulação
PanoRecon	vídeo monocular	reconstrução online com instâncias; simulador não é o objetivo principal
DM-NeRF	RGB, poses e mapas 2D de instância	campo neural decomposto, com malha por extração; não gera cena diretamente
COLMAP	RGB e poses fixas	nuvem densa por MVS, sem instâncias ou cena de simulação
URDFormer	imagem RGB	hierarquia URDF com ativos predefinidos para simulação articulada
DRAWER	vídeo	ambiente interativo com geometria e articulações
GRS	RGB-D	segmentação, recuperação de ativos e tarefas de simulação
Cadeia avaliada nesta dissertação	RGB, poses e mapas 2D de instância	malha DM-NeRF, IDs, objetos separados e cena SDFormat no Gazebo Classic

A comparação mostra que os trabalhos cobrem pontos diferentes entre aparência, reconstrução, compreensão de cena e geração de conteúdo para simulação. A cadeia desta dissertação mantém a geometria do DM-NeRF como ponto de partida e concentra a análise em sua estruturação e integração ao simulador. Métodos que inferem articulações ou recuperam ativos resolvem outro problema e, por isso, são tratados como contexto de literatura, não como equivalentes experimentais.

3 METODOLOGIA

3.1 Visão geral

O estudo é organizado como uma cadeia de reconstrução e estruturação. O estágio neural é executado com DM-NeRF sobre DM-SR. A partir do modelo treinado, são produzidas métricas de teste e uma malha triangular com identificadores de instância por vértice. O pós-processamento transforma essa saída em objetos independentes, seleciona um candidato geométrico a piso, regulariza essa superfície quando a seleção é válida e exporta uma cena em SDFormat.

A Figura 1 apresenta a sequência completa e indica a medida associada a cada transformação. Essa correspondência entre etapa e medida orienta o protocolo experimental e impede que qualidade visual seja tomada como substituta da qualidade geométrica ou funcional.



Figura 1: Cadeia metodológica entre as observações do DM-SR e a cena no Gazebo Classic, com as medidas empregadas em cada etapa.

Por convenção deste experimento, as condições da ablação interna são identificadas pelo prefixo A: A0 corresponde à malha extraída, A1 acrescenta a separação dos objetos e A2 acrescenta a regularização do piso. As verificações no Gazebo recebem o prefixo G e avançam da validação estática, G0, aos ensaios funcionais G1–G3. A numeração expressa, portanto, a progressão cumulativa da cadeia, e não uma nomenclatura própria do DM-NeRF.

As etapas e suas medidas são apresentadas na Tabela 2. A organização evita atribuir a uma etapa uma métrica que ela não pode alterar. A separação estrutural A1, por exemplo, não modifica intencionalmente as coordenadas das faces preservadas e, portanto, não é avaliada por PSNR ou por ganho de distância de superfície.

Tabela 2: Etapas da cadeia e medidas utilizadas.

Etapa	**Transformação**	**Medida principal**
Neural	treinamento e avaliação do DM-NeRF	PSNR, SSIM, LPIPS e AP em vistas de teste
A0 – malha	extração da malha	distâncias de superfície, Precision, Completeness e F-score
A1 – objetos	separação por IDs explícitos	número de instâncias, cobertura de faces e fronteiras
A2 – piso	regularização do candidato a piso	resíduos ao plano antes/depois
Gazebo	exportação e execução	verificações G0–G3

3.2 Conjunto de dados DM-SR

O conjunto DM-SR fornece imagens RGB, poses de câmera, mapas bidimensionais de instância e uma malha tridimensional de referência. Para a cena *study*, o experimento utiliza 300 imagens de treinamento e 100 vistas de teste do protocolo original. A malha de referência e os metadados de câmera são mantidos nas avaliações geométricas; quatro vistas de teste são usadas nas comparações qualitativas.

Quatro vistas reais da cena, extraídas do conjunto de teste, são apresentadas posteriormente junto às renderizações correspondentes do DM-NeRF (Figura 2). Essa comparação introduz visualmente a configuração doméstica/escritório e evita repetir as mesmas imagens em figuras distintas.

A malha de referência tem 437.008 vértices e 844.701 faces. O procedimento oficial de extração de malha do DM-NeRF utiliza o *oriented bounding box* dessa referência para definir o volume e a orientação da consulta ao campo neural. Dessa forma, a referência participa da definição do domínio de extração, e as métricas geométricas são interpretadas dentro desse domínio.

Os mapas de instância do DM-SR utilizam identificadores inteiros, mas os artefatos inspecionados não fornecem um catálogo semântico completo que associe cada ID a uma classe do ambiente. Em particular, não foi encontrada uma associação oficial entre um ID e a classe piso.

3.3 Treinamento e avaliação do DM-NeRF

A reprodução utiliza a implementação oficial do DM-NeRF. A configuração final usa 64 amostras no passe inicial, 128 amostras adicionais, 3.072 raios no treinamento e 1.024 raios no avaliador. O treinamento foi realizado com precisão mista automática; a avaliação final e a extração da malha foram mantidas em FP32.

O avaliador oficial calcula a razão sinal-ruído de pico (PSNR), o índice de similaridade

estrutural (SSIM) [12] e a distância perceptual LPIPS [16] para síntese de vistas; o PSNR segue a definição usada no protocolo do DM-NeRF [10]. Para decomposição, a interseção sobre união (IoU) mede a sobreposição entre uma máscara predita e sua referência, e a precisão média (AP) resume a qualidade das detecções em um limiar de IoU, conforme o avaliador do método. Valores maiores indicam melhor correspondência. São usados os limiares de IoU 0,50, 0,75, 0,80, 0,85, 0,90 e 0,95. A função de perda e as métricas emitidas durante o treinamento não são utilizadas como resultados de teste.

3.4 Extração da malha e contrato de rótulos

Após o treinamento, o campo neural é consultado no volume definido pelo procedimento oficial e convertido em malha triangular. A condição A0 reúne a geometria extraída e um vetor de identificadores de instância associado aos vértices. As cores presentes na visualização são usadas somente para apresentação; a separação estrutural consulta os identificadores explícitos, e não valores RGB.

Antes de separar objetos, o contrato verifica a quantidade e a ordem dos vértices, os índices dos triângulos, a topologia e a finitude das coordenadas. Essa verificação impede a associação de IDs a uma malha com ordem de vértices diferente. A malha final contém 356.272 vértices e 710.928 faces.

3.5 Separação estrutural (A1)

A condição A1 é formada a partir de A0. Para cada triângulo, são consultados os IDs de seus três vértices. Uma face é atribuída a uma instância somente quando os três IDs coincidem. Faces com IDs diferentes são classificadas como faces de fronteira e permanecem fora das malhas individuais. A decisão evita escolher arbitrariamente um dos rótulos presentes na face.

Para cada instância com faces homogêneas, os vértices utilizados são remapeados e uma malha independente é exportada. São registrados o ID, o número de vértices e faces, a área, os limites espaciais e o centroide. A cobertura de faces homogêneas e a quantidade de fronteiras são calculadas sobre a topologia original.

3.6 Seleção geométrica do piso

Como não há rótulo semântico oficial para o piso, a seleção usa uma heurística geométrica definida antes da observação da malha final. Cada instância é analisada somente pelas faces homogêneas. O plano principal é obtido por covariância dos vértices dessas faces com ponderação pela área dos triângulos. São calculados área, fração de área aproximadamente horizontal, normal, altura e RMSE do ajuste.

Uma instância é elegível quando satisfaz simultaneamente: área de pelo menos 0,5

m^2; pelo menos 85% da área com orientação de até 15 graus da vertical; normal do plano dentro do mesmo limite angular; RMSE de no máximo 0,03 m; e posição na faixa inferior da cena, definida pelo percentil 1 das alturas acrescido de 20% da amplitude vertical. O eixo vertical da malha é +Y.

Entre candidatas elegíveis, a maior área é escolhida se a segunda candidata tiver área inferior a 80% da primeira. Caso contrário, a saída é ambígua. Se nenhuma instância for elegível, a saída é "não identificada". Em ambos os casos de abstenção, A2 é bloqueada. A regra não utiliza cor, número de ID ou associação histórica como critério semântico.

3.7 Regularização do piso (A2)

Quando existe candidato válido, os vértices associados ao ID selecionado são usados no algoritmo *Random Sample Consensus* (RANSAC) de Fischler and Bolles [3], que ajusta um modelo robusto mesmo na presença de pontos discrepantes. O limiar é 2 cm e a semente é fixa. O plano final é ajustado aos inliers. A regularização projeta apenas os vértices da instância selecionada sobre esse plano. A topologia e os IDs não são alterados.

O efeito é medido sobre o mesmo subconjunto antes e depois da projeção. São reportados erro absoluto médio, RMSE, P95 e fração de inliers. Uma redução desses resíduos indica apenas maior aderência ao plano estimado. Como a operação é uma projeção, a redução é esperada por construção e não demonstra aumento de fidelidade global em relação ao ambiente real.

3.8 Exportação para Gazebo Classic

A exportação gera mundos SDFormat com referências relativas. A0 é representada por uma malha única. A1 e A2 são representadas por modelos independentes derivados das instâncias. Cada modelo possui um link, um elemento visual e um elemento de colisão apontando para a mesma malha triangular. O referencial +Y da reconstrução é rotacionado para +Z do Gazebo por uma transformação rígida comum.

A validação G0 verifica XML, nomes únicos, existência das malhas, caminhos relativos, escalas positivas e correspondência entre visual e colisão. Essa etapa não executa a física e não substitui o parser nativo do Gazebo. G1, G2 e G3 verificam, respectivamente, carregamento real, manipulação independente e suporte/colisão do piso.

4 PROTOCOLO EXPERIMENTAL

4.1 Unidade experimental e proveniência

A cena *study* é a unidade experimental. O mesmo modelo, obtido após 200.000 iterações em três sessões de treinamento, é empregado na avaliação de vistas, na decomposição e na extração geométrica. Ensaios preliminares de desempenho e infraestrutura não são incorporados aos resultados científicos.

A configuração, o ambiente computacional e as saídas brutas foram preservados para reprodução. Antes da análise, verificou-se a consistência entre o resumo do avaliador oficial, as métricas das 100 vistas de teste e os artefatos geométricos extraídos.

Os scripts, configurações e instruções de execução estão versionados no repositório `https://github.com/Jfsslemos/sdf-generator`. A configuração empregada nos resultados corresponde ao commit `e8bef9b7dc77`. O repositório registra o processamento desde o treinamento e a avaliação oficial até a extração, a separação por instância, a análise geométrica, a exportação SDFormat e os testes estáticos. As saídas numéricas usadas nas tabelas permanecem associadas aos arquivos que as produziram, enquanto artefatos volumosos são mantidos fora do controle de versão.

4.2 Condições de ablação A0, A1 e A2

O prefixo A identifica as condições da ablação interna, e a numeração representa estados cumulativos do pós-processamento: 0 para a saída sem essas transformações, 1 após a separação estrutural e 2 após a regularização do piso. As três condições são derivadas da mesma reconstrução:

- **A0**: malha extraída do campo neural, antes do pós-processamento geométrico;
- **A1**: A0 separada em objetos por IDs explícitos de instância; e
- **A2**: A1 com projeção dos vértices do candidato a piso sobre o plano estimado.

A0 é avaliada por métricas de superfície. A1 é avaliada por cobertura da separação e quantidade de objetos; as coordenadas das faces preservadas não são modificadas. A2 é

avaliada por métricas pareadas do piso e por suporte e colisão no simulador.

4.3 Síntese de vistas e decomposição

As métricas de síntese são PSNR, SSIM e LPIPS. Para PSNR e SSIM, valores maiores indicam maior semelhança com a imagem de referência; para LPIPS, valores menores indicam maior semelhança perceptual. A decomposição utiliza AP50, AP75, AP80, AP85, AP90 e AP95. O sufixo indica o limiar de IoU exigido: quanto maior o limiar, mais precisa deve ser a sobreposição das máscaras; em todos os casos, AP maior é melhor. As médias são calculadas sobre as 100 vistas de teste e conferidas contra os resultados individuais.

4.4 Avaliação geométrica

A0 e a malha de referência são amostradas com 200.000 pontos de superfície, semente 42. Para cada conjunto, calcula-se a distância ao vizinho mais próximo do conjunto oposto. As métricas incluem distância média em cada direção, soma das duas médias como distância simétrica L1, RMSE em cada direção e Precision, Completeness e F-score nos limiares de 1, 2 e 5 cm.

Para um limiar t, Precision é a fração dos pontos previstos a no máximo t da referência. Completeness é a fração dos pontos da referência a no máximo t da previsão. O F-score é a média harmônica dessas duas frações.

A interpretação considera a dependência do bounding frame da referência no meshing oficial. Portanto, as métricas descrevem a saída dentro do protocolo reproduzido; não são apresentadas como uma avaliação cujo volume de extração foi obtido independentemente do *ground truth*.

4.5 Baseline geométrico externo

Como referência externa foi executado o MVS denso do COLMAP [7] com as 300 imagens de treinamento da cena *study*. As poses e os intrínsecos oficiais do DM-SR foram fornecidos diretamente ao COLMAP; portanto, o baseline avalia a reconstrução densa e não a estimação de pose. Para cada imagem de referência foram selecionadas as dez câmeras mais próximas em posição. O PatchMatch utilizou consistência geométrica, intervalo de profundidade de 4 a 15 m e a fusão foi executada com `min_num_pixels=1`. Não foi realizada busca de hiperparâmetros.

A saída do COLMAP permanece no sistema de coordenadas das poses do DM-SR, enquanto o gerador de malha do DM-NeRF consulta a rede após a permutação de eixos $[x, y, z]_{rede} = [x, -z, y]_{cena}$. Antes da comparação, a nuvem COLMAP é portanto convertida de volta para o sistema da malha por $[x, y, z]_{cena} = [x, z, -y]_{COLMAP}$.

Há ainda uma diferença de suporte: o meshing oficial do DM-NeRF restringe a consulta a uma caixa orientada definida a partir da referência, com extensões fixas de $1,9 \times 7,0 \times 7,0$ m. Para não penalizar apenas o COLMAP por reconstruir pontos fora desse volume, a avaliação principal do baseline é limitada ao mesmo suporte orientado. Dos 5.800.316 pontos fundidos, 3.416.962 (58,91%) permanecem dentro desse volume. Em seguida, 200.000 pontos são amostrados com semente 42, igualando a cardinalidade usada na avaliação de A0. As métricas são então calculadas pelas mesmas definições de distância, Precision, Completeness e F-score.

Os números produzidos diretamente pelo notebook antes dessa conversão de coordenadas e da equalização de suporte não são usados na análise comparativa, pois misturam convenções de referência distintas.

4.6 Avaliação da separação e do piso

Em A1 são registrados o número de instâncias, faces homogêneas, faces de fronteira e cobertura. As faces de fronteira permanecem contabilizadas mesmo quando são omitidas das malhas individuais.

Para o piso, o relatório de seleção registra todos os candidatos e motivos de rejeição. A regularização usa limiar RANSAC de 2 cm, 2.000 iterações e semente 42. O P95 é mantido como medida principal, acompanhado de média absoluta, RMSE e fração de inliers.

4.7 Validação funcional

O prefixo G identifica as verificações realizadas no Gazebo. A numeração avança da verificação estrutural estática para ensaios funcionais progressivamente mais específicos:

G0 validação estática do arquivo SDFormat e de suas referências;

G1 carregamento do mundo no Gazebo Classic sem erro fatal associado aos modelos;

G2 transformação independente de pelo menos uma instância em A1/A2;

G3 verificação pontual de apoio e colisão da superfície regularizada em A2.

G0 não é interpretado como demonstração de comportamento físico. G1–G3 verificam, em sequência, carregamento, independência estrutural e contato no ponto ensaiado.

4.8 Custo computacional

São reportados tempo de treinamento, atualizações efetivas, atualizações puladas pelo AMP, pico de memória alocada pelo PyTorch, pico observado pela telemetria, tempo de

avaliação e tempo de extração da malha. O uso de GPU gratuita é uma condição de reprodução, não uma métrica de qualidade.

5 RESULTADOS

5.1 Treinamento e custo computacional

O treinamento foi concluído em três sessões, totalizando aproximadamente 30 h 58 min. O estado final registra 200.000 iterações, 199.916 atualizações efetivamente aplicadas pelo otimizador e 85 atualizações puladas pelo escalonador de AMP. Isso corresponde a aproximadamente 0,0425% das tentativas de atualização.

O pico de memória alocada pelo PyTorch foi de aproximadamente 5,58 GiB e o pico observado pela telemetria do dispositivo foi 7.417 MiB. A avaliação oficial levou 2.568,48 s (42,8 min) e a extração da malha levou 109,13 s (1,82 min). A Tabela 3 reúne esses valores.

Tabela 3: Resumo da execução final.

Medida	**Valor**
Iteração final	200.000
Atualizações efetivas	199.916
Atualizações puladas por AMP	85
Tempo de treinamento	30 h 58 min
Pico PyTorch	5,58 GiB
Pico da telemetria	7.417 MiB
Tempo de avaliação	2.568,48 s
Tempo de meshing	109,13 s

O custo concentra-se no treinamento por cena. Nesse regime, a cadeia é adequada à preparação — fora de linha — de um ambiente de simulação, e não à reconstrução durante a execução de uma tarefa robótica. Depois do treinamento, a avaliação e a extração geométrica acrescentaram menos de 45 minutos na configuração utilizada.

5.2 Síntese de vistas

A Tabela 4 apresenta as médias do avaliador oficial sobre 100 vistas de teste. PSNR e SSIM aumentam com a semelhança à referência, enquanto LPIPS diminui quando a distância perceptual é menor. A média oficial coincide com a agregação dos resultados por vista. Essas métricas caracterizam aparência, mas não medem precisão da superfície tridimensional.

Tabela 4: Métricas do avaliador oficial na cena *study*.

PSNR	SSIM	LPIPS	AP50	AP75	AP80	AP85	AP90	AP95
41,1100	0,9875	0,0260	0,9956	0,9911	0,9849	0,9769	0,9311	0,7192

5.2.1 Comparação com os resultados publicados do DM-NeRF

A reprodução pode ser comparada diretamente aos valores publicados por Wang et al. [10] para a mesma cena *study* do DM-SR. Essa comparação é distinta de um novo baseline: seu objetivo é verificar se o estágio neural reproduz o comportamento reportado pelo método de origem antes de analisar as transformações propostas nesta dissertação. A Tabela 5 apresenta os valores.

Tabela 5: Comparação entre a reprodução desta dissertação e os resultados publicados para a cena *study* do DM-SR.

Fonte	**PSNR (dB)**	**SSIM**	**LPIPS**	**$AP_{0,75}$ (%)**
Wang et al. (2023)	41,08	0,987	0,026	98,86
Esta reprodução	41,110	0,9875	0,0260	99,11

As diferenças são de 0,03 dB em PSNR, 0,0005 em SSIM, aproximadamente zero em LPIPS na precisão reportada e 0,25 ponto percentual em $AP_{0,75}$. Com uma única cena, esses desvios não sustentam uma análise de significância estatística; eles mostram que a execução reproduz proximamente os valores publicados para *study*.

O mesmo artigo reporta, para a cena *study*, $AP_{0,75}$ de 96,86% para Mask R-CNN e 97,88% para Swin Transformer, ambos ajustados por cena, contra 98,86% do DM-NeRF publicado. A reprodução desta dissertação obteve 99,11%. Em relação aos valores publicados dos dois baselines 2D, a diferença é de 2,25 e 1,23 pontos percentuais, respectivamente. Esses números são usados como referência de literatura e não como reexecução independente dos baselines.

A Figura 2 compara as vistas 0, 33, 66 e 99 com as renderizações correspondentes. Como as duas primeiras linhas são visualmente próximas, a terceira apresenta a diferença absoluta entre os pixels, ampliada por um fator cinco apenas para visualização. As discrepâncias concentram-se em contornos, sombras e detalhes do mobiliário.

(a) Referência DM-SR



(b) Renderização DM-NeRF



(c) Diferença absoluta ampliada $5\times$

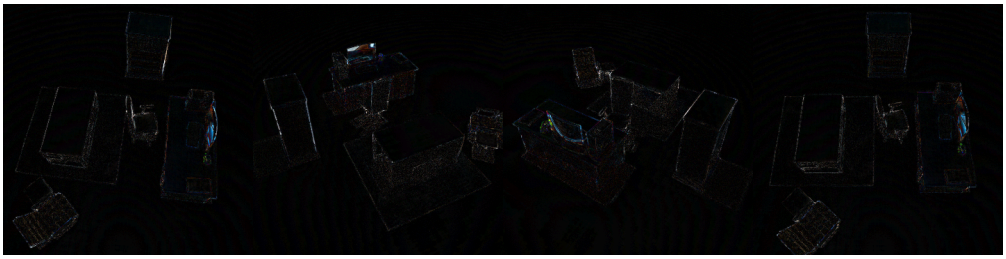


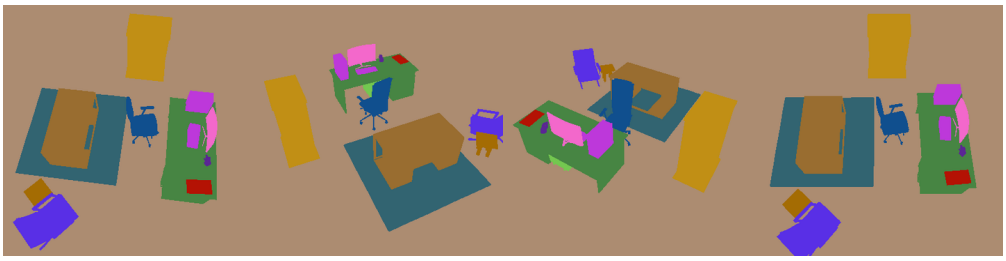
Figura 2: Síntese de vistas nas posições 0, 33, 66 e 99. A ampliação da diferença em (c) torna visíveis discrepâncias locais sem alterar as imagens comparadas.

5.3 Decomposição de instâncias

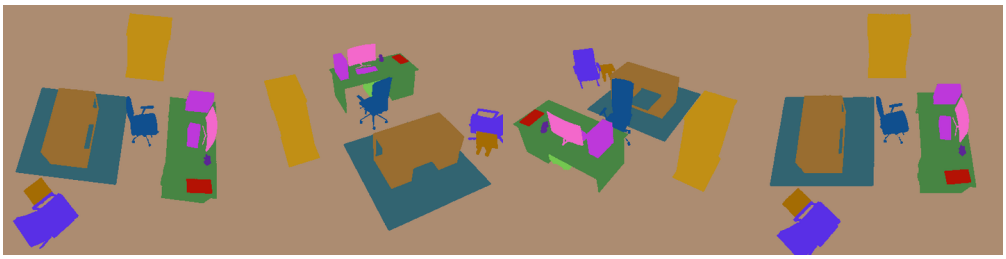
Os APs, para os quais valores maiores indicam melhor detecção e correspondência das máscaras, permanecem próximos de 1,0 nos limiares de IoU menos restritivos e diminuem quando a coincidência exigida se aproxima de 0,95. O AP50 é 0,9956, enquanto o AP95 é 0,7192. Esse comportamento indica que a correspondência geral das instâncias é mantida na maior parte das vistas, mas diferenças de contorno e pequenas regiões passam a afetar a métrica no limiar mais estrito. Como o protocolo fornece máscaras 2D durante o treinamento, os valores não demonstram descoberta de instâncias sem supervisão.

A Figura 3 compara os mapas de referência e predição nas mesmas quatro vistas. A terceira linha marca em magenta os pixels cujo ID difere entre os dois mapas, evidenciando que as discordâncias se concentram nas fronteiras e em estruturas pequenas.

(a) IDs de referência



(b) IDs preditos pelo DM-NeRF



(c) Pixels com IDs divergentes



Figura 3: Decomposição de instâncias nas vistas 0, 33, 66 e 99. Em (a) e (b), as cores identificam IDs, não classes semânticas; em (c), magenta indica divergência entre referência e predição.

5.4 Geometria extraída (A0)

A malha A0 final contém 356.272 vértices e 710.928 faces. A comparação visual com a referência DM-SR e o COLMAP aparece na Figura 4, sem repetir o mesmo enquadramento em uma figura isolada. A estrutura global da sala e dos objetos principais é reconhecível, mas a visualização também mostra regiões ruidosas e superfícies que não formam volumes fechados.

A Tabela 6 apresenta as distâncias médias e RMSE. As duas direções têm valores próximos: 4,34 cm da predição para a referência e 4,14 cm da referência para a predição.

Tabela 6: Distâncias entre A0 e a referência DM-SR.

Medida	**Valor**
Média predição → referência	4,335 cm
Média referência → predição	4,139 cm
Distância simétrica L1	8,474 cm
RMSE predição → referência	5,757 cm
RMSE referência → predição	4,940 cm

Os resultados por limiar são apresentados na Tabela 7. Precision mede a fração da reconstrução situada perto da referência; Completeness mede a fração da referência coberta pela reconstrução; e o F-score combina as duas medidas. Valores maiores são melhores. A 1 cm, somente cerca de 5% dos pontos em cada direção encontram correspondência dentro do limiar. A 5 cm, Precision e Completeness passam de 0,75 e o F-score chega a 0,7750. Assim, a reconstrução representa melhor a estrutura quando se admite tolerância de 5 cm, sem sustentar coincidência fina em 1 cm.

Tabela 7: Precision, Completeness e F-score da geometria A0.

Limiar	**Precision**	**Completeness**	**F-score**
1 cm	0,04887	0,04724	0,04804
2 cm	0,20977	0,18398	0,19603
5 cm	0,79630	0,75478	0,77498

5.5 Baseline geométrico externo: COLMAP

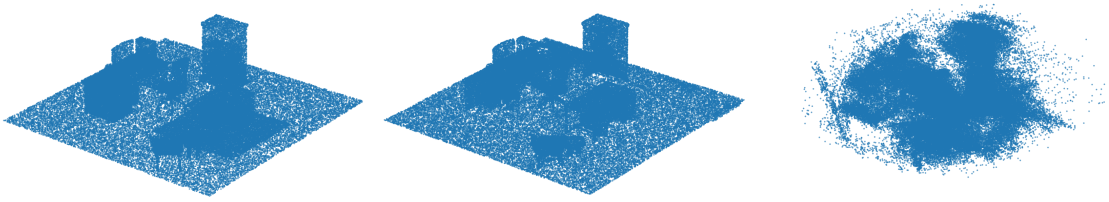
O baseline COLMAP concluiu o PatchMatch e a fusão densa para as 300 vistas de treinamento, produzindo 5.800.316 pontos. Após a conversão para o sistema de coordenadas da malha e a restrição ao mesmo volume orientado empregado pelo meshing do DM-NeRF, 3.416.962 pontos permaneceram no suporte comum. A comparação usa uma amostra determinística de 200.000 pontos dessa nuvem, de modo a manter a mesma cardinalidade de A0 e da referência.

A Tabela 8 compara as duas reconstruções. A0 apresenta menor erro nas duas direções. A distância média da predição para a referência é 4,34 cm em A0 e 20,42 cm no COLMAP; no sentido referência para predição, os valores são 4,14 cm e 8,13 cm. A diferença entre as direções no COLMAP indica que parte relevante da superfície de referência possui pontos próximos, mas a nuvem contém espessamento e pontos afastados da superfície correta.

Tabela 8: Comparação geométrica entre A0 e o baseline COLMAP no mesmo suporte e com 200.000 pontos por conjunto.

Medida	**DM-NeRF A0**	**COLMAP**
Média predição → referência	4,335 cm	20,418 cm
Média referência → predição	4,139 cm	8,129 cm
Distância simétrica L1	8,474 cm	28,547 cm
RMSE predição → referência	5,757 cm	30,079 cm
RMSE referência → predição	4,940 cm	13,942 cm
F-score a 1 cm	0,0480	0,0285
F-score a 2 cm	0,1960	0,1288
F-score a 5 cm	0,7750	0,3721

A decomposição de Precision e Completeness ajuda a interpretar a diferença a 5 cm: A0 obtém 0,7963 e 0,7548, respectivamente, enquanto o COLMAP obtém 0,2710 e 0,5936. Assim, o baseline recupera regiões próximas de grande parte da referência, mas com proporção maior de pontos fora da tolerância. A Figura 4 mostra a referência, A0 e COLMAP no mesmo enquadramento, e a Figura 5 resume os F-scores.



(a) Referência DM-SR (b) DM-NeRF A0 (c) COLMAP

Figura 4: Comparação qualitativa da geometria no mesmo sistema de coordenadas, suporte e enquadramento. A nuvem COLMAP apresenta maior dispersão e superfícies mais espessas.

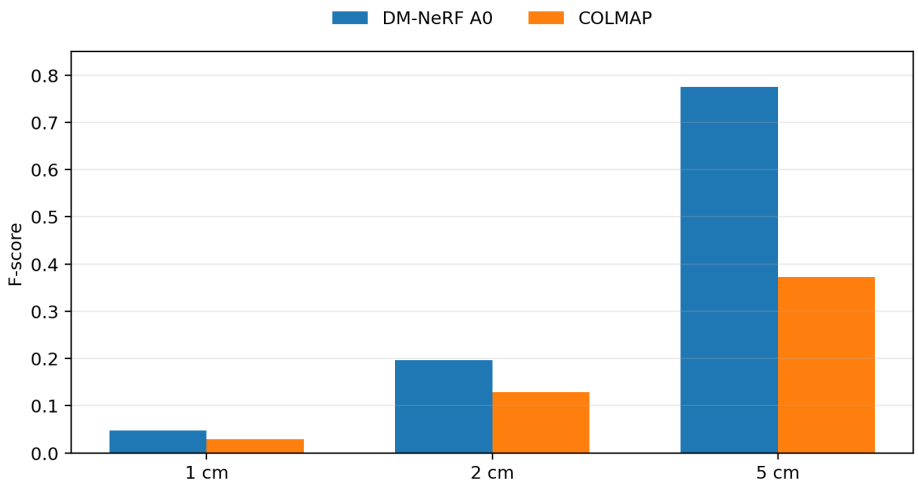


Figura 5: F-score geométrico de A0 e COLMAP nos limiares de 1, 2 e 5 cm.

5.6 Separação estrutural (A1)

A separação identificou 13 instâncias com faces homogêneas. Das 710.928 faces da malha original, 681.383 foram atribuídas a uma instância, enquanto 29.545 foram registradas como faces de fronteira. A cobertura resultante é 95,844%; nesse indicador, valores maiores representam maior preservação da topologia nas malhas individuais. A cobertura não mede estanqueidade nem corrige erros geométricos da malha de origem.

Tabela 9: Resumo da separação A1.

Instâncias exportadas	13
Faces da malha A0	710.928
Faces homogêneas exportadas	681.383
Faces de fronteira	29.545
Cobertura de faces homogêneas	95,844%

A Figura 6 utiliza as cores armazenadas em `mesh_instances.ply` apenas para distinguir visualmente as instâncias. A identidade empregada no processamento vem do vetor de IDs, não da cor.



Figura 6: Visualização da reconstrução colorida por instância em dois pontos de vista. As cores são usadas somente para distinguir IDs.

A individualização também foi verificada nos arquivos exportados por instância. Fragmentos e fronteiras permanecem visíveis em alguns objetos; por essa razão, a Figura 6 apresenta a cena completa colorida por ID, e a Figura 8 mostra posteriormente cada entidade carregada separadamente no Gazebo.

5.7 Seleção e regularização do piso

A heurística geométrica selecionou a instância 10. Ela foi a única instância a satisfazer simultaneamente os critérios de área, orientação, planaridade e altura. A instância 9 também apresenta grande fração horizontal e baixa altura, mas seu RMSE de 3,23 cm excede o limite de 3 cm definido antes da execução final. A seleção identifica um candidato geométrico e não constitui rótulo semântico de piso fornecido pelo DM-SR.

No RANSAC aplicado à instância selecionada, 77,11% dos vértices ficaram a até 2 cm do plano estimado. Antes da projeção, a distância absoluta média era 2,051 cm, o RMSE era 5,722 cm e o P95 era 6,800 cm. O maior residual chegou a 1,64 m, indicando a presença de vértices associados ao mesmo ID afastados do plano principal. Esse valor não foi removido da análise.

A projeção de A2 leva os vértices selecionados ao plano, reduzindo média, RMSE e P95 a erro numérico. Esse resultado é consequência direta da operação e deve ser interpretado como alteração de planaridade, não como demonstração de que a reconstrução inteira se tornou geometricamente mais fiel.

Tabela 10: Métricas da instância 10 antes e depois da regularização.

Medida	**A1**	**A2**
Média absoluta	2,051 cm	$< 10^{-12}$ cm
RMSE	5,722 cm	$< 10^{-12}$ cm
P95	6,800 cm	$< 10^{-12}$ cm
Fração de inliers (2 cm)	77,11%	100%

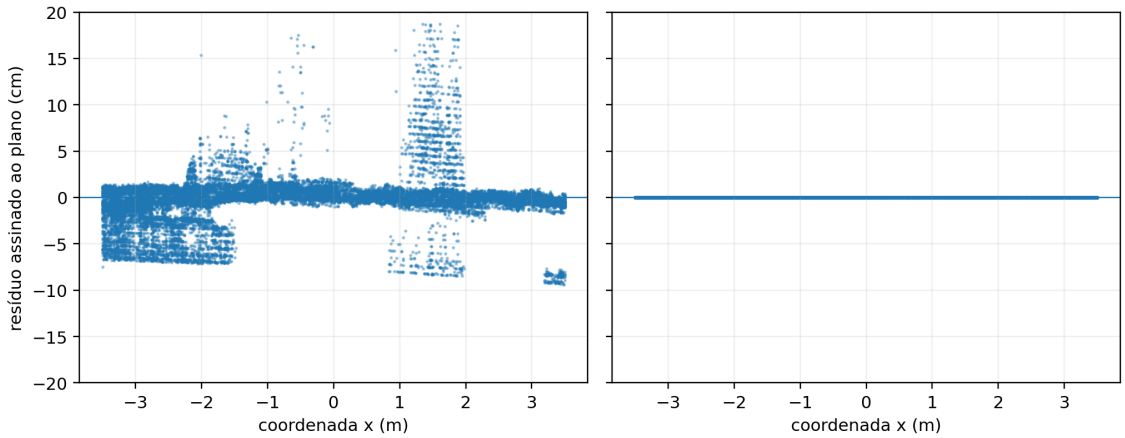


Figura 7: Resíduo assinado ao plano da instância 10 antes e depois da regularização. À esquerda, A1; à direita, A2. O eixo vertical é limitado a ± 20 cm para leitura da distribuição principal; o residual máximo de A1, 1,64 m, permanece reportado no texto e nas métricas.

5.8 Integração no Gazebo Classic

A validação G0 passou para as três condições. A0 gerou um modelo correspondente à malha completa; A1 e A2 geraram 13 modelos independentes, com caminhos relativos para os arquivos de malha e correspondência entre os elementos visuais e de colisão.

Os testes de execução foram realizados no Gazebo Classic 11.10.2. Em G1, os mundos A0, A1 e A2 foram carregados e permaneceram ativos durante a janela de verificação. Foram observados apenas avisos relativos à aparência visual padrão, sem erros de carregamento das geometrias usadas nos testes.

Em G2, a instância `instance_006` da condição A1 foi deslocada em 0,25 m no eixo x por meio da interface do Gazebo. A pose consultada antes da operação era $(0, 0, 0)$ m e, após o comando, a coordenada x passou para 0,25 m. A operação foi dirigida somente a esse modelo, demonstrando que a separação de A1 foi materializada em entidades endereçáveis de forma independente no simulador.

O teste G3 utilizou uma caixa dinâmica de 10 cm de lado e massa de 0,2 kg, posicionada com centro em $z = 0,65$ m sobre uma região do candidato a piso regularizado. A primeira pose foi registrada seis segundos após o início da simulação, já depois da queda. Nesse instante, o centro da caixa estava em $z = 0,093811$ m; oito segundos depois, estava em $z = 0,093806$ m, variação de aproximadamente 5 μm.

Considerando metade da altura da caixa, sua face inferior permaneceu em $z = 0,043806$ m. A altura calculada do plano regularizado no ponto $(x, y) = (3,07411, -3,31338)$ m, após a rotação comum de +Y para +Z usada na exportação, é $z = 0,043810$ m. A diferença de aproximadamente 4 μm expressa a concordância numérica entre a pose registrada da face inferior da caixa e a altura calculada do plano no mesmo ponto, não uma medida de precisão física micrométrica do Gazebo. A caixa caiu aproximadamente 0,56 m, encontrou a superfície, não a atravessou no ponto ensaiado e permaneceu estável durante a segunda janela de observação; por esses critérios, G3 foi aprovado.

Tabela 11: Resultado das verificações de integração com o Gazebo Classic.

Verificação	**A0**	**A1**	**A2**
G0 – validação estática	passou	passou	passou
G1 – carregamento no Gazebo	passou	passou	passou
G2 – manipulação independente	–	passou	–
G3 – apoio/colisão do piso	–	–	passou

Para tornar a individualização visualmente verificável, a mesma cena A2 foi aberta com materiais de visualização distintos por instância. Essa alteração não modifica poses, geometrias de colisão nem os resultados G1–G3. A Figura 8 mostra as entidades separadas no simulador; a caixa vermelha no canto superior esquerdo corresponde ao corpo dinâmico usado no ensaio G3.

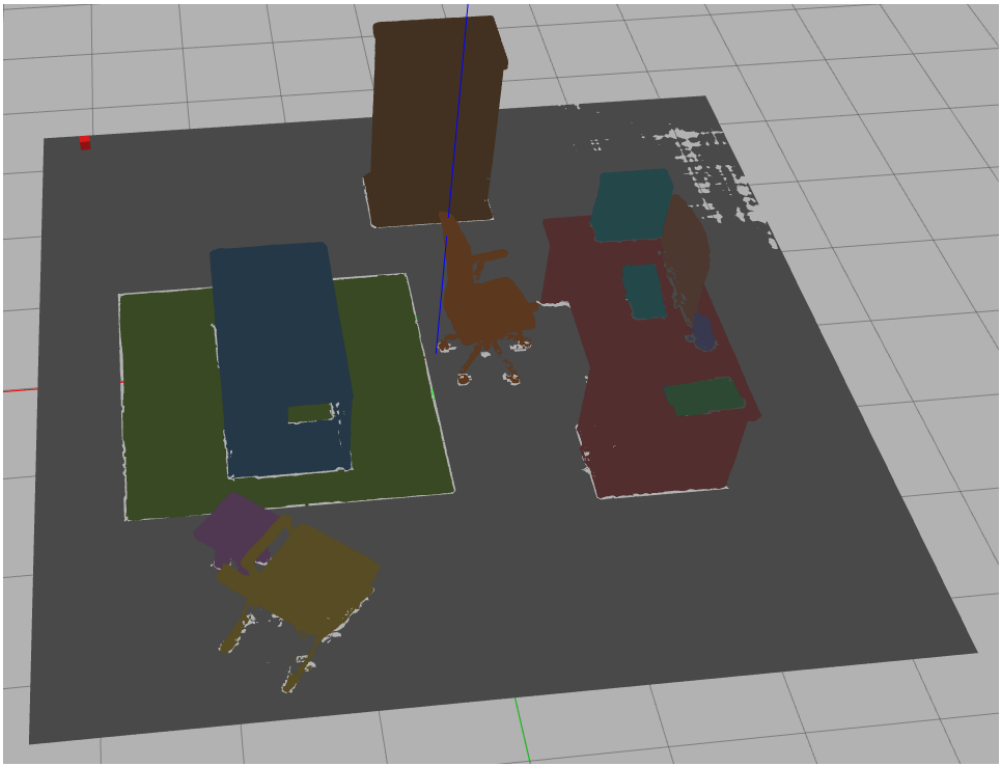


Figura 8: Cena A2 no Gazebo Classic com materiais visuais distintos por instância. As cores foram adicionadas somente para interpretação da figura; a geometria e as colisões são as mesmas usadas nos testes funcionais.

6 DISCUSSÃO

Os resultados situam a dissertação entre dois grupos de trabalhos que normalmente são avaliados por critérios diferentes. De um lado, reconstruções neurais e métodos panópticos procuram sintetizar vistas, estimar superfícies ou manter identidades de objetos. De outro, sistemas de geração de ambientes para robótica precisam produzir entidades explícitas, colisões e relações que possam ser alteradas pelo simulador. A cadeia estudada não substitui esses grupos por uma nova arquitetura; ela examina a passagem entre eles. O DM-NeRF fornece aparência e IDs de instância em um campo neural, enquanto o pós-processamento converte essa saída em malha, objetos independentes, superfície de apoio tratada e modelos carregáveis no Gazebo.

Essa passagem não pode ser julgada apenas pelas métricas de imagem. O PSNR de 41,1100 dB, o SSIM de 0,9875 e o LPIPS de 0,0260 mostram que as vistas sintetizadas se aproximam das referências segundo medidas de erro, estrutura e percepção. Os valores também são próximos aos publicados por Wang et al. [10] para a mesma cena. Apesar disso, o F-score geométrico da malha é 0,0480 a 1 cm e 0,7750 a 5 cm. A diferença entre os limiares mostra que boa síntese visual não implica coincidência centimétrica da superfície: erros de profundidade ou espessura podem ter pequeno efeito na imagem renderizada e grande efeito na correspondência tridimensional. Para a robótica, essa distinção importa porque contato e colisão dependem da posição da superfície, e não apenas da aparência projetada.

Os resultados de AP acrescentam outra dimensão. A redução de 0,9956 em AP50 para 0,7192 em AP95 indica que as instâncias são reconhecidas na maior parte das vistas, mas diferenças de contorno tornam-se relevantes quando a sobreposição exigida é quase total. Esse comportamento é compatível com a concentração das discordâncias nas fronteiras observada na comparação qualitativa. Como as máscaras 2D são fornecidas no treinamento, o resultado mede a reconstrução e a consistência da decomposição no protocolo DM-SR; não mede descoberta de objetos sem supervisão.

Kundu et al. [4], Siddiqui et al. [8] e Wu et al. [13] tratam problemas que esta dissertação não procura resolver. Panoptic Neural Fields mantém uma representação neural orientada a objetos; Panoptic Lifting consolida informação panóptica entre vistas; e

PanoRecon integra reconstrução monocular online com instâncias persistentes. Esses trabalhos ampliam a compreensão tridimensional da cena e, no caso de PanoRecon, tratam operação em tempo real. A presente cadeia parte de uma decomposição já produzida pelo DM-NeRF e concentra-se no passo posterior: associar IDs à topologia extraída, separar os componentes e fornecer uma estrutura consumível pelo simulador. Sua contribuição específica é, portanto, a materialização e a avaliação desse percurso, e não um novo método de segmentação panóptica.

A relação com URDFormer, DRAWER e GRS esclarece outra escolha. Chen et al. [2] inferem hierarquias e articulações e produzem descrições URDF; Xia et al. [14] combinam reconstrução e articulação de ambientes interativos; Zook et al. [18] recuperam ativos para compor tarefas de simulação. Essas abordagens privilegiam estrutura cinemática ou análogos funcionais formados por modelos previamente disponíveis. Aqui, a geometria observada permanece como fonte dos modelos exportados. Essa opção preserva a forma reconstruída e permite estudar seus erros, mas não fornece automaticamente juntas, massa, inércia ou materiais. Assim, reconstruir uma superfície e substituir objetos por ativos CAD são estratégias complementares: a primeira preserva particularidades da cena observada; a segunda pode fornecer geometria fechada e propriedades funcionais, ao custo de substituir o exemplar capturado. A dissertação avalia a primeira estratégia.

O COLMAP ocupa um papel deliberadamente restrito nessa análise. Ele fornece um baseline externo para a geometria densa porque reconstrói superfícies por correspondência multivista sem usar o campo neural. Não oferece, na configuração executada, decomposição de instâncias, associação semântica ou integração com o Gazebo; por isso, não seria correto compará-lo às condições A1 e A2 nem aos testes G0–G3. No mesmo suporte espacial e com amostras de igual cardinalidade, A0 obteve menor distância e maior F-score nos três limiares. Esse resultado descreve a cena *study*, as poses fornecidas e as configurações fixadas. Não estabelece superioridade geral do DM-NeRF sobre reconstrução fotogramétrica, sobretudo porque não houve otimização do COLMAP por cena e o volume de avaliação deriva do procedimento de meshing do DM-NeRF.

A condição A1 mostra o efeito estrutural que não aparece nas métricas de imagem ou de superfície. O processamento gerou 13 modelos e atribuiu 95,844% das faces a instâncias com rótulos homogêneos. As 29.545 faces restantes foram registradas como fronteiras em vez de serem atribuídas arbitrariamente. Com isso, a identidade deixa de ser somente um valor consultado no campo neural e passa a determinar arquivos e entidades que podem ser endereçados separadamente. O deslocamento isolado de uma instância no Gazebo confirma essa propriedade operacional. Ele não demonstra articulação nem comportamento físico do objeto, mas verifica que a organização da cena sobreviveu à exportação.

O tratamento da superfície de apoio ilustra por que a cadeia mede cada transformação separadamente. Na ausência de classe semântica oficial para o piso, a instância 10 foi

selecionada por área, orientação, altura e planaridade. A regularização reduziu os resíduos ao plano porque projeta os vértices sobre esse próprio plano; logo, o resultado quantifica a transformação aplicada, e não uma melhora automática da fidelidade global. O ensaio G3 acrescenta a consequência funcional: no ponto testado, a caixa caiu, encontrou a superfície, não a atravessou e permaneceu estável. A concordância numérica entre a face inferior da caixa e o plano serve para verificar a consistência do referencial naquele ponto, não a precisão física do simulador em toda a superfície.

O tempo de aproximadamente 30 h 58 min para treinar uma cena coloca o método no regime de preparação offline de ambientes. Essa característica é compatível com a criação prévia de cenários de teste, mas não com reconstrução durante uma tarefa robótica. O custo também ajuda a separar o objetivo deste trabalho de métodos online como PanoRecon: a questão investigada não é a atualização contínua do mapa, mas a conversão de uma reconstrução concluída em uma cena estruturada.

Em síntese, a contribuição científica está na decomposição do problema em transições mensuráveis. A avaliação neural verifica aparência e instâncias nas vistas; a avaliação de A0 mede a superfície e a compara ao COLMAP; A1 mede a preservação da topologia ao individualizar objetos; A2 mede a alteração do candidato a piso; e G0–G3 verificam se os artefatos resultantes formam uma cena carregável, editável e com contato no ponto ensaiado. Essa organização permite localizar tanto os ganhos quanto as perdas em cada etapa, sem inferir simulabilidade a partir de uma única métrica.

6.1 Validade e alcance

O estudo adota a cena *study* como estudo de caso controlado, mantendo fixos o conjunto de dados, as entradas e o protocolo de avaliação. As máscaras de instância são fornecidas ao DM-NeRF, e o volume do meshing depende da caixa orientada da referência DM-SR. O COLMAP recebeu as poses oficiais e uma configuração fixa, sem otimização específica por cena. As malhas individuais podem permanecer abertas nas fronteiras removidas, e a superfície de apoio foi escolhida por geometria, sem rótulo semântico de piso. A planarização de A2 decorre da operação de projeção, enquanto G3 verifica um único ponto. Massa, atrito, inércia e articulações não foram inferidos.

Dentro desses limites, o experimento demonstra que a reconstrução da cena estudada pode ser convertida em 13 entidades independentes, preservando a maior parte das faces, e carregada no Gazebo com manipulação individual e contato estável no local ensaiado. Também quantifica, no mesmo protocolo, a qualidade visual, a correspondência geométrica e o efeito das transformações estruturais, sem estender essas conclusões a outras cenas ou a propriedades físicas não observadas.

7 CONCLUSÃO

Esta dissertação avaliou a transformação de uma reconstrução neural com decomposição de instâncias em uma representação explícita e estruturada para simulação robótica. A cadeia manteve o DM-NeRF como método neural e reuniu extração geométrica, individualização dos elementos, regularização de uma superfície de apoio e integração com o Gazebo Classic.

Na cena *study*, a avaliação oficial em 100 vistas obteve PSNR de 41,1100 dB, SSIM de 0,9875 e LPIPS de 0,0260. A decomposição apresentou AP50 de 0,9956 e AP95 de 0,7192. A malha extraída atingiu F-score de 0,0480 a 1 cm, 0,1960 a 2 cm e 0,7750 a 5 cm, evidenciando a diferença entre qualidade de síntese e correspondência geométrica. No mesmo suporte, o COLMAP obteve 0,0285, 0,1288 e 0,3721 nesses limiares.

A separação estrutural gerou 13 objetos, preservou 95,844% das faces homogêneas e registrou 29.545 faces de fronteira. A regra geométrica selecionou a instância 10 como superfície de apoio, e sua regularização reduziu o P95 do residual ao plano de 6,80 cm para erro numérico. No Gazebo Classic, as três condições foram carregadas, uma instância foi manipulada separadamente e a superfície regularizada sustentou o corpo dinâmico no ponto ensaiado.

Quanto à questão de pesquisa, os resultados mostram em que medida a conversão foi alcançada: para a cena *study* e o protocolo adotado, o pós-processamento transformou a saída do DM-NeRF em geometria explícita, objetos independentes e uma cena executável no simulador. A qualidade visual não garantiu precisão geométrica fina, e o funcionamento verificado restringe-se a carregamento, manipulação individual e contato pontual. A contribuição do trabalho está em avaliar separadamente as etapas que levam da saída neural à cena de simulação, relacionando medidas de aparência, geometria, estrutura dos objetos e funcionamento no simulador.

REFERÊNCIAS

[1] Bhalgat, Y., Laina, I., Henriques, J. F., Vedaldi, A., and Zisserman, A. (2023). Contrastive lift: 3d object instance segmentation by slow-fast contrastive fusion. In *Advances in Neural Information Processing Systems*.

[2] Chen, Z. Q., Walsman, A., Memmel, M., Mo, K., Fang, A., Fox, D., and Gupta, A. (2024). URDFormer: A pipeline for constructing articulated simulation environments from real-world images. In *Robotics: Science and Systems*.

[3] Fischler, M. A. and Bolles, R. C. (1981). Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography. *Communications of the ACM*, 24(6):381–395.

[4] Kundu, A., Genova, K., Yin, X., Fathi, A., Pantofaru, C., Guibas, L., Tagliasacchi, A., Dellaert, F., and Funkhouser, T. (2022). Panoptic neural fields: A semantic object-aware neural scene representation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.

[5] Lemos, J. F. d. S. S., Dorneles, G. A., Maurell, I. P., Brião, S. L., Guerra, R. d. S., and Drews Junior, P. L. J. (2025). Digital environment description and reconstruction using panoptic segmentation. In *RoboCup 2024: Robot World Cup XXVII*, volume 15570 of *Lecture Notes in Computer Science*, pages 236–246. Springer.

[6] Mildenhall, B., Srinivasan, P. P., Tancik, M., Barron, J. T., Ramamoorthi, R., and Ng, R. (2020). NeRF: Representing scenes as neural radiance fields for view synthesis. In *European Conference on Computer Vision*.

[7] Schönberger, J. L., Zheng, E., Frahm, J.-M., and Pollefeys, M. (2016). Pixelwise view selection for unstructured multi-view stereo. In *European Conference on Computer Vision*, pages 501–518.

[8] Siddiqui, Y., Porzi, L., Rota Bulò, S., Müller, N., Niessner, M., Dai, A., and Kontschieder, P. (2023). Panoptic lifting for 3d scene understanding with neural fields.

In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9043–9052.

[9] Sucar, E., Liu, S., Ortiz, J., and Davison, A. J. (2021). imap: Implicit mapping and positioning in real-time. In *IEEE/CVF International Conference on Computer Vision*.

[10] Wang, B., Chen, L., and Yang, B. (2023). DM-NeRF: 3d scene geometry decomposition and manipulation from 2d images. In *International Conference on Learning Representations*.

[11] Wang, P., Liu, L., Liu, Y., Theobalt, C., Komura, T., and Wang, W. (2021). NeuS: Learning neural implicit surfaces by volume rendering for multi-view reconstruction. In *Advances in Neural Information Processing Systems*.

[12] Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612.

[13] Wu, D., Yan, Z., and Zha, H. (2024). PanoRecon: Real-time panoptic 3d reconstruction from monocular video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21507–21518.

[14] Xia, H., Su, E., Memmel, M., Jain, A., Yu, R., Mbiziwo-Tiapo, N., Farhadi, A., Gupta, A., Wang, S., and Ma, W.-C. (2025). DRAWER: Digital reconstruction and articulation with environment realism. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21771–21782.

[15] Yariv, L., Gu, J., Kasten, Y., and Lipman, Y. (2021). Volume rendering of neural implicit surfaces. In *Advances in Neural Information Processing Systems*.

[16] Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. (2018). The unreasonable effectiveness of deep features as a perceptual metric. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 586–595.

[17] Zhu, Z., Peng, S., Larsson, V., Xu, W., Bao, H., Cui, Z., Oswald, M. R., and Pollefeys, M. (2022). NICE-SLAM: Neural implicit scalable encoding for slam. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.

[18] Zook, A., Sun, F.-Y., Spjut, J., Blukis, V., Birchfield, S., and Tremblay, J. (2025). GRS: Generating robotic simulation tasks from real-world images. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 594–603.