



UNIVERSIDADE FEDERAL DO RIO GRANDE - FURG
CENTRO DE CIÊNCIAS COMPUTACIONAIS
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO
CURSO DE MESTRADO EM ENGENHARIA DE COMPUTAÇÃO

Dissertação de Mestrado

Reconstrução Semântica Automatizada de Ambientes Domésticos para Simulação de Robôs

João Francisco de Souza Santos Lemos

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Computação da Universidade Federal do Rio Grande - FURG, como requisito parcial para a obtenção do grau de Mestre em Engenharia de Computação

Orientador: Nelson Lopes Duarte Filho
Co-orientador: Rodrigo da Silva Guerra

Rio Grande, 2026

RESUMO

A partir de imagens obtidas em diferentes posições, métodos baseados em campos neurais aprendem uma representação tridimensional capaz de gerar novas vistas da cena. Essa representação reduz a necessidade de modelar manualmente a aparência do ambiente, mas não entrega diretamente os objetos separados e as geometrias de colisão exigidos pelo Gazebo Classic. Esta dissertação avalia uma cadeia que parte do DM-NeRF e converte sua saída em uma cena estruturada para simulação. O DM-NeRF também realiza decomposição de instâncias: atribui identificadores distintos aos objetos individuais, permitindo diferenciá-los mesmo quando pertencem à mesma categoria. O estudo utiliza a cena *study* do DM-SR, conjunto sintético de ambientes internos que fornece imagens RGB, poses de câmera, rótulos de instância por pixel e geometria tridimensional de referência. A avaliação separa aparência, identificação de instâncias, geometria, organização dos objetos e funcionamento no simulador. Em 100 vistas de teste, foram obtidos PSNR de 41,1100 dB, SSIM de 0,9875 e LPIPS de 0,0260. Na avaliação geométrica, o F-score da malha variou de 0,0480, a 1 cm, a 0,7750, a 5 cm; no mesmo suporte, o COLMAP obteve 0,0285 e 0,3721. Na cena avaliada, a cadeia produziu 13 modelos independentes, tratou geometricamente a superfície de apoio e gerou uma cena executável no Gazebo, enquanto a avaliação geométrica mostrou forte dependência do limiar de distância.

Palavras-chave: Reconstrução neural, simulação robótica, geometria tridimensional, DM-NeRF.

ABSTRACT

LEMOS, João Francisco de Souza Santos. **Automated Semantic Reconstruction of Domestic Environments for Robot Simulation**. 2026. 44 f. Dissertação (Mestrado) – Programa de Pós-Graduação em Computação. Universidade Federal do Rio Grande - FURG, Rio Grande.

From images captured at different positions, neural-field methods learn a three-dimensional scene representation that can generate novel views. This representation reduces the need to model the scene appearance manually, but it does not directly provide the separate objects and collision geometries required by Gazebo Classic. This dissertation evaluates a pipeline that starts from DM-NeRF and converts its output into a structured scene for simulation. DM-NeRF also performs instance decomposition: it assigns distinct identifiers to individual objects so that they can be distinguished even when they belong to the same category. The study uses the DM-SR *study* scene. DM-SR is a synthetic indoor-scene dataset that provides RGB images, camera poses, per-pixel instance labels, and three-dimensional reference geometry. The evaluation separates appearance, instance identification, geometry, object organization, and simulator operation. On 100 test views, the reconstruction achieved 41.1100 dB PSNR, 0.9875 SSIM, and 0.0260 LPIPS. In the geometric evaluation, the mesh F-score ranged from 0.0480 at 1 cm to 0.7750 at 5 cm; on the same spatial support, COLMAP achieved 0.0285 and 0.3721. In the evaluated scene, the pipeline produced 13 independent models, treated the support surface geometrically, and generated an executable Gazebo scene, while the geometric evaluation showed a strong dependence on the distance threshold.

Keywords: neural reconstruction, robot simulation, 3D geometry, DM-NeRF.

LISTA DE FIGURAS

Figura 1 Cadeia metodológica entre as observações do DM-SR e a cena no Gazebo Classic, com as medidas empregadas em cada etapa. 18

Figura 2 Vista RGB de referência da cena *study*, usada como estudo de caso. A cena contém duas mesas, assentos, armário e objetos menores; esses elementos aparecem posteriormente na avaliação da síntese, da geometria e da separação por instâncias. Fonte: material oficial do DM-NeRF/DM-SR [10]. 23

Figura 3 Síntese de vistas nas posições 0, 33, 66 e 99. A ampliação da diferença em (c) torna visíveis discrepâncias locais sem alterar as imagens comparadas. 30

Figura 4 Decomposição de instâncias nas vistas 0, 33, 66 e 99. Em (a) e (b), as cores identificam IDs, não classes semânticas; em (c), magenta indica divergência entre referência e predição. 31

Figura 5 Comparação qualitativa da geometria no mesmo sistema de coordenadas, suporte e enquadramento. A nuvem COLMAP apresenta maior dispersão e superfícies mais espessas. 33

Figura 6 F-score geométrico de A0 e COLMAP nos limiares de 1, 2 e 5 cm. . . 34

Figura 7 Visualização da reconstrução colorida por instância em dois pontos de vista. As cores são usadas somente para distinguir IDs. 35

Figura 8 Resíduo assinado ao plano da instância 10 antes e depois da regularização. À esquerda, A1; à direita, A2. O eixo vertical é limitado a ± 20 cm para leitura da distribuição principal; o residual máximo de A1, 1,64 m, permanece reportado no texto e nas métricas. 36

Figura 9 Cena A2 no Gazebo Classic com materiais visuais distintos por instância. As cores foram adicionadas somente para interpretação da figura; a geometria e as colisões são as mesmas usadas nos testes funcionais. 38

LISTA DE TABELAS

Tabela 1 Comparação qualitativa entre trabalhos relacionados e a cadeia desta dissertação. 16

Tabela 2 Etapas da cadeia e medidas utilizadas. 19

Tabela 3 Resumo da execução final. 28
Tabela 4 Métricas do avaliador oficial na cena *study*. 29
Tabela 5 Comparação entre a reprodução desta dissertação e os resultados publicados para a cena *study* do DM-SR. 29
Tabela 6 Distâncias entre A0 e a referência DM-SR. 32
Tabela 7 Precision, Completeness e F-score da geometria A0. 32
Tabela 8 Comparação geométrica entre A0 e o baseline COLMAP no mesmo suporte e com 200.000 pontos por conjunto. 33
Tabela 9 Resumo da separação A1. 34
Tabela 10 Métricas da instância 10 antes e depois da regularização. 36
Tabela 11 Resultado das verificações de integração com o Gazebo Classic. . . . 37

LISTA DE ABREVIATURAS E SIGLAS

AMP	Automatic Mixed Precision
AP	Average Precision
DM-NeRF	3D Scene Geometry Decomposition and Manipulation from 2D Images
DM-SR	conjunto de dados utilizado pelo protocolo do DM-NeRF
GT	Ground Truth
IoU	Intersection over Union
LPIPS	Learned Perceptual Image Patch Similarity
MVS	Multi-View Stereo
NeRF	Neural Radiance Field
PSNR	Peak Signal-to-Noise Ratio
RANSAC	Random Sample Consensus
RMSE	Root Mean Squared Error
SDFormat	Simulation Description Format
SSIM	Structural Similarity Index Measure
URDF	Unified Robot Description Format

SUMÁRIO

1 Introdução **9**
1.1 Problema de pesquisa 10
1.2 Objetivos 11
1.3 Delimitação e contribuição 11

2 Fundamentação e trabalhos relacionados **13**
2.1 Representações neurais de cenas e superfícies 13
2.2 Estrutura de objetos e reconstrução panóptica 13
2.3 Geração de ambientes para simulação 14
2.4 Comparação por características 15

3 Metodologia **17**
3.1 Visão geral 17
3.2 Conjunto de dados DM-SR 19
3.3 Treinamento e avaliação do DM-NeRF 20
3.4 Extração da malha e verificações de consistência 20
3.5 Separação estrutural (A1) 20
3.6 Seleção geométrica do piso 21
3.7 Regularização do piso (A2) 21
3.8 Exportação para Gazebo Classic 21

4 Protocolo experimental **23**
4.1 Unidade experimental e proveniência 23
4.2 Condições de ablação A0, A1 e A2 24
4.3 Síntese de vistas e decomposição 24
4.4 Avaliação geométrica 25
4.5 Baseline geométrico externo 25
4.6 Avaliação da separação e do piso 26
4.7 Validação funcional 26
4.8 Custo computacional 27

5 Resultados **28**
5.1 Treinamento e custo computacional 28
5.2 Síntese de vistas 29
5.2.1 Comparação com os resultados publicados do DM-NeRF 29
5.3 Decomposição de instâncias 30
5.4 Geometria extraída (A0) 31

5.5 Baseline geométrico externo: COLMAP 32
5.6 Separação estrutural (A1) 34
5.7 Seleção e regularização do piso 35
5.8 Integração no Gazebo Classic 36

6 Discussão **39**
6.1 Validade e alcance 41

7 Conclusão **42**

Referências **43**

1 INTRODUÇÃO

A construção de ambientes virtuais para robótica não termina quando uma cena reconstruída produz imagens semelhantes às observações originais. Uma reconstrução pode representar corretamente cores, contornos e iluminação nos pontos de vista avaliados e, ainda assim, posicionar uma superfície alguns centímetros distante de sua posição de referência. Essa diferença tem efeito direto quando o simulador calcula o contato de uma roda, de uma caixa ou de um robô com o ambiente.

A organização da geometria também é necessária. Se uma mesa, uma cadeira e o piso permanecem unidos em uma única malha, o simulador consegue exibir o conjunto, mas não consegue deslocar somente a cadeira sem processamento adicional. Uma superfície que se parece com um piso nas imagens pode conter ondulações ou vértices isolados que alteram as colisões. Portanto, produzir novas imagens, reconstruir a superfície e organizar a cena em objetos utilizáveis pelo Gazebo são problemas relacionados, porém distintos.

Os campos de radiância neurais, introduzidos por Mildenhall et al. [6], aprendem essa representação a partir de imagens e das posições e orientações das câmeras. Durante o treinamento, uma rede relaciona pontos do espaço às cores e à ocupação observadas nas imagens. Depois do treinamento, a representação pode ser consultada a partir de uma nova câmera para gerar uma imagem do ambiente. Esse processo reduz a modelagem manual da aparência, mas sua saída continua sendo uma função aprendida, e não um conjunto de modelos separados com geometrias visuais e de colisão.

O DM-NeRF [10] acrescenta a essa representação a identificação das instâncias. Uma instância corresponde a um objeto individual: duas cadeiras, por exemplo, recebem identificadores diferentes mesmo que pertençam à mesma categoria. No protocolo DM-SR utilizado nesta dissertação, o treinamento recebe imagens RGB, poses de câmera e mapas bidimensionais de instância. Cada pixel desses mapas contém um rótulo que informa qual objeto aparece naquela posição da imagem. As máscaras são fornecidas ao treinamento; portanto, a avaliação não mede descoberta de objetos sem supervisão.

O DM-NeRF representa a cena e permite consultar, em cada posição do espaço, tanto informações de aparência quanto a identidade de instância. Para chegar ao Gazebo, ainda é preciso converter essa representação em uma malha triangular, associar os identifica-

dores aos seus vértices e separar os triângulos em arquivos de objetos independentes. Também é preciso identificar uma superfície de apoio, tratar sua geometria quando ela satisfaz os critérios definidos e criar uma descrição de cena compatível com o simulador.

A dissertação examina essa passagem da representação aprendida pelo DM-NeRF para uma cena explícita, organizada em objetos independentes e utilizável no Gazebo Classic. A cadeia estudada compreende: (1) a reprodução do DM-NeRF na cena *study* do DM-SR; (2) a extração de uma malha; (3) a associação explícita dos identificadores de instância aos vértices; (4) a separação dos objetos; (5) a identificação geométrica de um candidato a piso; (6) a regularização condicionada dessa superfície; e (7) a exportação para Gazebo Classic. O SDFormat é empregado para descrever os modelos e o mundo carregado pelo simulador.

1.1 Problema de pesquisa

Simuladores como o Gazebo precisam que os elementos da cena sejam definidos individualmente, com geometria, posição e propriedades de colisão. Uma mesa, por exemplo, precisa corresponder a um modelo identificável para que sua pose possa ser consultada ou alterada sem mover o restante do ambiente. Quando toda a reconstrução forma uma única malha, essa operação não é possível diretamente.

Há ainda uma diferença entre aparência e geometria. Uma pequena alteração de profundidade pode quase não ser percebida em uma imagem renderizada, mas pode mudar o ponto no qual dois corpos colidem. Da mesma forma, uma superfície de apoio irregular pode sustentar um objeto em uma posição diferente da esperada ou permitir que ele atravesse uma região da malha. Além disso, massa, inércia, atrito e articulações não são obtidos de maneira geral apenas a partir das imagens usadas neste estudo.

A questão que orienta a dissertação é:

> **Em que medida uma reconstrução neural com decomposição de instâncias, combinada a pós-processamento geométrico, permite gerar ambientes domésticos estruturados para simulação robótica?**

Nesse enunciado, reconstrução neural designa a representação tridimensional aprendida pelo DM-NeRF a partir das imagens e poses. A resposta é construída por avaliações separadas: as imagens sintetizadas são comparadas às imagens de referência; as instâncias são comparadas por suas máscaras; a malha é comparada à geometria de referência; os objetos separados são verificados por sua topologia; e a cena exportada é carregada e testada no Gazebo.

1.2 Objetivos

O objetivo geral é avaliar a capacidade de uma cadeia baseada em DM-NeRF e pós-processamento geométrico de transformar uma representação aprendida da cena, com identificadores de instância, em um ambiente doméstico estruturado para o Gazebo Classic.

Os objetivos específicos são:

1) reproduzir o DM-NeRF na cena *study* do DM-SR e avaliar a síntese de vistas e a decomposição de instâncias pelo protocolo oficial;

2) avaliar a qualidade geométrica da malha extraída, distinguindo-a da qualidade das imagens sintetizadas;

3) estruturar a cena em objetos tridimensionais independentes e selecionar e regularizar geometricamente sua superfície de apoio; e

4) avaliar a integração da cena estruturada no Gazebo Classic segundo critérios funcionais definidos previamente.

O registro do custo computacional e da origem dos artefatos acompanha transversalmente essas etapas, de modo que as medições possam ser relacionadas às entradas e aos programas que as produziram.

1.3 Delimitação e contribuição

O escopo experimental adota o DM-NeRF como método principal, o DM-SR como conjunto de dados e a cena *study* como estudo de caso. A avaliação geométrica inclui o COLMAP, que reconstrói a superfície comparando imagens obtidas de diferentes posições. Ele funciona como referência externa para a geometria tridimensional; a identificação de instâncias e a integração com o Gazebo são avaliadas somente na cadeia baseada em DM-NeRF.

A contribuição consiste na formulação e na análise experimental do percurso entre a saída do DM-NeRF e uma cena estruturada para simulação. O trabalho associa os identificadores de instância à topologia da malha, trata separadamente as faces situadas entre rótulos diferentes, seleciona uma superfície de apoio por critérios geométricos e a regulariza somente quando esses critérios são satisfeitos. Cada resultado é medido no ponto correspondente da cadeia: aparência e máscaras nas vistas, distâncias na geometria, preservação de faces na separação e funcionamento após a exportação.

Neste experimento, o DM-NeRF fornece identificadores que permitem distinguir os objetos individuais da cena. Esses identificadores são usados para separar os objetos e organizar a cena para simulação. A avaliação verifica essa separação; identificar a categoria de cada objeto, como “cadeira” ou “mesa”, fica fora do escopo.

O processo recebe como entrada imagens, posições e orientações das câmeras e mapas que identificam os objetos em cada imagem. Com esses dados, o DM-NeRF é treinado para representar a cena e suas instâncias. Os programas consultam o modelo treinado para extrair uma malha e a separam em objetos individuais. Em seguida, procuram uma superfície que possa corresponder ao piso e, quando ela atende aos critérios definidos, ajustam seus vértices a um plano. Por fim, geram os arquivos que carregam a cena no Gazebo. É essa sequência de processamento que o trabalho chama de automatizada: depois que as entradas são fornecidas, as etapas são executadas sem editar manualmente a malha de cada objeto.

2 FUNDAMENTAÇÃO E TRABALHOS RELACIONADOS

2.1 Representações neurais de cenas e superfícies

Gerar uma imagem de uma cena a partir de uma câmera nova exige estimar o que existe ao longo de cada raio que parte dessa câmera. O NeRF de Mildenhall et al. [6] representa essa informação por uma rede neural. Ao consultar uma posição no espaço, a rede fornece uma densidade volumétrica, isto é, um valor usado para estimar quanto aquela região contribui para bloquear o raio. A consulta também fornece uma cor que depende da posição e da direção de observação. Os valores de vários pontos ao longo do raio são combinados por renderização volumétrica para formar cada pixel da imagem.

O NeRF original foi proposto para sintetizar novas vistas. Sua densidade pode ser convertida em uma superfície, mas a formulação não representa diretamente a distância até essa superfície. NeuS, de Wang et al. [11], e VolSDF, de Yariv et al. [15], incorporam uma função de distância assinada à representação implícita. O sinal indica de que lado da superfície está um ponto e o módulo representa sua distância à superfície. Essa formulação favorece a extração de malhas, embora não garanta, por si só, que a geometria reconstruída coincida com a geometria real.

Na robótica, outro problema é atualizar uma representação tridimensional enquanto a câmera se desloca. O iMAP, de Sucar et al. [9], e o NICE-SLAM, de Zhu et al. [17], usam representações implícitas para estimar simultaneamente o mapa e a posição da câmera. Esses sistemas aproximam campos neurais de tarefas robóticas, mas uma cena para o Gazebo ainda precisa definir separadamente os modelos que serão visualizados, movidos e usados no cálculo de colisões.

2.2 Estrutura de objetos e reconstrução panóptica

Para consultar ou editar um objeto sem alterar o restante da cena, a representação precisa distinguir cada objeto do fundo e dos demais elementos. O Panoptic Neural Fields, proposto por Kundu et al. [4], representa o fundo e cada objeto por redes separadas. Cada objeto ocupa uma caixa tridimensional orientada, e sua rede fornece cor e densidade em coordenadas locais. Essa organização permite remover, adicionar ou clonar objetos e

alterar a posição ou a orientação de suas caixas antes de renderizar uma nova imagem. A edição ocorre na representação neural; o método não tem como saída principal malhas de colisão ou um mundo de simulador.

Assim como o Panoptic Neural Fields, outros trabalhos procuram manter informações de objetos de maneira coerente entre diferentes imagens. Eles tratam, contudo, etapas distintas do problema. O Panoptic Lifting, de Siddiqui et al. [8], recebe imagens, poses e segmentações panópticas bidimensionais e resolve as inconsistências dos identificadores entre as vistas para formar uma representação panóptica tridimensional. O Contrastive Lift, de Bhalgat et al. [1], combina características aprendidas em diferentes ritmos para consolidar a separação das instâncias. O PanoRecon, de Wu et al. [13], reconstrói a partir de vídeo monocular em tempo real e mantém as instâncias ao longo da sequência. Esses métodos produzem representações nas quais os objetos podem ser identificados, mas não organizam diretamente os objetos como modelos e colisões de uma cena no Gazebo.

A comparação geométrica desta dissertação requer ainda um método que não dependa de um campo neural. O COLMAP reconstrói a geometria comparando imagens obtidas de diferentes posições. Seu componente de reconstrução estereoscópica multivista, ou MVS, procura correspondências entre as imagens para estimar profundidade e orientação local da superfície; depois, combina os mapas de profundidade em uma nuvem de pontos [7]. Nesta dissertação, a nuvem do COLMAP e a malha extraída do DM-NeRF são comparadas à geometria de referência do DM-SR pelas mesmas distâncias e pelos mesmos F-scores. A aparência das imagens, a separação dos objetos e o funcionamento no Gazebo são avaliados separadamente.

O DM-NeRF, proposto por Wang et al. [10], é o método usado para representar a cena e identificar suas instâncias. Ele acrescenta ao NeRF um campo de objetos, aprendido com rótulos bidimensionais, e permite consultar um código de instância junto à cor e à densidade. O artigo original também manipula objetos no campo neural por consultas inversas antes da renderização. A partir dessa representação, esta dissertação investiga outra sequência: extrai uma malha, associa os IDs à sua topologia, separa os objetos, trata a superfície de apoio e gera uma cena para o Gazebo Classic. A contribuição concentra-se em estruturar essas etapas posteriores e avaliar seus resultados geométricos, estruturais e funcionais.

2.3 Geração de ambientes para simulação

Gerar um ambiente para simulação exige definir a geometria dos objetos e, conforme a aplicação, suas partes móveis e relações. Os trabalhos a seguir partem de imagens ou vídeos, mas diferem quanto ao uso de modelos previamente disponíveis e quanto ao tipo de cena produzido.

O URDFormer, de Chen et al. [2], parte de uma imagem e produz uma hierarquia

em *Unified Robot Description Format* (URDF), formato que descreve elos e juntas. O método identifica partes, relações e articulações e usa ativos tridimensionais disponíveis previamente. Sua saída favorece a estrutura cinemática; ela não procura reproduzir, por reconstrução multivista, cada superfície observada.

O DRAWER, de Xia et al. [14], recebe vídeo e combina geometria implícita, aparência e articulações para produzir ambientes interativos. O GRS, de Zook et al. [18], parte de observações RGB-D, segmenta a cena e recupera ativos para compor tarefas de simulação. Nos dois casos, o objetivo inclui comportamento ou estrutura funcional. A cadeia desta dissertação mantém como geometria os dados extraídos do DM-NeRF e mede o que ocorre ao convertê-los em modelos independentes; ela não substitui os objetos observados por ativos de um catálogo.

Em trabalho anterior, Lemos et al. [5] exploraram a descrição e reconstrução de ambientes com segmentação panóptica, incluindo separação de componentes, tratamento do piso e geração de uma cena editável no Gazebo. A presente dissertação amplia esse desenvolvimento ao fixar o DM-NeRF como método principal e submeter a cadeia a um protocolo quantitativo que distingue síntese, geometria, estrutura e funcionamento. Os resultados da publicação anterior não são combinados com as medições atuais.

2.4 Comparação por características

A Tabela 1 permite comparar os trabalhos por três perguntas: quais dados entram no método, que representação ele produz e se essa representação já corresponde a uma cena para simulação. A indicação de que o simulador não é a saída principal significa que o trabalho resolve síntese, reconstrução ou compreensão de cena, mas não entrega diretamente modelos com geometria de colisão. As linhas sobre URDFormer, DRAWER e GRS mostram uma estratégia diferente, baseada em hierarquias, articulações ou ativos. A última linha descreve a cadeia avaliada nesta dissertação.

Tabela 1: Comparação qualitativa entre trabalhos relacionados e a cadeia desta dissertação.

Trabalho	**Entrada**	**Representação, estrutura e relação com simulação**
Panoptic Neural Fields	imagens e predições 2D	campo neural separado em objetos e fundo, com edição antes da renderização; simulador não é a saída principal
Panoptic Lifting	RGB, poses e máscaras panópticas	campo neural panóptico 3D; não gera cena de simulação
PanoRecon	vídeo monocular	reconstrução online com instâncias; simulador não é o objetivo principal
DM-NeRF	RGB, poses e mapas 2D de instância	campo neural com IDs de objeto e manipulação antes da renderização; não gera cena diretamente
COLMAP	RGB e poses fixas	nuvem densa por MVS, sem instâncias ou cena de simulação
URDFormer	imagem RGB	hierarquia URDF com ativos predefinidos para simulação articulada
DRAWER	vídeo	ambiente interativo com geometria e articulações
GRS	RGB-D	segmentação, recuperação de ativos e tarefas de simulação
Cadeia avaliada nesta dissertação	RGB, poses e mapas 2D de instância	malha DM-NeRF, IDs, objetos separados e cena SDFormat no Gazebo Classic

A tabela não estabelece uma classificação de desempenho, pois as entradas e as saídas não são equivalentes. Panoptic Neural Fields, Panoptic Lifting, PanoRecon e DM-NeRF tratam a representação ou a identificação dos objetos. URDFormer, DRAWER e GRS se aproximam da geração de conteúdo funcional, com articulações ou ativos. A cadeia avaliada aqui ocupa a passagem entre esses grupos: parte dos IDs e da geometria do DM-NeRF, materializa objetos independentes e verifica sua utilização no Gazebo.

3 METODOLOGIA

3.1 Visão geral

O estudo segue uma sequência que transforma os dados da cena em um ambiente utilizável no Gazebo Classic. Primeiro, o DM-NeRF é treinado com as imagens, as poses das câmeras e os mapas de instância do DM-SR. O modelo treinado é avaliado em vistas de teste e consultado para extrair uma malha triangular com um identificador de instância por vértice. Em seguida, os triângulos são separados em objetos independentes. Entre esses objetos, uma regra geométrica procura uma superfície candidata a piso e, quando os critérios são atendidos, projeta seus vértices sobre um plano. Por fim, as malhas visuais e de colisão são organizadas em arquivos SDFormat para carregar a cena no simulador.

A Figura 1 deve ser lida de cima para baixo. O primeiro bloco contém as imagens, as poses e os mapas de instância usados no treinamento. O bloco DM-NeRF representa a cena e permite avaliar as imagens e os IDs de objeto nas vistas de teste. Em A0, a representação é convertida em malha e sua geometria é comparada à referência. A1 separa essa malha em objetos independentes. A etapa seguinte seleciona o candidato a piso, e A2 regulariza essa superfície. O último bloco descreve a cena em SDFormat e a carrega no Gazebo. Os quadros à direita indicam o que é medido após cada transformação.



Figura 1: Cadeia metodológica entre as observações do DM-SR e a cena no Gazebo Classic, com as medidas empregadas em cada etapa.

Por convenção deste experimento, as condições da ablação interna são identificadas pelo prefixo A: A0 corresponde à malha extraída, A1 acrescenta a separação dos objetos e A2 acrescenta a regularização do piso. As verificações no Gazebo recebem o prefixo G e avançam da validação estática, G0, aos ensaios funcionais G1–G3. A numeração expressa, portanto, a progressão cumulativa da cadeia, e não uma nomenclatura própria do DM-NeRF.

A Tabela 2 relaciona cada transformação às medidas usadas para avaliar seu resultado. PSNR, SSIM e LPIPS comparam as imagens sintetizadas às referências, enquanto AP mede a correspondência das instâncias. Para a malha A0, usam-se distâncias entre superfícies, Precision, Completeness e F-score. A1 é verificada pelo número de instâncias, pela cobertura das faces e pelas fronteiras. A2 é medida pelos resíduos dos vértices ao plano. Por fim, G0–G3 examinam os arquivos e o funcionamento da cena no Gazebo. A associação evita atribuir a uma etapa uma métrica que ela não pode alterar: A1,

por exemplo, separa os objetos sem modificar intencionalmente as coordenadas das faces preservadas.

Tabela 2: Etapas da cadeia e medidas utilizadas.

Etapa	**Transformação**	**Medida principal**
Neural	treinamento e avaliação do DM-NeRF	PSNR, SSIM, LPIPS e AP em vistas de teste
A0 – malha	extração da malha	distâncias de superfície, Precision, Completeness e F-score
A1 – objetos	separação por IDs explícitos	número de instâncias, cobertura de faces e fronteiras
A2 – piso	regularização do candidato a piso	resíduos ao plano antes/depois
Gazebo	exportação e execução	verificações G0–G3

3.2 Conjunto de dados DM-SR

O DM-SR é um conjunto sintético de ambientes internos criado para avaliar decomposição e manipulação de cenas. Para cada vista, ele fornece uma imagem RGB, a posição e a orientação da câmera e um mapa de instâncias. Nesse mapa, cada pixel recebe o ID do objeto visível naquela posição; o ID distingue objetos individuais, mas não informa necessariamente uma categoria como mesa ou cadeira. O conjunto também fornece uma malha tridimensional de referência.

Para a cena *study*, o experimento utiliza 300 imagens de treinamento e 100 vistas de teste do protocolo original. A malha de referência e os metadados de câmera são mantidos nas avaliações geométricas; quatro vistas de teste são usadas nas comparações qualitativas.

Quatro vistas reais da cena, extraídas do conjunto de teste, são apresentadas posteriormente junto às renderizações correspondentes do DM-NeRF (Figura 3). Essa comparação introduz visualmente a configuração doméstica/escritório e evita repetir as mesmas imagens em figuras distintas.

A malha de referência tem 437.008 vértices e 844.701 faces. O procedimento oficial de extração de malha do DM-NeRF utiliza o *oriented bounding box* dessa referência para definir o volume e a orientação da consulta ao campo neural. Dessa forma, a referência participa da definição do domínio de extração, e as métricas geométricas são interpretadas dentro desse domínio.

Os mapas de instância do DM-SR utilizam identificadores inteiros, mas os artefatos inspecionados não fornecem um catálogo semântico completo que associe cada ID a uma classe do ambiente. Em particular, não foi encontrada uma associação oficial entre um ID e a classe piso.

3.3 Treinamento e avaliação do DM-NeRF

A reprodução utiliza a implementação oficial do DM-NeRF. A configuração final usa 64 amostras no passe inicial, 128 amostras adicionais, 3.072 raios no treinamento e 1.024 raios no avaliador. O treinamento foi realizado com precisão mista automática; a avaliação final e a extração da malha foram mantidas em FP32.

O avaliador oficial calcula a razão sinal-ruído de pico (PSNR), o índice de similaridade estrutural (SSIM) [12] e a distância perceptual LPIPS [16] para síntese de vistas; o PSNR segue a definição usada no protocolo do DM-NeRF [10]. Para decomposição, a interseção sobre união (IoU) mede a sobreposição entre uma máscara predita e sua referência, e a precisão média (AP) resume a qualidade das detecções em um limiar de IoU, conforme o avaliador do método. Valores maiores indicam melhor correspondência. São usados os limiares de IoU 0,50, 0,75, 0,80, 0,85, 0,90 e 0,95. A função de perda e as métricas emitidas durante o treinamento não são utilizadas como resultados de teste.

3.4 Extração da malha e verificações de consistência

Após o treinamento, a rede representa a cena por uma função que pode ser avaliada em diferentes posições do espaço. Essa função é o campo neural. Para extrair a geometria, o procedimento oficial avalia o campo em pontos do volume delimitado pela caixa orientada da referência. A partir dos valores de densidade, constrói uma malha triangular. Para cada vértice, o procedimento também consulta o campo de objetos e registra o identificador de instância correspondente. A condição A0 reúne essa geometria e o vetor de IDs. As cores presentes na visualização servem somente para apresentação; a separação usa os identificadores numéricos, e não os valores RGB.

Antes de separar os objetos, uma rotina verifica se a malha e os identificadores de instância correspondem entre si. Ela confere a quantidade e a ordem dos vértices, os índices que formam os triângulos, a estrutura de conexão da malha e se todas as coordenadas possuem valores numéricos finitos. Essas verificações evitam atribuir a um vértice o ID de outro caso a ordem dos vértices seja modificada. A malha final contém 356.272 vértices e 710.928 faces.

3.5 Separação estrutural (A1)

A condição A1 é formada a partir de A0. Para cada triângulo, são consultados os IDs de seus três vértices. Uma face é atribuída a uma instância somente quando os três IDs coincidem. Faces com IDs diferentes são classificadas como faces de fronteira e permanecem fora das malhas individuais. A decisão evita escolher arbitrariamente um dos rótulos presentes na face.

Para cada instância com faces homogêneas, os vértices utilizados são remapeados e

uma malha independente é exportada. São registrados o ID, o número de vértices e faces, a área, os limites espaciais e o centroide. A cobertura de faces homogêneas e a quantidade de fronteiras são calculadas sobre a topologia original.

3.6 Seleção geométrica do piso

Como não há rótulo semântico oficial para o piso, a seleção usa uma heurística geométrica definida antes da observação da malha final. Cada instância é analisada somente pelas faces homogêneas. O plano principal é obtido por covariância dos vértices dessas faces com ponderação pela área dos triângulos. São calculados área, fração de área aproximadamente horizontal, normal, altura e RMSE do ajuste.

Uma instância é elegível quando satisfaz simultaneamente: área de pelo menos 0,5 m^2; pelo menos 85% da área com orientação de até 15 graus da vertical; normal do plano dentro do mesmo limite angular; RMSE de no máximo 0,03 m; e posição na faixa inferior da cena, definida pelo percentil 1 das alturas acrescido de 20% da amplitude vertical. O eixo vertical da malha é +Y.

Entre candidatas elegíveis, a maior área é escolhida se a segunda candidata tiver área inferior a 80% da primeira. Caso contrário, a saída é ambígua. Se nenhuma instância for elegível, a saída é "não identificada". Em ambos os casos de abstenção, A2 é bloqueada. A regra não utiliza cor, número de ID ou associação histórica como critério semântico.

3.7 Regularização do piso (A2)

Quando existe candidato válido, os vértices associados ao ID selecionado são usados no algoritmo *Random Sample Consensus* (RANSAC) de Fischler and Bolles [3], que ajusta um modelo robusto mesmo na presença de pontos discrepantes. O limiar é 2 cm e a semente é fixa. O plano final é ajustado aos inliers. A regularização projeta apenas os vértices da instância selecionada sobre esse plano. A topologia e os IDs não são alterados.

O efeito é medido sobre o mesmo subconjunto antes e depois da projeção. São reportados erro absoluto médio, RMSE, P95 e fração de inliers. Uma redução desses resíduos indica apenas maior aderência ao plano estimado. Como a operação é uma projeção, a redução é esperada por construção e não demonstra aumento de fidelidade global em relação ao ambiente real.

3.8 Exportação para Gazebo Classic

A exportação gera mundos SDFormat com referências relativas. A0 é representada por uma malha única. A1 e A2 são representadas por modelos independentes derivados das instâncias. Cada modelo possui um link, um elemento visual e um elemento de colisão apontando para a mesma malha triangular. O referencial +Y da reconstrução é

rotacionado para +Z do Gazebo por uma transformação rígida comum.

A validação G0 verifica XML, nomes únicos, existência das malhas, caminhos relativos, escalas positivas e correspondência entre visual e colisão. Essa etapa não executa a física e não substitui o parser nativo do Gazebo. G1, G2 e G3 verificam, respectivamente, carregamento real, manipulação independente e suporte/colisão do piso.

4 PROTOCOLO EXPERIMENTAL

4.1 Unidade experimental e proveniência

A cena *study* é a unidade experimental. Ela representa um ambiente de trabalho com mesas, cadeiras, armário e objetos menores sobre o mobiliário. A Figura 2 apresenta uma vista RGB do próprio DM-SR, diferente das quatro vistas usadas posteriormente nas comparações qualitativas. Essa imagem permite reconhecer os elementos cuja aparência, geometria e separação são avaliadas ao longo do protocolo.

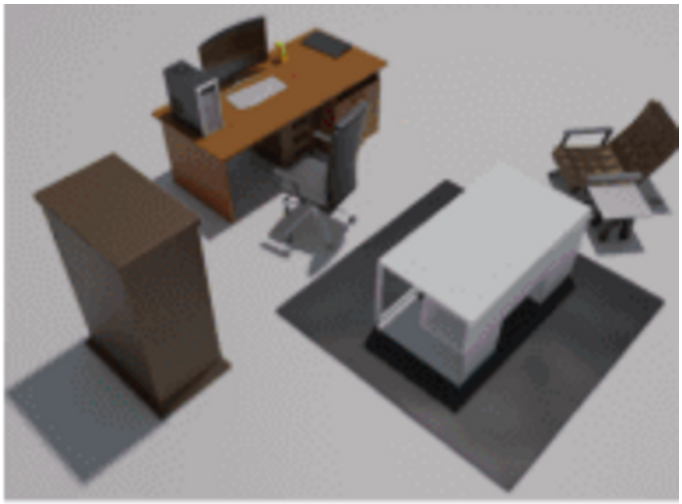


Figura 2: Vista RGB de referência da cena *study*, usada como estudo de caso. A cena contém duas mesas, assentos, armário e objetos menores; esses elementos aparecem posteriormente na avaliação da síntese, da geometria e da separação por instâncias. Fonte: material oficial do DM-NeRF/DM-SR [10].

O mesmo modelo, obtido após 200.000 iterações em três sessões de treinamento, é empregado na avaliação de vistas, na decomposição e na extração geométrica.

A configuração, o ambiente computacional e as saídas brutas foram preservados para reprodução. Antes da análise, verificou-se a consistência entre o resumo do avaliador oficial, as métricas das 100 vistas de teste e os artefatos geométricos extraídos.

Os scripts, configurações e instruções de execução estão versionados no repositório

`https://github.com/Jfsslemos/sdf-generator`. A configuração empregada nos resultados corresponde ao commit `e8bef9b7dc77`. O repositório registra o processamento desde o treinamento e a avaliação oficial até a extração, a separação por instância, a análise geométrica, a exportação SDFormat e os testes estáticos. As saídas numéricas usadas nas tabelas permanecem associadas aos arquivos que as produziram, enquanto artefatos volumosos são mantidos fora do controle de versão.

4.2 Condições de ablação A0, A1 e A2

O prefixo A identifica as condições da ablação interna, e a numeração representa estados cumulativos do pós-processamento: 0 para a saída sem essas transformações, 1 após a separação estrutural e 2 após a regularização do piso. As três condições são derivadas da mesma reconstrução:

- **A0**: malha extraída do campo neural, antes do pós-processamento geométrico;
- **A1**: A0 separada em objetos por IDs explícitos de instância; e
- **A2**: A1 com projeção dos vértices do candidato a piso sobre o plano estimado.

A0 é avaliada por métricas de superfície. A1 é avaliada por cobertura da separação e quantidade de objetos; as coordenadas das faces preservadas não são modificadas. A2 é avaliada por métricas pareadas do piso e por suporte e colisão no simulador.

4.3 Síntese de vistas e decomposição

Esta etapa verifica duas propriedades do modelo treinado. A primeira é se ele gera, para câmeras de teste, imagens próximas às referências. A segunda é se o ID previsto em cada região da imagem corresponde ao objeto indicado pelo mapa de instâncias de referência.

As métricas de síntese são PSNR, SSIM e LPIPS. Para PSNR e SSIM, valores maiores indicam maior semelhança com a imagem de referência; para LPIPS, valores menores indicam maior semelhança perceptual. Na decomposição, a interseção sobre união (IoU) mede quanto a máscara prevista e a máscara de referência se sobrepõem. A precisão média (AP) resume as correspondências que atingem um limiar mínimo de IoU. São usados AP50, AP75, AP80, AP85, AP90 e AP95. Quanto maior o sufixo, mais exata precisa ser a sobreposição; em todos os casos, AP maior é melhor. As médias são calculadas sobre as 100 vistas de teste e conferidas contra os resultados individuais.

4.4 Avaliação geométrica

A avaliação geométrica verifica se a superfície reconstruída ocupa posições próximas às da malha de referência e se cobre as mesmas regiões da cena. Essa verificação é distinta da comparação de imagens: um objeto pode aparecer corretamente em uma vista e estar deslocado em profundidade.

A0 e a malha de referência são amostradas com 200.000 pontos de superfície, usando a semente 42 para tornar a amostragem repetível. Para cada ponto de A0, calcula-se a distância até o ponto mais próximo da referência; depois, repete-se o cálculo da referência para A0. As duas direções são necessárias porque uma reconstrução pode produzir pontos próximos da referência e, ao mesmo tempo, deixar regiões da referência sem cobertura. As métricas incluem a distância média em cada direção, a soma das duas médias como distância simétrica L1 e o RMSE em cada direção.

Para um limiar t, Precision é a fração dos pontos reconstruídos que está a no máximo t da referência. Completeness é a fração dos pontos da referência que encontra algum ponto reconstruído a no máximo t. O F-score é a média harmônica dessas duas frações e só permanece alto quando precisão e cobertura são altas. O protocolo usa limiares de 1, 2 e 5 cm para mostrar como a conclusão muda entre uma exigência de coincidência fina e uma tolerância mais ampla.

A interpretação considera a dependência do bounding frame da referência no meshing oficial. Portanto, as métricas descrevem a saída dentro do protocolo reproduzido; não são apresentadas como uma avaliação cujo volume de extração foi obtido independentemente do *ground truth*.

4.5 Baseline geométrico externo

O COLMAP reconstrói a geometria procurando pontos correspondentes em imagens obtidas de diferentes posições. Ele é usado somente como referência externa para a geometria: sua nuvem de pontos e a malha A0 são comparadas à mesma malha de referência. O COLMAP não participa da separação A1, da regularização A2 nem dos testes no Gazebo.

Foi executado o MVS denso do COLMAP [7] com as 300 imagens de treinamento da cena *study*. Nesse processo, o PatchMatch estima profundidades ao procurar correspondências entre imagens, e a fusão reúne os mapas de profundidade em uma nuvem. As poses e os intrínsecos oficiais do DM-SR foram fornecidos diretamente; portanto, o ensaio mede a reconstrução densa e não a capacidade do COLMAP de estimar as câmeras. Para cada imagem de referência foram selecionadas as dez câmeras mais próximas em posição. O PatchMatch utilizou consistência geométrica, intervalo de profundidade de 4 a 15 m, e a fusão foi executada com `min_num_pixels=1`. Não foi realizada busca de hiperparâmetros.

A saída do COLMAP permanece no sistema de coordenadas das poses do DM-SR, enquanto o gerador de malha do DM-NeRF consulta a rede após a permutação de eixos $[x, y, z]_{rede} = [x, -z, y]_{cena}$. Antes da comparação, a nuvem COLMAP é portanto convertida de volta para o sistema da malha por $[x, y, z]_{cena} = [x, z, -y]_{COLMAP}$.

Há ainda uma diferença na região espacial coberta por cada saída. O meshing oficial do DM-NeRF consulta somente uma caixa orientada definida a partir da referência, com extensões fixas de $1,9 \times 7,0 \times 7,0$ m, enquanto o COLMAP pode produzir pontos além dessa caixa. Comparar volumes diferentes poderia penalizar o COLMAP apenas por reconstruir uma região maior ou favorecer um método por avaliar uma região menor. Por isso, as duas saídas são medidas no mesmo suporte orientado. Dos 5.800.316 pontos fundidos pelo COLMAP, 3.416.962 (58,91%) permanecem dentro desse volume. Em seguida, 200.000 pontos são amostrados com semente 42, igualando a cardinalidade usada na avaliação de A0. As métricas são calculadas pelas mesmas definições de distância, Precision, Completeness e F-score.

A comparação utiliza as métricas calculadas após a conversão de coordenadas e a equalização do suporte. Assim, as duas reconstruções são avaliadas sob a mesma convenção espacial e não se misturam referenciais distintos.

4.6 Avaliação da separação e do piso

A avaliação de A1 verifica se os IDs associados aos vértices podem ser convertidos em objetos independentes sem modificar a posição das faces preservadas. São registrados o número de instâncias, as faces homogêneas, as faces de fronteira e a cobertura. As faces de fronteira permanecem contabilizadas mesmo quando são omitidas das malhas individuais.

Para o piso, o relatório registra todos os candidatos e os motivos de rejeição. O RANSAC, ou consenso de amostras aleatórias, estima um plano a partir de subconjuntos de pontos e escolhe o modelo sustentado pelo maior conjunto de pontos próximos. A regularização usa limiar de 2 cm, 2.000 iterações e semente 42. O P95 é mantido como medida principal, acompanhado de média absoluta, RMSE e fração de inliers.

4.7 Validação funcional

O prefixo G identifica as verificações realizadas no Gazebo. A numeração avança da verificação estrutural estática para ensaios funcionais progressivamente mais específicos:

G0 validação estática do arquivo SDFormat e de suas referências;

G1 carregamento do mundo no Gazebo Classic sem erro fatal associado aos modelos;

G2 transformação independente de pelo menos uma instância em A1/A2;

G3 verificação pontual de apoio e colisão da superfície regularizada em A2.

G0 não é interpretado como demonstração de comportamento físico. G1–G3 verificam, em sequência, carregamento, independência estrutural e contato no ponto ensaiado.

4.8 Custo computacional

São reportados tempo de treinamento, atualizações efetivas, atualizações puladas pelo AMP, pico de memória alocada pelo PyTorch, pico observado pela telemetria, tempo de avaliação e tempo de extração da malha. O uso de GPU gratuita é uma condição de reprodução, não uma métrica de qualidade.

5 RESULTADOS

5.1 Treinamento e custo computacional

O treinamento foi concluído em três sessões, totalizando aproximadamente 30 h 58 min. O estado final registra 200.000 iterações, 199.916 atualizações efetivamente aplicadas pelo otimizador e 85 atualizações puladas pelo escalonador de AMP. Isso corresponde a aproximadamente 0,0425% das tentativas de atualização. A diferença entre iterações e atualizações ocorre quando a precisão mista detecta valores numéricos inadequados e evita aplicar aquela atualização.

O pico de memória alocada pelo PyTorch foi de aproximadamente 5,58 GiB e o pico observado pela telemetria do dispositivo foi 7.417 MiB. A avaliação oficial levou 2.568,48 s (42,8 min) e a extração da malha levou 109,13 s (1,82 min). A Tabela 3 reúne esses valores.

Tabela 3: Resumo da execução final.

Medida	**Valor**
Iteração final	200.000
Atualizações efetivas	199.916
Atualizações puladas por AMP	85
Tempo de treinamento	30 h 58 min
Pico PyTorch	5,58 GiB
Pico da telemetria	7.417 MiB
Tempo de avaliação	2.568,48 s
Tempo de meshing	109,13 s

A Tabela 3 mostra que o custo se concentra no treinamento por cena: avaliação e extração da malha somaram menos de 45 minutos, enquanto o treinamento consumiu quase 31 horas. Nesse regime, a cadeia prepara previamente um ambiente para simulação; ela não reconstrói a cena durante a execução de uma tarefa robótica.

5.2 Síntese de vistas

A Tabela 4 reúne as médias do avaliador oficial sobre 100 vistas de teste. As três primeiras colunas medem a aparência das imagens: PSNR e SSIM aumentam com a semelhança à referência, enquanto LPIPS diminui quando a distância perceptual é menor. As seis colunas seguintes medem a correspondência das máscaras de instância em exigências crescentes de sobreposição. A média oficial coincide com a agregação dos resultados por vista. Os valores de imagem descrevem a projeção observada pelas câmeras, mas não medem a posição da superfície tridimensional.

Tabela 4: Métricas do avaliador oficial na cena *study*.

PSNR	SSIM	LPIPS	AP50	AP75	AP80	AP85	AP90	AP95
41,1100	0,9875	0,0260	0,9956	0,9911	0,9849	0,9769	0,9311	0,7192

5.2.1 Comparação com os resultados publicados do DM-NeRF

A reprodução pode ser comparada diretamente aos valores publicados por Wang et al. [10] para a mesma cena *study* do DM-SR. Essa comparação é distinta de um novo baseline: seu objetivo é verificar se o estágio neural reproduz o comportamento reportado pelo método de origem antes de analisar as transformações propostas nesta dissertação. A Tabela 5 apresenta os valores.

Tabela 5: Comparação entre a reprodução desta dissertação e os resultados publicados para a cena *study* do DM-SR.

Fonte	**PSNR (dB)**	**SSIM**	**LPIPS**	**AP$_{0,75}$ (%)**
Wang et al. (2023)	41,08	0,987	0,026	98,86
Esta reprodução	41,110	0,9875	0,0260	99,11

As diferenças são de 0,03 dB em PSNR, 0,0005 em SSIM, aproximadamente zero em LPIPS na precisão reportada e 0,25 ponto percentual em AP$_{0,75}$. Como PSNR, SSIM e AP aumentam com a qualidade e LPIPS diminui, a proximidade ocorre em todas as direções esperadas das métricas. Com uma única cena, esses desvios não sustentam uma análise de significância estatística; eles mostram que a execução reproduz proximamente os valores publicados para *study*.

O mesmo artigo reporta, para a cena *study*, AP$_{0,75}$ de 96,86% para Mask R-CNN e 97,88% para Swin Transformer, ambos ajustados por cena, contra 98,86% do DM-NeRF publicado. A reprodução desta dissertação obteve 99,11%. Em relação aos valores publicados dos dois baselines 2D, a diferença é de 2,25 e 1,23 pontos percentuais, respectivamente. Esses números são usados como referência de literatura e não como reexecução independente dos baselines.

A Figura 3 compara as vistas 0, 33, 66 e 99 com as renderizações correspondentes. Cada coluna deve ser lida verticalmente: a primeira linha é a referência, a segunda é a imagem gerada pelo DM-NeRF e a terceira marca a diferença absoluta. Como as duas primeiras linhas são visualmente próximas, a diferença foi ampliada por um fator cinco apenas para visualização. As áreas claras nessa terceira linha se concentram em contornos, sombras e detalhes do mobiliário, enquanto as superfícies maiores mantêm aparência semelhante.

(a) Referência DM-SR



(b) Renderização DM-NeRF



(c) Diferença absoluta ampliada $5\times$

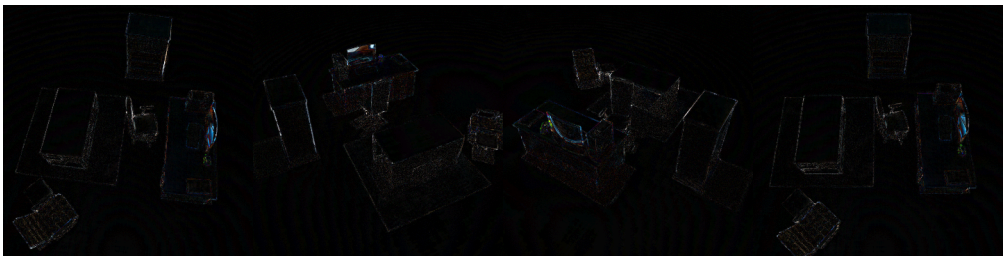


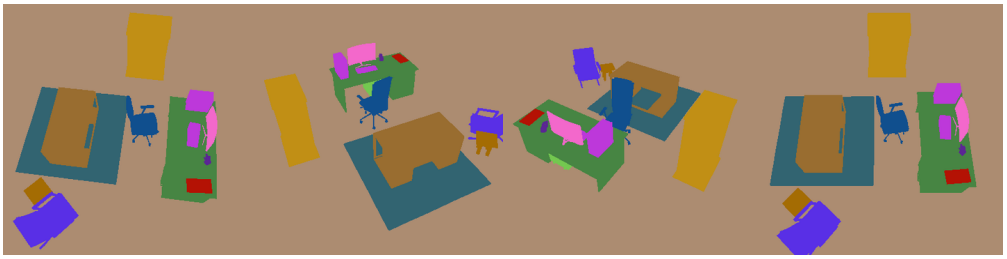
Figura 3: Síntese de vistas nas posições 0, 33, 66 e 99. A ampliação da diferença em (c) torna visíveis discrepâncias locais sem alterar as imagens comparadas.

5.3 Decomposição de instâncias

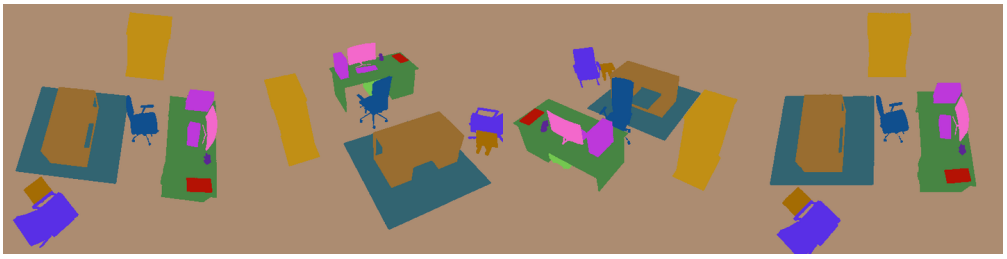
Os APs, para os quais valores maiores indicam melhor detecção e correspondência das máscaras, permanecem próximos de 1,0 nos limiares de IoU menos restritivos e diminuem quando a coincidência exigida se aproxima de 0,95. O AP50 é 0,9956, enquanto o AP95 é 0,7192. Esse comportamento indica que a correspondência geral das instâncias é mantida na maior parte das vistas, mas diferenças de contorno e pequenas regiões passam a afetar a métrica no limiar mais estrito. Como o protocolo fornece máscaras 2D durante o treinamento, os valores não demonstram descoberta de instâncias sem supervisão.

A Figura 4 compara os mapas de referência e predição nas mesmas quatro vistas. Cada cor identifica um objeto individual, e não sua categoria. A terceira linha marca em magenta os pixels cujo ID difere entre os dois mapas. O leitor deve observar que as regiões centrais dos objetos permanecem em grande parte iguais, enquanto as discordâncias se concentram nas fronteiras e em estruturas pequenas. Isso explica por que o AP permanece alto em IoU 0,50 e diminui quando a sobreposição exigida chega a 0,95.

(a) IDs de referência



(b) IDs preditos pelo DM-NeRF



(c) Pixels com IDs divergentes



Figura 4: Decomposição de instâncias nas vistas 0, 33, 66 e 99. Em (a) e (b), as cores identificam IDs, não classes semânticas; em (c), magenta indica divergência entre referência e predição.

5.4 Geometria extraída (A0)

A malha A0 final contém 356.272 vértices e 710.928 faces. A comparação visual com a referência DM-SR e o COLMAP aparece na Figura 5, sem repetir o mesmo enquadramento em uma figura isolada. A estrutura global da sala e dos objetos principais é reconhecível, mas a visualização também mostra regiões ruidosas e superfícies que não formam volumes fechados.

A Tabela 6 apresenta as distâncias médias e RMSE; em todas essas medidas, valores

menores indicam maior proximidade entre as superfícies. As duas direções têm valores próximos: 4,34 cm da predição para a referência e 4,14 cm da referência para a predição. Essa proximidade entre as direções indica que o erro médio não é dominado apenas por pontos excedentes da reconstrução nem apenas por regiões ausentes da referência. Os RMSEs, maiores que as médias, mostram que alguns pontos estão mais afastados e recebem peso maior pelo erro quadrático.

Tabela 6: Distâncias entre A0 e a referência DM-SR.

Medida	**Valor**
Média predição → referência	4,335 cm
Média referência → predição	4,139 cm
Distância simétrica L1	8,474 cm
RMSE predição → referência	5,757 cm
RMSE referência → predição	4,940 cm

Os resultados por limiar são apresentados na Tabela 7. Precision mede a fração da reconstrução situada perto da referência; Completeness mede a fração da referência coberta pela reconstrução; e o F-score combina as duas medidas. Valores maiores são melhores. A 1 cm, somente cerca de 5% dos pontos em cada direção encontram correspondência dentro do limiar. A 5 cm, Precision e Completeness passam de 0,75 e o F-score chega a 0,7750. Assim, a reconstrução representa melhor a estrutura quando se admite tolerância de 5 cm, sem sustentar coincidência fina em 1 cm.

Tabela 7: Precision, Completeness e F-score da geometria A0.

Limiar	**Precision**	**Completeness**	**F-score**
1 cm	0,04887	0,04724	0,04804
2 cm	0,20977	0,18398	0,19603
5 cm	0,79630	0,75478	0,77498

5.5 Baseline geométrico externo: COLMAP

O baseline COLMAP concluiu o PatchMatch e a fusão densa para as 300 vistas de treinamento, produzindo 5.800.316 pontos. Após a conversão para o sistema de coordenadas da malha e a restrição ao mesmo volume orientado empregado pelo meshing do DM-NeRF, 3.416.962 pontos permaneceram no suporte comum. A comparação usa uma amostra determinística de 200.000 pontos dessa nuvem, de modo a manter a mesma cardinalidade de A0 e da referência.

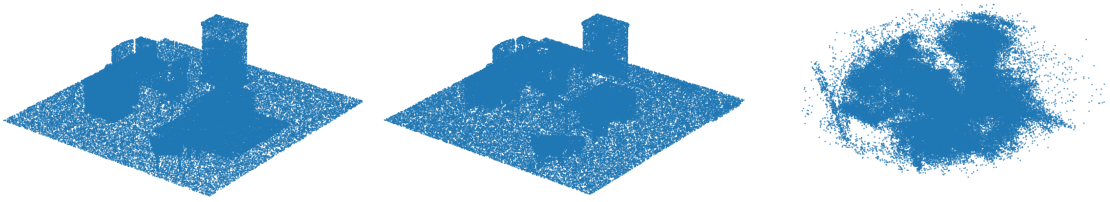
A Tabela 8 compara as duas reconstruções. A0 apresenta menor erro nas duas dire-

ções. A distância média da predição para a referência é 4,34 cm em A0 e 20,42 cm no COLMAP; no sentido referência para predição, os valores são 4,14 cm e 8,13 cm. A diferença entre as direções no COLMAP indica que parte relevante da superfície de referência possui pontos próximos, mas a nuvem contém espessamento e pontos afastados da superfície correta.

Tabela 8: Comparação geométrica entre A0 e o baseline COLMAP no mesmo suporte e com 200.000 pontos por conjunto.

Medida	**DM-NeRF A0**	**COLMAP**
Média predição → referência	4,335 cm	20,418 cm
Média referência → predição	4,139 cm	8,129 cm
Distância simétrica L1	8,474 cm	28,547 cm
RMSE predição → referência	5,757 cm	30,079 cm
RMSE referência → predição	4,940 cm	13,942 cm
F-score a 1 cm	0,0480	0,0285
F-score a 2 cm	0,1960	0,1288
F-score a 5 cm	0,7750	0,3721

A decomposição de Precision e Completeness ajuda a interpretar a diferença a 5 cm: A0 obtém 0,7963 e 0,7548, respectivamente, enquanto o COLMAP obtém 0,2710 e 0,5936. A completude do COLMAP é maior que sua precisão. Isso significa que sua nuvem chega perto de parte relevante da referência, mas uma parcela maior dos pontos reconstruídos permanece afastada da superfície correta. A Figura 5 permite observar esse espessamento ao comparar as três colunas no mesmo enquadramento. A Figura 6 mostra, para ambos os métodos, o aumento do F-score quando a tolerância passa de 1 para 5 cm; barras maiores são melhores.



(a) Referência DM-SR (b) DM-NeRF A0 (c) COLMAP

Figura 5: Comparação qualitativa da geometria no mesmo sistema de coordenadas, suporte e enquadramento. A nuvem COLMAP apresenta maior dispersão e superfícies mais espessas.

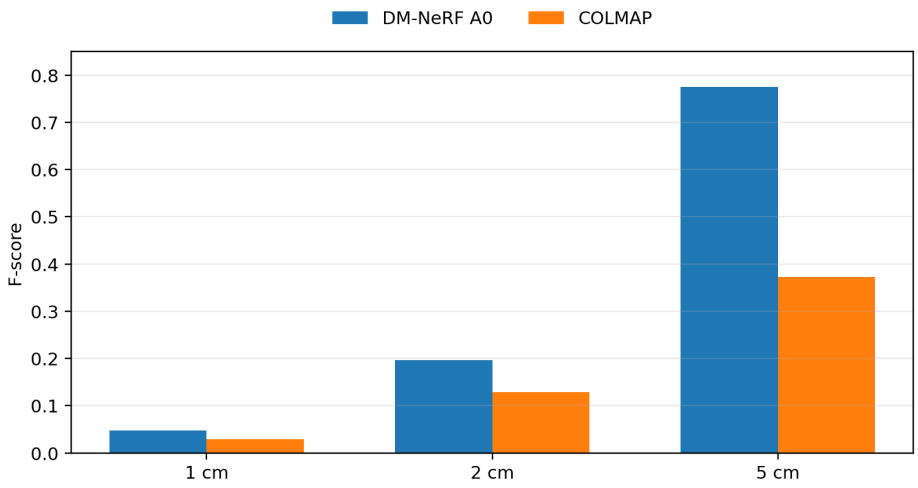


Figura 6: F-score geométrico de A0 e COLMAP nos limiares de 1, 2 e 5 cm.

5.6 Separação estrutural (A1)

A separação identificou 13 instâncias com faces homogêneas. Das 710.928 faces da malha original, 681.383 foram atribuídas a uma instância, enquanto 29.545 foram registradas como faces de fronteira. A Tabela 9 organiza essa contagem. A cobertura resultante é 95,844%; nesse indicador, valores maiores representam maior preservação da topologia nas malhas individuais. A1 não melhora a geometria de A0: seu resultado é estrutural, pois transforma os IDs associados à malha em arquivos e modelos que podem ser manipulados separadamente. A cobertura não mede estanqueidade nem corrige erros geométricos da malha de origem.

Tabela 9: Resumo da separação A1.

Instâncias exportadas	13
Faces da malha A0	710.928
Faces homogêneas exportadas	681.383
Faces de fronteira	29.545
Cobertura de faces homogêneas	95,844%

A Figura 7 mostra a mesma reconstrução em dois pontos de vista. As mudanças de cor marcam as fronteiras entre IDs e permitem reconhecer quais partes se tornaram objetos distintos. A identidade empregada no processamento vem do vetor de IDs, não da cor armazenada em `mesh_instances.ply`.



Figura 7: Visualização da reconstrução colorida por instância em dois pontos de vista. As cores são usadas somente para distinguir IDs.

A individualização também foi verificada nos arquivos exportados por instância. Fragmentos e fronteiras permanecem visíveis em alguns objetos; por essa razão, a Figura 7 apresenta a cena completa colorida por ID, e a Figura 9 mostra posteriormente cada entidade carregada separadamente no Gazebo.

5.7 Seleção e regularização do piso

A heurística geométrica selecionou a instância 10. Ela foi a única instância a satisfazer simultaneamente os critérios de área, orientação, planaridade e altura. A instância 9 também apresenta grande fração horizontal e baixa altura, mas seu RMSE de 3,23 cm excede o limite de 3 cm definido antes da execução final. A seleção identifica um candidato geométrico e não constitui rótulo semântico de piso fornecido pelo DM-SR.

No RANSAC aplicado à instância selecionada, 77,11% dos vértices ficaram a até 2 cm do plano estimado. Antes da projeção, a distância absoluta média era 2,051 cm, o RMSE era 5,722 cm e o P95 era 6,800 cm. O maior residual chegou a 1,64 m, indicando a presença de vértices associados ao mesmo ID afastados do plano principal. Esse valor não foi removido da análise.

A Tabela 10 compara o mesmo conjunto de vértices antes e depois da projeção. Para média absoluta, RMSE e P95, valores menores indicam maior proximidade ao plano; para a fração de inliers, valores maiores indicam que mais vértices estão a até 2 cm. A projeção de A2 leva os vértices selecionados ao plano, reduzindo média, RMSE e P95 a erro numérico. Essa redução ocorre por construção e descreve a planarização aplicada, não um aumento medido da fidelidade global da reconstrução. A consequência funcional é verificada separadamente pelo contato no Gazebo.

Tabela 10: Métricas da instância 10 antes e depois da regularização.

Medida	**A1**	**A2**
Média absoluta	2,051 cm	$< 10^{-12}$ cm
RMSE	5,722 cm	$< 10^{-12}$ cm
P95	6,800 cm	$< 10^{-12}$ cm
Fração de inliers (2 cm)	77,11%	100%

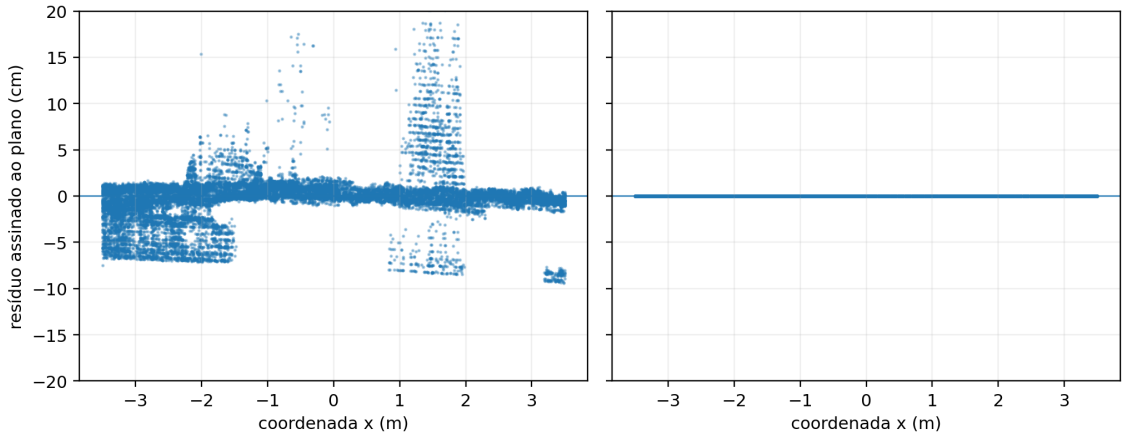


Figura 8: Resíduo assinado ao plano da instância 10 antes e depois da regularização. À esquerda, A1; à direita, A2. O eixo vertical é limitado a ± 20 cm para leitura da distribuição principal; o residual máximo de A1, 1,64 m, permanece reportado no texto e nas métricas.

Na Figura 8, a concentração dos pontos de A2 em torno de zero confirma o efeito da projeção. Em A1, a dispersão mostra as irregularidades do candidato original; o limite vertical de ± 20 cm permite ler a região principal sem ocultar do texto o residual máximo de 1,64 m.

5.8 Integração no Gazebo Classic

A Tabela 11 deve ser lida como uma sequência de propriedades distintas. G0 verifica a estrutura dos arquivos; G1 verifica se o Gazebo carrega os mundos; G2 verifica se um objeto separado pode ser deslocado sem mover os demais; e G3 verifica o contato em um ponto da superfície regularizada. A validação G0 passou para as três condições. A0 gerou um modelo correspondente à malha completa; A1 e A2 geraram 13 modelos independentes, com caminhos relativos para os arquivos de malha e correspondência entre os elementos visuais e de colisão.

Os testes de execução foram realizados no Gazebo Classic 11.10.2. Em G1, os mundos A0, A1 e A2 foram carregados e permaneceram ativos durante a janela de verificação. Foram observados apenas avisos relativos à aparência visual padrão, sem erros de carregamento das geometrias usadas nos testes.

Em G2, a instância `instance_006` da condição A1 foi deslocada em 0,25 m no eixo x por meio da interface do Gazebo. A pose consultada antes da operação era $(0, 0, 0)$ m e, após o comando, a coordenada x passou para 0,25 m. A operação foi dirigida somente a esse modelo, demonstrando que a separação de A1 foi materializada em entidades endereçáveis de forma independente no simulador.

O teste G3 utilizou uma caixa dinâmica de 10 cm de lado e massa de 0,2 kg, posicionada com centro em $z = 0,65$ m sobre uma região do candidato a piso regularizado. A primeira pose foi registrada seis segundos após o início da simulação, já depois da queda. Nesse instante, o centro da caixa estava em $z = 0,093811$ m; oito segundos depois, estava em $z = 0,093806$ m, variação de aproximadamente 5 μm.

Considerando metade da altura da caixa, sua face inferior permaneceu em $z = 0,043806$ m. A altura calculada do plano regularizado no ponto $(x, y) = (3,07411, -3,31338)$ m, após a rotação comum de +Y para +Z usada na exportação, é $z = 0,043810$ m. A diferença de aproximadamente 4 μm expressa a concordância numérica entre a pose registrada da face inferior da caixa e a altura calculada do plano no mesmo ponto, não uma medida de precisão física micrométrica do Gazebo. A caixa caiu aproximadamente 0,56 m, encontrou a superfície, não a atravessou no ponto ensaiado e permaneceu estável durante a segunda janela de observação; por esses critérios, G3 foi aprovado.

Tabela 11: Resultado das verificações de integração com o Gazebo Classic.

Verificação	**A0**	**A1**	**A2**
G0 – validação estática	passou	passou	passou
G1 – carregamento no Gazebo	passou	passou	passou
G2 – manipulação independente	–	passou	–
G3 – apoio/colisão do piso	–	–	passou

Para tornar a individualização visualmente verificável, a mesma cena A2 foi aberta com materiais de visualização distintos por instância. Essa alteração não modifica poses, geometrias de colisão nem os resultados G1–G3. Na Figura 9, as cores diferentes mostram que os elementos foram carregados como modelos separados. A caixa vermelha no canto superior esquerdo corresponde ao corpo dinâmico usado no ensaio G3; sua presença permite localizar o teste pontual, mas a captura não mede por si só a qualidade do contato.

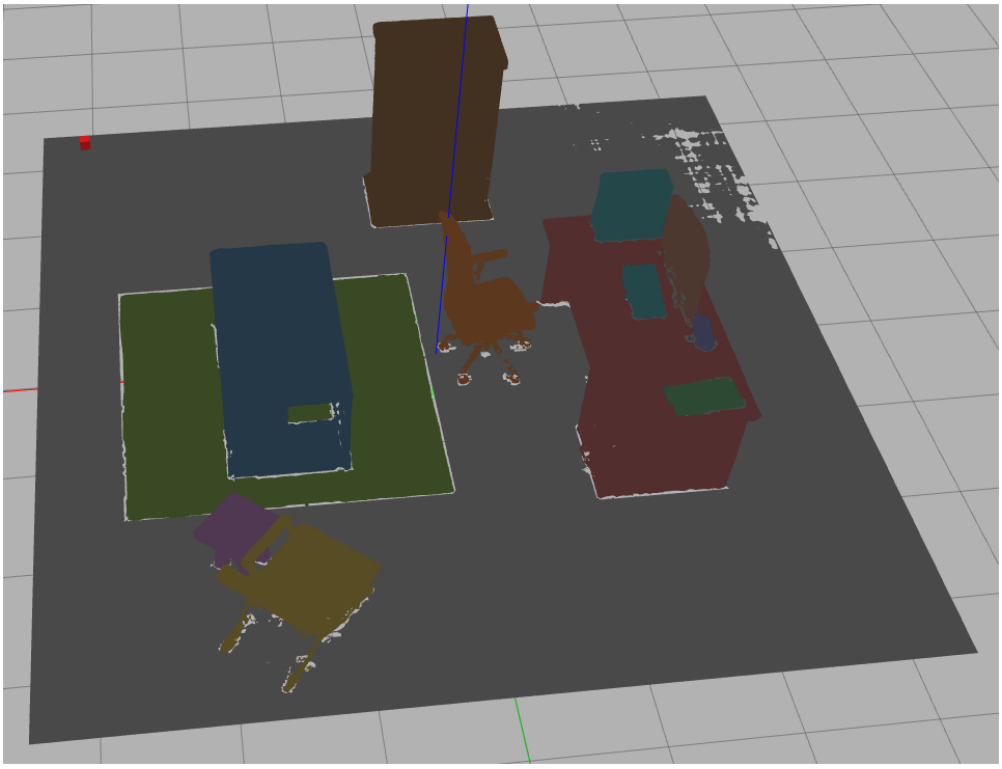


Figura 9: Cena A2 no Gazebo Classic com materiais visuais distintos por instância. As cores foram adicionadas somente para interpretação da figura; a geometria e as colisões são as mesmas usadas nos testes funcionais.

6 DISCUSSÃO

Os resultados ligam dois problemas que costumam ser avaliados separadamente. Métodos como DM-NeRF, Panoptic Neural Fields e Panoptic Lifting procuram gerar novas vistas, estimar superfícies ou manter a identidade dos objetos entre imagens. Para usar o resultado no Gazebo, porém, cada objeto precisa corresponder a um modelo com malha visual e malha de colisão. A cadeia estudada examina essa passagem. O DM-NeRF fornece aparência e IDs de instância em uma função aprendida; o pós-processamento extrai a malha, separa os objetos, trata a superfície de apoio e gera os modelos carregados pelo simulador.

Essa passagem não pode ser julgada apenas pelas métricas de imagem. O PSNR de 41,1100 dB, o SSIM de 0,9875 e o LPIPS de 0,0260 mostram que as vistas sintetizadas se aproximam das referências segundo medidas de erro, estrutura e percepção. Os valores também são próximos aos publicados por Wang et al. [10] para a mesma cena. Apesar disso, o F-score geométrico da malha é 0,0480 a 1 cm e 0,7750 a 5 cm. A diferença entre os limiares mostra que boa síntese visual não implica coincidência centimétrica da superfície: erros de profundidade ou espessura podem ter pequeno efeito na imagem renderizada e grande efeito na correspondência tridimensional. Para a robótica, essa distinção importa porque contato e colisão dependem da posição da superfície, e não apenas da aparência projetada.

Os resultados de AP avaliam a identidade dos objetos nas imagens. A redução de 0,9956 em AP50 para 0,7192 em AP95 indica que as instâncias são reconhecidas na maior parte das vistas, mas diferenças de contorno tornam-se relevantes quando a sobreposição exigida é quase total. Esse comportamento é compatível com a concentração das discordâncias nas fronteiras observada na comparação qualitativa. Como as máscaras 2D são fornecidas no treinamento, o resultado mede a reprodução dos IDs nas novas vistas; não mede descoberta de objetos sem supervisão.

Kundu et al. [4], Siddiqui et al. [8] e Wu et al. [13] tratam problemas que esta dissertação não procura resolver. Panoptic Neural Fields mantém uma representação neural orientada a objetos; Panoptic Lifting consolida informação panóptica entre vistas; e PanoRecon integra reconstrução monocular online com instâncias persistentes. Esses tra-

balhos ampliam a compreensão tridimensional da cena e, no caso de PanoRecon, tratam operação em tempo real. A presente cadeia parte de uma decomposição já produzida pelo DM-NeRF e concentra-se no passo posterior: associar IDs à topologia extraída, separar os componentes e fornecer uma estrutura consumível pelo simulador. Nesse contexto, a dissertação concentra-se nas etapas posteriores à decomposição: associação dos IDs à malha, separação dos objetos e geração e avaliação da cena destinada ao simulador.

A relação com URDFormer, DRAWER e GRS esclarece outra escolha. Chen et al. [2] inferem hierarquias e articulações e produzem descrições URDF; Xia et al. [14] combinam reconstrução e articulação de ambientes interativos; Zook et al. [18] recuperam ativos para compor tarefas de simulação. Essas abordagens privilegiam estrutura cinemática ou análogos funcionais formados por modelos previamente disponíveis. Aqui, a geometria observada permanece como fonte dos modelos exportados. Essa opção preserva a forma reconstruída e permite estudar seus erros, mas não fornece automaticamente juntas, massa, inércia ou materiais. Assim, reconstruir uma superfície e substituir objetos por ativos CAD são estratégias complementares: a primeira preserva particularidades da cena observada; a segunda pode fornecer geometria fechada e propriedades funcionais, ao custo de substituir o exemplar capturado. A dissertação avalia a primeira estratégia.

O COLMAP ocupa um papel deliberadamente restrito nessa análise. Ele fornece um baseline externo para a geometria densa porque reconstrói superfícies por correspondência multivista sem usar o campo neural. Não oferece, na configuração executada, decomposição de instâncias, associação semântica ou integração com o Gazebo; por isso, não seria correto compará-lo às condições A1 e A2 nem aos testes G0–G3. No mesmo suporte espacial e com amostras de igual cardinalidade, A0 obteve menor distância e maior F-score nos três limiares. Esse resultado descreve a cena *study*, as poses fornecidas e as configurações fixadas. Não estabelece superioridade geral do DM-NeRF sobre reconstrução fotogramétrica, sobretudo porque não houve otimização do COLMAP por cena e o volume de avaliação deriva do procedimento de meshing do DM-NeRF.

A condição A1 mostra o efeito estrutural que não aparece nas métricas de imagem ou de superfície. O processamento gerou 13 modelos e atribuiu 95,844% das faces a instâncias com rótulos homogêneos. As 29.545 faces restantes foram registradas como fronteiras em vez de serem atribuídas arbitrariamente. Com isso, a identidade deixa de ser somente um valor consultado no campo neural e passa a determinar arquivos e entidades que podem ser endereçados separadamente. O deslocamento isolado de uma instância no Gazebo confirma essa propriedade operacional. Ele não demonstra articulação nem comportamento físico do objeto, mas verifica que a organização da cena sobreviveu à exportação.

O tratamento da superfície de apoio ilustra por que a cadeia mede cada transformação separadamente. Na ausência de classe semântica oficial para o piso, a instância 10 foi selecionada por área, orientação, altura e planaridade. A regularização reduziu os resíduos

ao plano porque projeta os vértices sobre esse próprio plano; logo, o resultado quantifica a transformação aplicada, e não uma melhora automática da fidelidade global. O ensaio G3 acrescenta a consequência funcional: no ponto testado, a caixa caiu, encontrou a superfície, não a atravessou e permaneceu estável. A concordância numérica entre a face inferior da caixa e o plano serve para verificar a consistência do referencial naquele ponto, não a precisão física do simulador em toda a superfície.

O tempo de aproximadamente 30 h 58 min para treinar uma cena coloca o método no regime de preparação offline de ambientes. Essa característica é compatível com a criação prévia de cenários de teste, mas não com reconstrução durante uma tarefa robótica. O custo também ajuda a separar o objetivo deste trabalho de métodos online como PanoRecon: a questão investigada não é a atualização contínua do mapa, mas a conversão de uma reconstrução concluída em uma cena estruturada.

Em síntese, cada avaliação responde a uma pergunta concreta. As métricas de imagem verificam a aparência das vistas; os APs verificam os IDs nas máscaras; A0 mede a posição e a cobertura da superfície e a compara ao COLMAP; A1 mede quantas faces permanecem associadas aos objetos separados; A2 mede a alteração do candidato a piso; e G0–G3 verificam se os arquivos formam uma cena carregável, se um objeto pode ser deslocado isoladamente e se há contato no ponto ensaiado. Assim, uma imagem semelhante à referência não é usada como prova de que a geometria ou o funcionamento no simulador também estão corretos.

6.1 Validade e alcance

O estudo adota a cena *study* como estudo de caso controlado, mantendo fixos o conjunto de dados, as entradas e o protocolo de avaliação. As máscaras de instância são fornecidas ao DM-NeRF, e o volume do meshing depende da caixa orientada da referência DM-SR. O COLMAP recebeu as poses oficiais e uma configuração fixa, sem otimização específica por cena. As malhas individuais podem permanecer abertas nas fronteiras removidas, e a superfície de apoio foi escolhida por geometria, sem rótulo semântico de piso. A planarização de A2 decorre da operação de projeção, enquanto G3 verifica um único ponto. Massa, atrito, inércia e articulações não foram inferidos.

Dentro desses limites, o experimento demonstra que a reconstrução da cena estudada pode ser convertida em 13 entidades independentes, preservando a maior parte das faces, e carregada no Gazebo com manipulação individual e contato estável no local ensaiado. Também quantifica, no mesmo protocolo, a qualidade visual, a correspondência geométrica e o efeito das transformações estruturais, sem estender essas conclusões a outras cenas ou a propriedades físicas não observadas.

7 CONCLUSÃO

Esta dissertação partiu de um problema prático: uma representação capaz de gerar imagens semelhantes às referências ainda não corresponde aos modelos separados que o Gazebo usa para movimentar objetos e calcular colisões. A qualidade visual também não informa, sozinha, se as superfícies ocupam as posições corretas no espaço. Para tratar essa diferença, a cadeia extraiu uma malha do DM-NeRF, associou os IDs de instância à sua topologia, separou os objetos, regularizou uma superfície de apoio selecionada por geometria e exportou a cena para o Gazebo Classic.

Na cena *study*, a avaliação oficial em 100 vistas obteve PSNR de 41,1100 dB, SSIM de 0,9875 e LPIPS de 0,0260. A decomposição apresentou AP50 de 0,9956 e AP95 de 0,7192. A malha extraída atingiu F-score de 0,0480 a 1 cm, 0,1960 a 2 cm e 0,7750 a 5 cm. Essa variação mostra que a qualidade observada nas imagens não corresponde, necessariamente, à mesma precisão na geometria tridimensional. No mesmo suporte, o COLMAP obteve 0,0285, 0,1288 e 0,3721 nesses limiares.

A separação estrutural gerou 13 objetos, preservou 95,844% das faces homogêneas e registrou 29.545 faces de fronteira. A regra geométrica selecionou a instância 10 como superfície de apoio, e sua regularização reduziu o P95 do residual ao plano de 6,80 cm para erro numérico. No Gazebo Classic, as três condições foram carregadas, uma instância foi manipulada separadamente e a superfície regularizada sustentou o corpo dinâmico no ponto ensaiado.

Quanto à questão de pesquisa, os resultados mostram em que medida a conversão foi alcançada. Para a cena *study* e o protocolo adotado, o pós-processamento transformou a função aprendida pelo DM-NeRF em geometria explícita, 13 objetos independentes e uma cena executável no simulador. A semelhança das imagens não garantiu coincidência geométrica em escala centimétrica: o F-score foi baixo a 1 cm e aumentou quando a tolerância chegou a 5 cm. A estrutura acrescentada à saída do DM-NeRF permitiu carregar as três condições, deslocar um objeto isoladamente e sustentar a caixa no ponto ensaiado. A contribuição do trabalho está em avaliar separadamente as etapas que levam da saída neural à cena de simulação, relacionando medidas de aparência, geometria, estrutura dos objetos e funcionamento no simulador.

REFERÊNCIAS

[1] Bhalgat, Y., Laina, I., Henriques, J. F., Vedaldi, A., and Zisserman, A. (2023). Contrastive lift: 3d object instance segmentation by slow-fast contrastive fusion. In *Advances in Neural Information Processing Systems*.

[2] Chen, Z. Q., Walsman, A., Memmel, M., Mo, K., Fang, A., Fox, D., and Gupta, A. (2024). URDFormer: A pipeline for constructing articulated simulation environments from real-world images. In *Robotics: Science and Systems*.

[3] Fischler, M. A. and Bolles, R. C. (1981). Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography. *Communications of the ACM*, 24(6):381–395.

[4] Kundu, A., Genova, K., Yin, X., Fathi, A., Pantofaru, C., Guibas, L., Tagliasacchi, A., Dellaert, F., and Funkhouser, T. (2022). Panoptic neural fields: A semantic object-aware neural scene representation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.

[5] Lemos, J. F. d. S. S., Dorneles, G. A., Maurell, I. P., Brião, S. L., Guerra, R. d. S., and Drews Junior, P. L. J. (2025). Digital environment description and reconstruction using panoptic segmentation. In *RoboCup 2024: Robot World Cup XXVII*, volume 15570 of *Lecture Notes in Computer Science*, pages 236–246. Springer.

[6] Mildenhall, B., Srinivasan, P. P., Tancik, M., Barron, J. T., Ramamoorthi, R., and Ng, R. (2020). NeRF: Representing scenes as neural radiance fields for view synthesis. In *European Conference on Computer Vision*.

[7] Schönberger, J. L., Zheng, E., Frahm, J.-M., and Pollefeys, M. (2016). Pixelwise view selection for unstructured multi-view stereo. In *European Conference on Computer Vision*, pages 501–518.

[8] Siddiqui, Y., Porzi, L., Rota Bulò, S., Müller, N., Niessner, M., Dai, A., and Kontschieder, P. (2023). Panoptic lifting for 3d scene understanding with neural fields.

In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9043–9052.

[9] Sucar, E., Liu, S., Ortiz, J., and Davison, A. J. (2021). imap: Implicit mapping and positioning in real-time. In *IEEE/CVF International Conference on Computer Vision*.

[10] Wang, B., Chen, L., and Yang, B. (2023). DM-NeRF: 3d scene geometry decomposition and manipulation from 2d images. In *International Conference on Learning Representations*.

[11] Wang, P., Liu, L., Liu, Y., Theobalt, C., Komura, T., and Wang, W. (2021). NeuS: Learning neural implicit surfaces by volume rendering for multi-view reconstruction. In *Advances in Neural Information Processing Systems*.

[12] Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612.

[13] Wu, D., Yan, Z., and Zha, H. (2024). PanoRecon: Real-time panoptic 3d reconstruction from monocular video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21507–21518.

[14] Xia, H., Su, E., Memmel, M., Jain, A., Yu, R., Mbiziwo-Tiapo, N., Farhadi, A., Gupta, A., Wang, S., and Ma, W.-C. (2025). DRAWER: Digital reconstruction and articulation with environment realism. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21771–21782.

[15] Yariv, L., Gu, J., Kasten, Y., and Lipman, Y. (2021). Volume rendering of neural implicit surfaces. In *Advances in Neural Information Processing Systems*.

[16] Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. (2018). The unreasonable effectiveness of deep features as a perceptual metric. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 586–595.

[17] Zhu, Z., Peng, S., Larsson, V., Xu, W., Bao, H., Cui, Z., Oswald, M. R., and Pollefeys, M. (2022). NICE-SLAM: Neural implicit scalable encoding for slam. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.

[18] Zook, A., Sun, F.-Y., Spjut, J., Blukis, V., Birchfield, S., and Tremblay, J. (2025). GRS: Generating robotic simulation tasks from real-world images. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 594–603.